

Universidad Nacional del Sur

Tesis: Doctor en Control de Sistemas

LNET: una Estructura de Aproximación para Sistemas No Lineales Discretos

Guillermo Blas Sentoni

Bahía Blanca
Argentina

1997

Prefacio

Esta tesis es presentada como parte de los requisitos para optar al grado académico de Doctor en Control de Sistemas, de la Universidad Nacional del Sur y no ha sido presentada previamente para la obtención de otro título en esta Universidad ni en otras. La misma contiene los resultados de la investigaciones realizada bajo la dirección del Dr. Osvaldo Agamennoni.

Sin establecer orden alguno, deseo expresar mi más profundo agradecimiento a las siguientes instituciones y personas:

A la Planta Piloto de Ingeniería Química, su Director Dr. Guillermo Crapiste, sus Investigadores y Personal Administrativo, por su apoyo permanentemente a mis actividades en la investigación.

Al Departamento de Ingeniería Eléctrica (DIE) de esta Universidad, a su Director Dr. Osvaldo Agamennoni, al Consejo Departamental, y a su Personal Administrativo por su apoyo permanentemente a mis actividades académicas.

Al Consejo Nacional de Investigaciones Científicas y Técnicas (CONICET), por su apoyo económico.

Al Dr. José A. Romagnoli, director de las becas que el CONICET me ha otorgado.

A mis amigos y compañeros del Departamento 15 (consumidores voraces de tartas de frutilla) por las gratas horas compartidas durante el trabajo diario.

A mis amigos y compañeros del Laboratorio de Control y Robótica del DIE por el apoyo recibido cada vez que fue necesario.

A todas las personas que, directa o indirectamente, colaboraron y me alentaron

a concretar este trabajo.

A Mariela, mi compañera, amiga y esposa. Pero si una imágen vale más que mil palabras ¿qué utilizar entonces Petisa, que sea suficiente, para expresar un sentimiento?

Guillermo

Febrero de 1997

G. B. Sentoni

Departamento de Ingeniería Eléctrica
UNIVERSIDAD NACIONAL DEL SUR

Resumen

Se presenta en esta tesis la estructura de aproximación LNet, la cual está compuesta por un conjunto de sistemas discretos de Laguerre relacionados de forma no lineal mediante un Perceptrón de una capa oculta. Esta estructura es capaz de aproximar a sistemas susceptibles de ser caracterizados como no lineales discretos, causales, invariantes en el tiempo y que posean un cierto tipo de continuidad denominada memoria evanescente. Dicha forma de continuidad fundamenta la utilización de los denominados coeficientes de Lipschitz para la evaluación del número de sistemas de Laguerre. La cantidad de neuronas de la capa oculta se estima mediante una técnica de poda basada en la descomposición en valores singulares de una cierta transformación de los datos. El conjunto de la metodología de identificación desarrollada se ilustra a través de diversos ejemplos en los cuales se comparan los resultados de aproximación obtenidos con los de otros modelos. El primero de dichos ejemplos lo constituye un sistema no lineal discreto, al cual prosigue uno de cancelación de eco no lineal en una línea telefónica. Como último ejemplo se considera la aplicación de la metodología propuesta en el modelado de una columna de destilación binaria de alcoholes y su control mediante una estrategia de control predictivo. Culmina la tesis con una discusión de las futuras tendencias en el tema.

Abstract

This thesis introduces the LNet approximation structure, which is synthesized with a set of linear discrete Laguerre systems nonlinearly related by a single hidden layer Perceptron. This structure is able to approximate systems susceptible of been characterized as nonlinear, discrete, time invariant and with a certain kind of continuity called fading memory. This kind of continuity provides the basis for using the so called Lipschitz coefficients for the number of Laguerre's systems evaluation. The hidden layer neuron quantity is estimated by a pruning technique based in the singular value decomposition of a certain data transformation. The whole identification methodology is illustrated by examples in which the approximation results are compared with similar results of other models. The former of those examples is a nonlinear discrete system approximation followed by another one of nonlinear echo cancelling in a telephone line. As the last example, the proposed methodology is applied into modeling an alcohol binary distillation column and in its control by mean of a predictive control strategy. The thesis ends with a discussion of the future tendencies in this line of work.

Notaciones Generales.

A continuación estableceremos las notaciones generales. Una variable u representará a una secuencia o a un valor escalar de acuerdo al contexto. En el caso de una secuencia, su valor en un tiempo dado k se notará como $u(k)$. Los vectores se notarán en negrita minúscula $\mathbf{x}$ y las matrices en negrita mayúscula $\mathbf{A}$. Para las funciones se utilizarán minúsculas itálicas f si son escalares y minúsculas negritas $\mathbf{f}$ si son vectoriales. Para funcionales F y operadores N mayúsculas itálicas. Los espacios funcionales se notarán, por ejemplo, como $\mathcal{C}(\mathbf{U})$.

Varios

$\mathbf{x}(k)$: estados discretos del sistema en el instante de tiempo k.

$u(k)$: valor de la entrada en el instante de tiempo k.

$y(k)$: valor de la salida en el instante de tiempo k.

u : secuencia de entrada.

y : secuencia de salida.

$\mathbf{f}$: función de transición de estados.

$\widetilde{\mathbf{f}}$: aproximación de la función $\mathbf{f}$ de transición de estados.

h : función de salida.

$\widetilde{h}$: aproximación de la función h de salida.

$\mathfrak{z}$: variable compleja de la transformada $\mathcal{Z}$.

$\mathbf{A}, \mathbf{B}, \mathbf{c}$: descripción del sistema lineal SISO.

$\mathbf{Z}$: matriz de datos filtrados por los sistemas de Laguerre.

$\mathbf{X}_o$: matriz $\mathbf{Z}$ propagada a través de la capa oculta.

$\mathbf{U}_o, \mathbf{\Sigma}_o, \mathbf{V}_0$: $\mathbf{X}_o = \mathbf{U}_o^T \cdot \mathbf{\Sigma}_o \cdot \mathbf{V}_0$, descomposición en valores singulares de la matriz $\mathbf{X}_o$.

$c_{m_0 m_1 \cdots m_n}$: coeficientes de la serie de Wiener.

s : salida de un neurona antes de la no linealidad ϕ.

o : salida de un neurona después de la no linealidad ϕ.

ϕ : no linealidad de la neurona.

$\boldsymbol{\phi}$: no linealidad de la capa.

α : transformación afín de la neurona.

$\boldsymbol{\alpha}$: transformación afín de la capa.

g : función continua.

$k_m(\cdot, \cdot, \ldots, \cdot)$: núcleos de la serie de Volterra.

$a_{l_0 l_1 \cdots l_m}$: coeficientes de la serie de Volterra.

$l_p(t)$: sistemas continuos de Laguerre de orden p.

$l_n(k)$: sistemas discretos de Laguerre de orden n.

$ph_{m_n}(\cdot)$: polinomios de Hermite.

$vv_p(t)$: variable auxiliar que representa la convolución de la señal de entrada $u(t)$ con el sistema de Laguerre $l_p(t)$.

λ : coeficientes de Lipschitz.

$\mathbf{G}_i(\cdot)$: función transferencia matricial.

B_r : bola de radio r.

Γ_{B_r} : conjunto de funciones continuas en B_r con extensión de gradiente finito.

Constantes.

nc : número de capas ocultas de un Perceptrón.

no_i : número de neuronas de la capa oculta i-ésima.

lm : longitud de memoria.

m : número de polinomios de Laguerre en la estructura LNet.

n_u : número de términos de la entrada u utilizados en una ecuación recursiva.

n_y : número de términos de la salida y utilizados en una ecuación recursiva.

n_L : número de sistemas de Laguerre en la expansión de un sistema lineal.

np : número de pares de datos entrada-salida $[u(k), y(k)]$ disponibles.

c_λ : cota en los coeficientes de Lipschitz.

k_{lip} : constante de Lipschitz.

r_o : rango de la matriz $\mathbf{X}_o$.

r : longitud de memoria de la respuesta impulsiva $hcp_i\,(k)$.

Respuestas Impulsivas y Regresores

$hlin\,(k)$: respuesta impulsiva del sistema lineal.

$hgc_i\,(k)$: respuesta impulsiva del modelo general de bloques en cascadas para la sección i-ésima.

$hcp_i\,(k)$: respuesta impulsiva de modelo de cascadas en paralelo para la sección i-ésima.

$\mathbf{u}_L\,(k)$: es el vector de los sistemas de Laguerre.

$\mathbf{u}_{nu}\,(k)$: vector regresor de entradas del sistema hasta el orden $k - nu$.

$\mathbf{y}_{ny}\,(k)$: vector regresor de salidas del sistema hasta el orden $k - ny$.

$\widetilde{\mathbf{y}}_{ny}\,(k)$: vector regresor de salidas del modelo hasta el orden $k - ny$.

Operadores y Funcionales.

$P[u]\,(k)$: operador de truncamiento aplicado a la entrada u en el tiempo k.

$q^{-1}[\cdot]$: operador retardo de unitario.

$q^{\tau}[\cdot]$: operador retardo de τ muestras.

$R^{lm}[\cdot]$: operador línea de retardo de orden lm.

$N_i[\cdot]$: operador transformación de una capa.

$L_i[u]\,(k)$: i-ésimo operador de Laguerre aplicado a la entrada u para el tiempo k.

$G_i[u]$: Funcional asociada al i-ésimo operador de Laguerre aplicada a la entrada u.

$N[u]\,(k)$: operador no lineal discreto aplicado a u en el tiempo k.

$F[u]$: funcional asociada al operador causal e invariante al desplazamiento N aplicada a la entrada u.

Espacios.

$\mathbb{R}^n$: espacio Euclideo de dimensión n.

$\mathbb{Z}$: espacio de los números enteros.

l^∞ : espacio de las secuencias acotadas, provisto de la norma del supremo.

$\mathcal{C}\,(\mathbf{U})$: espacio de funciones continuas en el compacto $\mathbf{U}$.

$\mathcal{P}\,(\mathbf{U})$: espacio de expandido por polinomios en el compacto $\mathbf{U}$.

$\mathcal{N}\,(\mathbf{U})$: espacio expandido por perceptrones de una capa oculta en el compacto $\mathbf{U}$.

Contenidos

Lista de Figuras **2**

Lista de Tablas **4**

1 Introducción. **7**
1.1 Sistemas y Modelos. 7
1.2 Taxonomía de Modelos. 8
1.2.1 Modelado Riguroso o Identificación? 10
1.3 Aproximación de Sistemas Lineales. 11
1.3.1 Representación Interna de Sistemas Lineales. 13
1.3.2 Representación Externa de Sistemas Lineales. 16
1.4 Aproximación de SNL con Memoria Evanescente. 20
1.4.1 Representación Interna de Sistemas no Lineales. 24
1.4.2 Representación Externa de Sistemas no Lineales. 25
1.5 Objetivos de esta Tesis. 28
1.6 Desarrollo de la Tesis. 29

2 Aproximación de Sistemas. **31**
2.1 Introducción. 31
2.2 Redes Neuronales. 33
2.2.1 Redes Multicapas. 37
2.2.2 Redes Recurrentes. 39
2.2.3 Redes Generalizadas. 41
2.3 Diversos Modelos de Aproximación Entrada-Salida. 41
2.3.1 Esquemas Convencionales. 42
2.3.2 Esquemas No Convencionales. 49
2.4 Estructura LNet. 51
2.5 Conclusiones. 59

3 LNet: una Estructura para Aproximar Sistemas No Lineales Discretos. **61**
3.1 Introducción. 61
3.1.1 Notación, Definiciones y Comentarios Previos. 62
3.2 Memoria Evanescente. 68
3.3 Teorema de Aproximación de la Estructura LNet. 70
3.3.1 Teorema de Stone-Weierstrass. 72

3.3.2 Lema I. 72
3.3.3 Lema II. 72
3.3.4 Lema III. 74
3.3.5 Prueba del Teorema de la Estructura LNet. 75
3.4 Consideraciones sobre la Aproximación Obtenida. 76
3.5 Conclusiones. 77

4 Determinación de la Estructura LNET. 79
4.1 Introducción. 79
4.2 Evaluación del Número de Sistemas de Laguerre. 82
4.2.1 Coeficientes de Lipschitz. 85
4.3 Estimación de la Cantidad de Neuronas Mediante Valores Singulares. . . 93
4.4 Validación. 100
4.5 Sumario de la Metodología de Modelado. 102
4.6 Conclusiones. 103

5 Ejemplos de Aplicación. 105
5.1 Sistema no Lineal Discreto. 105
5.1.1 Descripción del Sistema y Condiciones de Identificación. 106
5.1.2 Resultados de Aproximación. 107
5.1.3 Discusión de los Resultados. 110
5.2 Cancelación de Eco en un Línea Telefónica. 111
5.2.1 Descripción del Sistema. 112
5.2.2 Resultados de Aproximación. 114
5.2.3 Discusión de los Resultados. 118
5.3 Columna Binaria de Alcoholes. 119
5.3.1 Descripción del Sistema. 119
5.3.2 Resultados de Aproximación. 121
5.3.3 Aspectos Generales de Control Predictivo. 126
5.3.4 Discusión de los Resultados. 130
5.4 Conclusiones. 131

6 Conclusiones y Recomendaciones. 133

A Propiedades de los Sistemas de Laguerre. 147

B Lema I. 151

C Modelo de la Columna de Destilación Binaria de Alcoholes. 153

Lista de Figuras

1.1 Representación Esquemática del Sistema. 12
1.2 Diferentes Tipos de Modelos. 14
1.3 Sistema con Memoria Evanescente. 23

2.1 Esquema de Clasificación de Redes Neuronales Artificiales. 34
2.2 Esquema de una Neurona Artificial. 35
2.3 Estructura de Red Multicapas. 38
2.4 Diagrama Pictórico de una Red Multicapas. 38
2.5 Representación de la Red de Hopfield. 40
2.6 Representación en Diagrama de Bloques de la Red de Hopfield. 41
2.7 Estructuras de Redes Generalizadas: Diversos Esquemas. 42
2.8 Esquema del Sistema y el Modelo que lo Aproxima. 43
2.9 Método de Wiener 45
2.10 Modelo General de Cascadas. 46
2.11 Método de Secciones en Cascada/Paralelo. 47
2.12 Estructura LNet 52
2.13 Sigmoide para Diversos Parámetros a) $b = cte$. b) $w1 = cte$. 57
2.14 Interpolación y Aproximación. 59

3.1 Secuencia Causal, su Extensión no Causal y uso del Operador de Truncamiento. 65
3.2 Secuencias Causal, Extendida y Respuestas Asociadas. 66
3.3 Reconstrucción del Operador N a Partir de su Funcional Asociada F. . . 67
3.4 Operador Detector de Pico. 69
3.5 Diversos Tipos de Saturación. 77

4.1 Curva típica de los coeficientes de Lipschitz. 88
4.2 Señal Equiprob para Tres Probabilidades pr Distintas. 90
4.3 Coeficientes de Lipschitz para Distribuciones: a) Uniforme, b) Normal y c) EP. 92
4.4 Matrices Involucradas en el Entrenamiento. 95
4.5 Dinámica Caótica de la Población de un Sistema Biológico. 98
4.6 Error de Aproximación para el Sistema Caótico para 1, 2, 5 y 14 Neuronas en la Capa Oculta. 99
4.7 Errores de Entrenamiento y Prueba en un Proceso Típico de Aprendizaje. 101

5.1 Sistema No Lineal Discreto. 106
5.2 Coeficientes de Lipschitz del para el Sistema No Lineal Discreto. 108
5.3 Coeficientes de la Expansión de Laguerre del Subsistema Lineal y Pesos de la Neurona de la Capa Oculta del Perceptrón. 109
5.4 Aproximación y Error de Aproximación del Sistema No Lineal Discreto. . 110
5.5 Validación del Modelo LNet para el Sistema no Lineal Discreto. 111
5.6 Cancelación de Eco en una Línea Telefónica 112
5.7 a) Función g_1(conversor D/A). b) Función g_2 (retorno del eco). 114
5.8 NFir con 4 Entradas y 7 Neuronas. 116
5.9 LNet con 4 Sistemas de Laguerre y 7 Neuronas. 117
5.10 NFir con 6 Entradas y 15 Neuronas. 117
5.11 LNet con 6 Sistemas de Laguerre y 15 Neuronas. 118
5.12 Esquema de la Columna de Destilación Binaria de Alcoholes. 120
5.13 Destilado en el Estado Estacionario para Diferentes Valores del Reflujo. . 121
5.14 Coeficientes de Lipschitz para la Columna. 123
5.15 Aproximación del Destilado por los Modelos SISO LNet y de Cascadas en Paralelo. 123
5.16 Validación del Modelo LNet para la Columna. 124
5.17 Extensión MISO Propuesta para la Estructura LNet. 125
5.18 Modelos Miso LNet y Lineal para la columna. 126
5.19 Cota al Horizonte de Control para la Columna. 128
5.20 Resultados de Control de la Columna. 130

Lista de Tablas

3.1 Esquema de Teoremas y Resultados Involucrados en la Demostración del Teorema LNet. 71

4.1 Valores de la Función con la Totalidad de los Datos Utilizados. 83
4.2 Error de Aproximación para 1,2,5 y 14 Neuronas. 99

5.1 Estructuras y Errores de Aproximación: configuración 1. 115
5.2 Estructuras y Errores de Aproximación: configuración 2. 116
5.3 Parámetros Utilizados en el Algoritmo de Control. 129

C.1 Parámetros de la Columna 156

Capítulo 1

Introducción.

Este capítulo presenta la problemática general de obtención de modelos a través de un proceso de identificación mediante datos de entrada-salida. En primer lugar se exponen consideraciones generales que explicitan que se entiende por sistema, entradas, salidas, modelos, etc., continuando con una clasificación posible de tipos de modelos. Se prosigue mostrando que el identificar las representaciones internas de modelos lineales genera modelos de memoria infinita, mientras que la identificación de su representación externa produce modelos de memoria finita. Estos conceptos se extienden a sistemas no lineales con memoria evanescente. Para los sistemas susceptibles de ser caracterizados como no lineales, con memoria evanescente, e invariantes al desplazamiento se muestra la conveniencia de identificar a su representación externa mediante la estructura de aproximación LNet propuesta. La estructura LNet es capaz de aproximar arbitrariamente bien en forma uniforme a dichos sistemas mediante una combinación no lineal de sistemas de Laguerre efectuada mediante un Perceptrón de una capa oculta. Concluye el capítulo con un comentario general sobre el desarrollo de los restantes capítulos de la tesis.

1.1 Sistemas y Modelos.

En términos generales un *sistema* es un objeto (o colección de objetos) sobre el cual interactuan diversas clases de variables y del cual se desea estudiar algunas propiedades. Serán denominadas *salidas* a las señales observables producidas por el sistema que son de interés; mientras que las variables que pueden ser manipuladas para afectar al sistema se denominarán *entradas*. Un *modelo* es una herramienta con la cual

se estudian y/o explican determinadas propiedades del sistema sin tener que realizar una experimentación sobre el mismo. El proceso de *experimentación,* es el procedimiento mediante el cual se ponen de manifiesto las relaciones causa-efecto del sistema. El conocimiento obtenido a través de la experimentación se utiliza luego para postular las hipótesis que pasarán a formar parte de los modelos. En general el grado de exactitud del modelo depende de su utilización futura. Sin embargo, ningún modelo es lo suficientemente exacto y/o general como para describir todos los aspectos del comportamiento del sistema bajo estudio. Cabe destacar que un modelo, una ley, una teoría o un paradigma pueden explicar parcialmente un fenómeno, y que tienen validez hasta que surge otro (modelo, ley, teoría o paradigma) que lo supera. Si bien es improbable que un modelo reproduzca en forma exacta el comportamiento de un sistema, lo que si es dado esperar es que pueda reproducir aceptablemente determinados comportamientos bajo ciertas condiciones. Y que además sea capaz de reproducir con resultados comparables lo experimentado en condiciones análogas. Esto habla de la reproductibilidad de la experimentación, paso fundamental de cualquier teoría científica. De esta forma cada modelo elegido es válido para las condiciones en que se realizó la experimentación, las cuales constituyen su *dominio de aplicación o validez*. La validación del modelo, ley, teoría o paradigma, usualmente se obtiene por contrastación con la realidad.

En general la ciencia trata de inferir modelos de las observaciones y estudiar sus propiedades. Dichos modelos pueden ser de un carácter mas o menos formal ya sean hipótesis, leyes de la naturaleza, paradigmas, etc. Sin embargo, todos comparten la característica de que intentan asociar lo observado con un patrón que lo explique. Dependiendo de las cualidades del sistema estudiado, de las necesidades de precisión y de las herramientas de modelación utilizadas, los modelos adoptarán características, muchas de las cuales son dicotómicas, de la siguiente clasificación de modelos.

1.2 Taxonomía de Modelos.

El valor de esta clasificación es orientativo y no pretende ser conclusiva dado que existen una gran diversidad de sistemas (caóticos, etc.) que o bien no pueden encuadrarse de acuerdo a ella o pueden ser clasificados de acuerdo a otros criterios.

Lineal/no-lineal.

Modelo lineal: expresa relaciones lineales entre sus variables. Es válido el principio de superposición de efectos. Ej. $dy(t)/dt = ay(t) + bu(t)$

Modelo no-lineal: expresa relaciones no lineales entre sus variables, no siendo válido el principio de superposición de efectos. Ej. $dy(t)/dt = a\sqrt{y(t)} + bu(t)$

Parámetros Concentrados/Parámetros Distribuidos:

Modelo de parámetros concentrados: el sistema es descripto por un conjunto de ecuaciones diferenciales a derivadas totales. Los parámetros de estas ecuaciones se expresan mediante un conjunto finito (concentrado) de valores. Ej. $dy/dt = ay(t) + bu(t)$

Modelo de parámetros distribuídos: el sistema es descripto por un conjunto de ecuaciones diferenciales a derivadas parciales. Los parámetros de estas ecuaciones se expresan mediante un conjunto infinito (distribuido) de valores, como distribuciones, perfiles de concentración, dilución etc. Ej. $\alpha(t)\,\partial^2 y(t,x)/dx^2 = \partial y(t,x)/\partial t$

Determinístico/Estocástico.

Modelo determinístico: el sistema es descripto por un conjunto de ecuaciones en las cuales los eventos que ocurren pueden ser caracterizados en forma individual. Ej. Ley termodinámica de los gases ideales.

Modelo Estocástico: el sistema es descripto por un conjunto de ecuaciones en las cuales las variables solo pueden ser caracterizadas por sus características estadísticas, como ser distribución de probabilidad, esperanza, varianzas etc. Ej. movimiento Browniano en un gas.

Tiempo Continuo/Discreto.

Modelo de tiempo continuo: describen sistemas donde las variables dependen continuamente del tiempo. Están descriptos por conjuntos de ecuaciones diferenciales. Ej. $dy(t)/dt = ay(t) + bu(t),\ t \in [0, \infty)$

Modelo de tiempo discreto: las variables de estos modelos solo están definidas para instantes de tiempo discretos. Estos modelos están descriptos por ecuaciones a diferencias. Ej. $y(k+1) = ay(k) + bu(k),\ k \in [0, 1, 2, 3, \ldots, \infty)$

Invariantes/Variantes en el Tiempo.

Modelo invariante en el tiempo: describen sistemas donde las relación de las variables con los parámetros es constante. En consecuencia para estos modelos la respuesta a una cierta entrada no depende en absoluto del tiempo en que ésta se aplica. Ej. $dy(t)/dt = ay(t) + bu(t)$

Modelo variante en el tiempo: describen sistemas donde las relación de las variables con los parámetros depende del tiempo. Ej. $dy(t)/dt = a(t)\,y(t) + bu(t)\,,\ a(t) = a_0 \sin(5t)$

Externos/Internos.

Modelo externo o entrada-salida: describen al sistema estableciendo una relación directa entre las entradas y las salidas del mismo, sin considerar ninguna otra relación. Ej. la respuesta impulsiva en un sistema lineal.

Modelo interno o entrada-estados-salida: describen al sistema estableciendo las relaciones entre las variables de entrada y las internas o estados, y entre estos estados y las salidas. De esta forma describen tanto el comportamiento externo como el interno del sistema. La descripción del sistema en variables de estado es la típica caracterización de esta clase.

Causales.

Modelo causal: se denomina así a los modelos que responden a una relación de causa-efecto. En otras palabras, las salidas de ese modelo dependen solamente de la evolución previa del modelo y no de eventos futuros.

Una vez definido que tipo de modelo se requiere para la aplicación particular, existen básicamente dos caminos muy diferentes de obtenerlos: la modelación teórica y la identificación de sistemas.

1.2.1 Modelado Riguroso o Identificación?

En general un sistema está constituido por elementos, cada uno de los cuales involucra una transformación y/o un transporte de masa, energía y/o información. Un modelo matemático refleja una parte de estos procesos, solo cuando han sido abstraídas del sistema las propiedades de interés. El modelado teórico riguroso provee de técnicas para el planteo de ecuaciones que expresan el comportamiento dinámico del sistema a partir de las leyes físicas y fenomenológicas de sus componentes. En el caso de aplicaciones ingenieriles las leyes mas utilizadas, por citar algunas, son: balances de masa y energía, leyes de Newton, ley de fricción de Coulomb, ley de los fluídos ideales de Bernoulli, etc. Estas leyes modelan el comportamiento de determinadas subpartes constitutivas del sistema en estudio, las cuales combinadas forman al modelo total, procediendo de lo particular a lo general. Como vimos anteriormente, un modelo matemático puede ser una simple ecuación diferencial lineal con parámetros concentrados. O podría ser un complejo sistema de ecuaciones diferenciales no lineales en derivadas parciales, con parámetros

dependiendo en forma temporal y espacial. Esta complejidad impone a menudo varios obstáculos para obtener los modelos procediendo de la manera anterior:

- Las suposiciones para obtener al modelo pueden ser muy restrictivas o poco realistas, de forma tal que resulta imposible captar lo esencial del sistema.
- Algunos parámetros suelen ser muy difíciles de medir o peor aun completamente desconocidos.
- Modelos muy complejos obligan a resolver un gran conjunto de ecuaciones diferenciales, que usualmente constituyen el cuello de botella en el momento de la integración.

El otro camino para obtener un modelo matemático de un sistema dinámico, consiste en construirlo directamente a partir de los datos obtenidos mediante un proceso de experimentación. El proceso de generar un modelo de los datos obtenidos del sistema se denomina *identificación*. Las características de los modelos obtenidos mediante técnicas de identificación varían de acuerdo al tipo de enfoque utilizado, siendo útil esclarecer algunos conceptos. Estos serán ejemplificados para el caso lineal, haciendo luego las respectivas extensiones para el caso no lineal.

1.3 Aproximación de Sistemas Lineales.

Sea un sistema que admite ser modelado como lineal discreto e invariante en el tiempo, con una entrada escalar u y una salida escalar y que en el instante de tiempo discreto k toman los valores $u(k)$ e $y(k)$ respectivamente como el de la Figura 1.1. Y sea una descripción en variables de estado:

$$\begin{aligned} \mathbf{x}(k+1) &= \mathbf{A}\mathbf{x}(k) + \mathbf{b}u(k) \\ y(k) &= \mathbf{c}\mathbf{x}(k) \end{aligned}, \tag{1.1}$$

donde $k \in (-\infty, \ldots, -1, 0, 1, \ldots, \infty)$, $\mathbf{x}(k) = [x_1(k), x_2(k), \cdots, x_n(k)]$, representa a los n estados, $\mathbf{x}_0$ estado inicial, con $\mathbf{A}, \mathbf{b}$, y $\mathbf{c}$ de dimensiones $(n \times n), (n \times 1)$, y $(1 \times n)$ respectivamente. Por claridad en la exposición se tratará con un sistema de una entrada y una salida. Con las debidas consideraciones, resultados análogos pueden ser generalizados a sistemas con múltiples entradas y múltiples salida.



Figura 1.1: Representación Esquemática del Sistema.

Una caracterización alternativa de 1.1 se obtiene mediante la *respuesta impulsiva* $hlin\left(k\right)$ (o función de peso):

$$y\left(k\right) = \sum_{\tau=0}^{\infty} hlin\left(\tau\right) u\left(k-\tau\right). \tag{1.2}$$

Conocer $\left\{hlin\left(\tau\right)\right\}_{\tau=0}^{\infty}$ y $u\left(l\right)$ para todo $l \leq k$ permite conocer la salida $y\left(l\right), l \leq k$ para cualquier entrada. *Consecuentemente la respuesta impulsiva provee una caracterización completa del sistema*. Dado que esta respuesta impulsiva es infinita, es útil considerar formas más compactas como las recursivas que eviten tener que utilizar los infinitos términos de $hlin\left(k\right)$. Consiguientemente la ecuación 1.2 puede ser expresada como

$$y\left(k\right) = \sum_{i=1}^{n_y} a_i y\left(k-i\right) + \sum_{j=0}^{n_u} b_j u\left(k-j\right), \tag{1.3}$$

donde los parámetros a_i y b_j tienen órdenes n_y y n_u respectivamente, $n_y > n_u$. Mediante la utilización de la transformada $\mathcal{Z}$ en la expresión 1.3 se obtiene la siguiente función racional:

$$y\left(\mathfrak{z}\right) = \frac{b_0 + b_1\mathfrak{z}^{-1} + \ldots + b_{n_u}\mathfrak{z}^{-n_u}}{1 + a_1\mathfrak{z}^{-1} + a_2\mathfrak{z}^{-2} \ldots + a_{n_y}\mathfrak{z}^{-n_y}} u\left(\mathfrak{z}\right), \tag{1.4}$$

donde $y\left(\mathfrak{z}\right) = \mathcal{Z}\left[y\left(k\right)\right], u\left(\mathfrak{z}\right) = \mathcal{Z}\left[u\left(k\right)\right]$. Este cociente de polinomios es un operador lineal en la variables compleja $\mathfrak{z}$ que relaciona a la transformada de la entrada con la transformada de la salida. Se denominan *ceros* a los ceros del polinomio numerador de 1.4 y *polos* a los ceros del polinomio denominador de 1.4 en la forma usual. Si suponemos coprimos[1] a los polinomios numerador y denominador de la ecuación 1.4 se obtiene la siguiente relación:

$$\begin{aligned} \mathbf{x}\left(k+1\right) &= \mathbf{A}\mathbf{x}\left(k\right) + \mathbf{b}u\left(k\right) \\ y\left(k\right) &= \mathbf{c}\mathbf{x}\left(k\right) \end{aligned}, \tag{1.5}$$

donde $\mathbf{x}\left(k\right) = \left[x_1\left(k\right), x_2\left(k\right), \cdots, x_{n_y}\left(k\right)\right]$, $k \in \left(-\infty, \ldots, -1, 0, 1, \ldots, \infty\right)$ representa a

[1] coprimos: son polinomios coprimos aquellos que no contienen factores en comun.

los n_y estados; donde $\mathbf{A}:(n_y \times n_y)$, $\mathbf{b}:(n_y \times 1)$, y $\mathbf{c}:(1 \times n_y)$. Los valores de las matrices correspondientes son:

$$\mathbf{A} = \begin{bmatrix} -a_1 & -a_2 & \cdots & -a_{n_{y-1}} & -a_{n_y} \\ 1 & 0 & \cdots & 0 & 0 \\ 0 & 1 & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & 0 \end{bmatrix}, \mathbf{b} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix},$$

$$\mathbf{c} = \left[0^{(1\times(n_y-n_u))}, b_1, b_2, \ldots, b_{n_u}\right]$$

donde $0^{(1\times(n_y-n_u))}$ es un vector fila de ceros de longitud $(n_y - n_u)$.

Han sido presentadas cuatro diferentes caracterizaciones posibles para un modelo lineal discreto e invariante al desplazamiento. Por un lado se encuentra la representación mediante una suma convolución de infinitos términos 1.2 que no exige ningún conocimiento previo, constituyendo una caracterización externa del sistema. Por otro, están las caracterizaciones en ecuaciones recursivas 1.3, las descripciones mediante un operador lineal en la variable compleja $\mathfrak{z}$ 1.4 y las descripciones en variables de estado 1.5. Para estas descripciones se necesita cierto conocimiento interno del sistema, el cual se manifiesta en el orden de las recursiones, el número de polos y ceros y/o el orden del sistema en variables de estado. Conocida la equivalencia entre las representaciones 1.3, 1.4 y 1.5 clasificaremos a estas representaciones del sistema lineal como internas. Cada modelo al ser identificado, dependerá del tipo de descripción y de las cualidades de los algoritmos de identificación. En este sentido diremos un modelo tiene *memoria finita* si su salida actual $\widetilde{y}(k)$ depende de un conjunto finito de valores; contrariamente diremos que tiene memoria infinita. A continuación se mostrará que al aproximar la representación interna de un sistema lineal se obtiene un modelo de memoria infinita, mientras que al aproximar la representación externa se obtiene un modelo de memoria finita.

1.3.1 Representación Interna de Sistemas Lineales.

A continuación veremos que el aproximar al sistema descripto por una ecuación recursiva como 1.3 conduce a un modelo IIR (Infinite Impulse Response, Figuras 1.2a y 1.2b). La familia de modelos denominados ARMAX, AR, ARAMAX etc. como pueden ser

encontrados en la bibliografía [39, Ljung] deriva de este tipo de aproximaciones.Definiremos

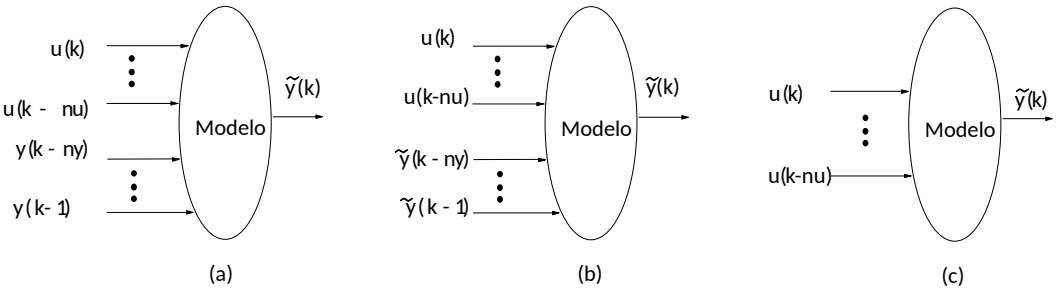


Figura 1.2: Diferentes Tipos de Modelos.

dos operadores de suma utilidad en los futuros desarrollos: $q^{\tau}[\cdot]$ es el operador retardo de τ muestras definido por

$$\begin{aligned} q^{\tau}[u](k) &= u(k+\tau) \\ q^{-\tau}[u](k) &= u(k-\tau) \end{aligned} \tag{1.6}$$

y $R^{lm}[\cdot]$ es el operador línea de retardo de órden lm definido por

$$R^{lm}[u](k) = [u(k), u(k-1), \ldots, u(k-lm+1)]^T. \tag{1.7}$$

Se notará $q^{\tau}u(k)$ y $R^{lm}u(k)$ en lugar de $q^{\tau}[u](k)$ y $R^{lm}[u](k)$ respectivamente, siempre que sea claro y distinguible en el contexto. El operador retardo unitario será notado como q^{-1}. En base a estos operadores definiremos a los vectores regresores de entrada

$$\mathbf{u}_{nu}(k) = R^{nu}[u](k) = [u(k), ..., u(k-nu)]^T \tag{1.8}$$

y de salida,

$$\mathbf{y}_{ny}(k) = R^{ny}[y](k) = [y(k-1), ..., y(k-n_y)]^T \tag{1.9}$$

lo que permite expresar a la ecuación 1.3 en una forma más compacta

$$y(k) = \overline{\mathbf{a}}^T \mathbf{y}_{ny}(k) + \overline{\mathbf{b}}^T \mathbf{u}_{nu}(k) \tag{1.10}$$

con los vectores de parámetros $\overline{\mathbf{a}} = \left[a_1, \ldots, a_{n_y}\right]^T$ y $\overline{\mathbf{b}} = [b_0, \ldots, b_{n_u}]^T$.

Idealmente sería deseable generar el valor estimado $\widetilde{y}(k)$ de $y(k)$ como en el

esquema de la Figura1.2b:

$$\widetilde{y}(k) = \widetilde{\mathbf{b}}^T \widetilde{\mathbf{y}}_{ny}(k) + \widetilde{\mathbf{a}}^T \mathbf{u}_{nu}(k),$$

utilizando el vector de regresores de la salida del modelo

$$\widetilde{\mathbf{y}}_{ny}(k) = \left[\widetilde{y}(k-1), ..., \widetilde{y}(k-n_y)^T\right], \tag{1.11}$$

con $\widetilde{\mathbf{a}}$, $\widetilde{\mathbf{b}}$ los valores estimados de $\overline{\mathbf{a}}$ y $\overline{\mathbf{b}}$ respectivamente. Para ajustar los parámetros del modelo se procede como es usual minimizando alguna función de costo del error $e = y(k) - \widetilde{y}(k)$. En el esquema de la Figura 1.2b se utilizan las salidas $\widetilde{\mathbf{y}}_{ny}(k)$ para generar al próxima valor $\widetilde{y}(k)$. Procediendo de esta forma, se introduce una realimentación dado que el modelo es ajustado en base a $\mathbf{u}_{nu}(k)$ e $\widetilde{\mathbf{y}}_{ny}(k)$ para estimar $\widetilde{y}(k)$. Desafortunadamente la resolución del problema de estimación planteado en esta forma es altamente no lineal y con graves problemas de estabilidad [68].

Una posible solución consiste en utilizar la estructura de la Figura 1.2a, lo que equivale a linearizar el problema de estimación de parámetros mediante la utilización de las salidas reales $[y(k-1), ..., y(k-n_y)]$:

$$\begin{aligned} e(k) &= y(k) - \widetilde{y}(k) \\ &= y(k) - \widetilde{\mathbf{b}}^T \widetilde{\mathbf{y}}_{ny}(k) - \widetilde{\mathbf{a}}^T \mathbf{u}_{nu}(k) \\ &= \left(\overline{\mathbf{b}} - \widetilde{\mathbf{b}}\right)^T \mathbf{y}_{ny}(k) + \left(\overline{\mathbf{a}} - \widetilde{\mathbf{a}}\right)^T \mathbf{u}(k) \end{aligned} \quad . \tag{1.12}$$

Como resultado el problema de estimación puede ser resuelto utilizando mínimos cuadrados en una forma simple. Tanto los modelos de las Figura 1.2 a y b utilizan valores retrasados de las salidas ($\mathbf{y}_{ny}(k)$ o $\widetilde{\mathbf{y}}_{ny}(k)$ respectivamente). Lo cual genera una dependencia continua del valor $\widetilde{y}(k)$ de la salida con el estado inicial, razón por la cual son denominados modelos de memoria infinita. Veremos a continuación que al aproximar la representación externa de un sistema lineal se obtienen un modelo de memoria finita.

1.3.2 Representación Externa de Sistemas Lineales.

FIR.

Otra opción para caracterizar al sistema 1.5 consiste en tomar un número finito n_u de términos de su respuesta impulsiva. Esto equivale a truncar la sumatoria 1.2 estimando solo los primeros n_u términos de $\{hlin(\tau)\}_{\tau=0}^{n_u-1}$, lo cual conduce a obtener un modelo de memoria finita denominado FIR (Finite Impulse Response, Figura 1.2c). De hecho un modelo FIR también se obtiene al eliminar la recursión en 1.10 haciendo $\overline{\mathbf{a}}^T = 0$

$$y(k) = \overline{\mathbf{b}}^T \mathbf{u}_{nu}(k), \tag{1.13}$$

con $\mathbf{u}_{nu}$ como en 1.8 para n_u el orden del filtro. Es fácil ver que la aproximación externa de este sistema tiene una representación en series de infinitos términos que al ser truncada genera un modelo de memoria finita. Resulta evidente que para mejorar la aproximación del modelo FIR es necesario aumentar el orden n_u, hecho que implica incrementar la cantidad de parámetros que deben ser identificados. En este sentido el orden de un filtro FIR para una misma realización es de aproximadamente un orden superior al que tendría uno IIR. Sin embargo este tipo de modelos es de muy fácil identificación, se obtienen estimaciones que son mínimos globales, los algoritmos son estables y son muy fáciles de utilizar en simulación.

Alternativamente es posible considerar a los modelos tipo FIR desde el punto de vista de aproximaciones funcionales como:

$$y(k) = \sum_{i=0}^{n_u} b_i q^i [u](k). \tag{1.14}$$

Se puede apreciar que el sistema es expandido en una base ortonormal formada por retardos unitarios. El operador retardo unitario q^{-1} tiene una memoria de un solo valor, lo que explicaría la gran cantidad de términos que hay que tomar para aproximar determinados sistemas. Además su utilización no es adecuada cuando se utiliza para períodos cortos de muestreo [46]. Una opción es usar otro operador, como pueden ser los sistemas de Laguerre, que al tener mayor cantidad de memoria reduzca la cantidad de términos involucrados en la aproximación.

Laguerre.

Es bien conocido en la literatura el caso de aproximaciones de sistemas 1.5 en base a sistemas de Laguerre [75], [76]. El conjunto de sistemas puede ser expresado en el campo complejo como:

$$L_i(\mathfrak{z}) = \mathfrak{z}^{-nd}\sqrt{(1-a^2)\,T}\frac{\mathfrak{z}}{\mathfrak{z}-a}\left[\frac{1-a\mathfrak{z}}{\mathfrak{z}-a}\right]^i,\ i:0,\ldots,\infty, \tag{1.15}$$

y donde:

$L_i(\mathfrak{z})$: es la transformada $\mathcal{Z}$ de $l_i(k)$, el sistema de orden i.

a : el polo generador tal que $|a|<1$ lo que asegura la estabilidad.

T : tiempo de muestreo. Cuando el sistema es discreto $T=1$.

nd : expresa un retardo puro del sistema de nd muestras.

Este conjunto de sistemas representa a una generalización de los presentados en [9], [75] y [76] dado que incluyen un retardo de nd muestras. En [75] se trata con sistemas estrictamente propios, de forma que los sistemas definidos por 1.15 coinciden con los allí presentados cuando $nd=1$. Es conocido el hecho de que sistemas lineales con retardos puros pueden ser modelados por sistemas de Laguerre [40] y [55]. Sin embargo cuando el sistema es discreto, es más útil separar al retardo como un número de muestras exactas, y aproximar al resto del sistema mediante las expansiones mencionadas. La inclusión del término que modela al retardo puro tiene una explicación relativamente sencilla. Supongamos que se desea aproximar un sistema discreto lineal que es un retardo puro de una muestra, es decir su respuesta impulsiva es $hlin(k)=\{0,1\}$. Este simple sistema que resulta tan sencillo de aproximar utilizando un operador retardo unitario q^{-1}, demanda una cantidad desmesurada de operadores de Laguerre. Dicho retardo resulta fácilmente detectable mediante un análisis de correlación y es mucho mas sencillo modelarlo en forma separada, que mediante toda la expansión funcional de los sistemas de Laguerre. El siguiente ejemplo aclarará este tópico.

Ejemplo 1. *Supongamos que se desea aproximar a una función continua* $g(x):\mathbb{R}\to\mathbb{R}$ *en un segmento de la recta que se elige como* $[-\pi,\pi]$ *por medio de dos aproximadores*

distintos. Uno de ellos el polinomio

$$p(x) = \sum_{i=0}^{m} cp_i x^i, \tag{1.16}$$

con $cp_i \in \mathbb{R}$ *y el otro la serie de Fourier*

$$sf(x) = \sum_{i=0}^{m} af_i \sin(2\pi i x) + \sum_{i=0}^{m} bf_i \cos(2\pi i x), \tag{1.17}$$

con $af_i, bf_i \in \mathbb{R}$. *De forma tal, la función* $g(x)$ *puede ser expresada como*

$$g(x) \cong p(x),$$

donde $\cong$ *significa aproximadamente igual, para* $x \in [-\pi, \pi]$, *lo que es equivalente a decir que el conjunto* $\{1, x^2, x^3, ...\}$ *forma una base en* $[-\pi, \pi]$. *En forma similar es posible establecer que*

$$g(x) \cong sf(x),$$

para $x \in [-\pi, \pi]$. *Es bien conocido el hecho de que el conjunto de funciones* $\{\sin(2\pi i x), \cos(2\pi i x)\}$, $i : 0, ..., \infty$, *tambien forma una base en* $[-\pi, \pi]$. *Es decir que tanto el polinomio de la ecuación 1.16 como la serie de Fourier de la ecuación 1.17 tienen similares capacidades de aproximación para funciones coninuas en* $[-\pi, \pi]$. *Ahora bien, si se elige* $g(x) = \sin(2\pi x)$ *la cantidad de términos requeridos por un polinomio es elevada comparada con el único término* $\sin(2\pi x)$ *necesario en una serie de Fourier. Similares resultados se obtienen si por ejemplo se desea aproximar a* $g(x) = x^2$ *mediante una serie de Fourier, comparado con el único elemento* x^2 *necesario por un polinomio. Concretamente, cada vez que se debe aproximar una función que pertenece a una base por elementos de otra base de características distintas, la cantidad de términos necesarios es generalmente grande. Tanto el conjunto* $\{q^i\}_{i=0}^{\infty}$ *como* $\{L_i(\cdot)\}_{i=0}^{\infty}$ *conforman bases ortonormales para* $l^2(\mathbb{Z}_+)$ *lo cual explica, siguiendo el razonamiento anterior, las dificultades para expresar elementos de una base en la otra.* ■

Mediante un ligero abuso de notación, la ecuación 1.15 puede ser expresada en base al operador retardo unitario q^{-1} en un forma muy utilizada:

$$L_i\left(q^{-1}\right) = q^{-nd}\frac{\sqrt{\left(1-a^2\right)T}}{1-aq^{-1}}\left[\frac{q^{-1}-a}{1-aq^{-1}}\right]^i, \quad i = 0, \ldots, \infty. \tag{1.18}$$

Se puede apreciar que estos sistemas se generan con un pasabajos básico

$$L_0\left(q^{-1}\right) = \frac{\sqrt{\left(1-a^2\right)T}}{1-aq^{-1}},$$

al que se le van agregando secciones pasabada en cascada de la forma $\left(\frac{q^{-1}-a}{1-aq^{-1}}\right)$. De esta forma se puede expresar a cada nuevo sistema en base al anterior en una simple forma recursiva

$$L_i\left(q^{-1}\right) = L_{i-1}\left(q^{-1}\right)\left(\frac{q^{-1}-a}{1-aq^{-1}}\right).$$

Utilizando dichos sistemas como base, un sistema lineal estrictamente propio puede ser representado (ver por ejemplo [75]) por medio de la ecuación 1.18 con $nd = 1$, como:

$$y\left(k\right) = \sum_{i=0}^{n_L} bl_i L_i\left[u\right]\left(k\right). \tag{1.19}$$

Con una correcta selección de a, se pueden lograr aproximaciones de hasta un orden menor que las que se obtendrían con un FIR, siendo comparables a las aproximaciones logradas con un IIR ($n_u >> n_L \simeq n_y$). Wahlberg [75] sugiere que este hecho se debe a que el operador de los sistemas utilizados tienen más memoria que el operador retardo unitario utilizado en un FIR. Las ventajas a considerar son apreciables desde el punto de vista de la aproximación y de la estabilidad. Utilizados en un esquema de identificación adaptativo, es fácil asegurar la estabilidad de dicho esquema, dado que solo hay que controlar que $|a| < 1$. Además es posible utilizar a estos modelos en simulación para horizontes de tiempo arbitrariamente largos.

Se ha visto por un lado, que al aproximar la representación interna de un sistema lineal discreto se obtienen modelos de memoria infinita denominados IIR. Estos modelos son muy económicos respecto de la cantidad de términos que utilizan para representar a un sistema dado. Por otro, al aproximar la representación externa de un sistema lineal discreto se obtiene un modelo de memoria finita denominado FIR. Otra opción consiste en utilizar sistemas de Laguerre para realizar la aproximación. Al igual que en un FIR, es posible tanto simular al sistema en horizontes de tiempo arbitrariamente largos, co-

mo también mejorar la aproximación obtenida simplemente aumentando el orden del modelo. Seleccionando de una forma cuidadosa el valor del polo, se consiguen aproximaciones cuya cantidad de términos es comparable a la de un IIR. En la siguiente sección serán expresados conceptos análogos desarrollados para sistemas no lineales con memoria evanescente.

1.4 Aproximación de SNL con Memoria Evanescente.

Dada la inherente complejidad de los sistemas no lineales, es usual que haya que restringir el campo de estudio a una subclase de los mismos. En este caso trataremos la subclase de los sistemas no lineales discretos que poseen memoria evanescente. Comenzaremos por considerar la representación *Interna* de sistemas no lineales discretos conocida como representación *Entradas-Estados-Salidas*:

$$\begin{aligned} \mathbf{x}(k+1) &= \mathbf{f}[\mathbf{x}(k), u(k)] \\ y(k) &= h[\mathbf{x}(k)] \end{aligned}, \tag{1.20}$$

$k \in (-\infty, \ldots, -1, 0, 1, \ldots, \infty)$ donde $u(k)$, $\mathbf{x}(k)$ e $y(k)$ representan elementos de las secuencias de entrada, estados y la salida en el instante de tiempo k, $\mathbf{x}_0$ es el estado inicial. Sea l^∞, espacio de secuencias acotadas provisto de la norma del supremo

$$\|u\|_\infty = \sup_k |u(k)| .$$

Un elemento de este espacio consiste en una secuencia de valores u que en el instante de tiempo k toma el valor $u(k)$. Sin embargo aproximar a un sistema no lineal en un conjunto tan general es una tarea ardua. Una visión más realista consiste en seleccionar un subespacio $\mathbf{K}$ tal que

$$\mathbf{K} \triangleq \{u \in l^\infty | \, \|u\|_\infty < m_1, \; m_1 > 0\} . \tag{1.21}$$

Simplemente se pide que la entrada esté acotada dentro de una región. Como anteriormente mencionamos este subespacio compone el dominio de aplicación o validez del modelo. Conjuntamente cada elemento de una secuencia pertenece a un espacio vectorial de dimensión finita. Así $u(k) \in \mathbf{U}$, espacio de entrada; $\mathbf{x}(k) \in \mathbf{X}$, espacio de estados

e $y(k) \in \mathbf{Y}$, espacio de salidas. Las funciones $\mathbf{f}$ y h son transformaciones no lineales estáticos definidos como $\mathbf{f} : \mathbf{X} \times \mathbf{U} \to \mathbf{X}$ y $h : \mathbf{X} \to \mathbf{Y}$. Para un sistema de una entrada y una salida, $\mathbf{U} \subset \mathbb{R}$, $\mathbf{X} \subset \mathbb{R}^n$, $\mathbf{Y} \subset \mathbb{R}$ con el vector de estados $\mathbf{x}(k) = [x_1(k), x_2(k), \cdots, x_n(k)]$. Luego un sistema Σ queda caracterizado por por el conjunto

$$\Sigma = (\mathbf{U}, \mathbf{X}, \mathbf{Y}, \mathbf{f}, h, x_0). \tag{1.22}$$

Las funciones $\mathbf{f}$ y h en 1.20 describen al sistema desde un punto de vista de sus variables de estado o de su representación interna. Para expresar al sistema de esta manera se requiere de una gran cantidad de conocimiento físico del sistema, esto es conocer sus estados. Consideremos a continuación al equivalente no lineal de la ecuación 1.3:

$$y(k) = g([y(k-1), ..., y(k-n_y)], [u(k-1), ..., u(k-n_u)]), \tag{1.23}$$

o por 1.9 y 1.8 como

$$y(k) = g(\mathbf{y}_{ny}(k), \mathbf{u}_{nu}(k)), \tag{1.24}$$

donde $g(\cdot)$ es una cierta función no lineal sin memoria. Este tipo de modelo denominado NARMAX [50] por su similitud con el caso el ARMAX lineal, será considerado como una representación interna de 1.20.

Para caracterizar la representación externa del sistema 1.22 consideraremos al operador $N : l^\infty \to l^\infty$ entrada-salida asociado a dicho sistema:

$$y(k) = N[u](k). \tag{1.25}$$

Dicho operador puede no existir para toda la generalidad de los sistemas no lineales discretos, a diferencia de lo que ocurre en los sistemas lineales para los cuales está definida la transformada $\mathcal{Z}$. Sin embargo para sistemas con memoria evanescente este operador puede ser aproximado. Pasaremos a definir qué se entiende por la aproximación de este operador y por memoria evanescente.

Dado un sistema y su modelo, intuitivamente cabe esperar que las salidas de uno y otro permanezcan cercanas. Diremos que un modelo aproxima uniformemente a un sistema en un subconjunto $\mathbf{K}$ (ver ecuación 1.21) de la entrada con un $\varepsilon > 0$, si para toda la longitud de la secuencia de entrada u en $\mathbf{K}$ la salida permanece cercana a menos

de ε. La representación de la ecuación 1.20 es general y describe a una gran diversidad de sistemas no lineales discretos, de los cuales no todos pueden ser aproximados en forma uniforme. Como ejemplo específico, considérese un sistema no lineal autónomo con múltiples regiones de equilibrio. Un modelo inexacto puede converger a regiones del espacio de estados que no coincidan con las del sistema. Si las condiciones iniciales se encuentran cercanas al borde de dos regiones diferentes, es posible que el modelo converja a una región distinta de la del sistema original. Una clase de sistemas que puede ser aproximada bajo los anteriores criterios es la denominada de memoria evanescente. Los sistemas lineales estables son buenos ejemplos de sistemas con memoria evanescente Ante una secuencia constante de entrada, la salida converge asintóticamente al valor correspondiente de estado estacionario independientemente de las condiciones iniciales. Otros ejemplos los constituyen las cascadas de sistemas lineales dinámicos con sistemas no lineales sin memoria[2] como los modelos de Wiener y Hammerstein. El concepto de memoria evanescente, está relacionado estrictamente a propiedades de entrada-salida. Este hecho define una forma de continuidad en el operador de entrada-salida relacionado al sistema. Por lo tanto pasaremos a definir el concepto de memoria evanescente desde el punto de vista de continuidad de funciones. Una función se dice continua si elementos cercanos en el dominio tienen imágenes cercanas. En forma similar un sistema se dice continuo en un subconjunto $\mathbf{K}$ del espacio de secuencias de entrada, si secuencias de entrada que en algún sentido están próximas, producen secuencias de salida que están próximas. El sentido de proximidad será determinado por una norma. En este sentido se dice que, Σ es un *sistema causal continuo* en $\mathbf{K}$, si dado $\varepsilon > 0$ y para cada $u, v \in \mathbf{K}$, existe $\delta(\varepsilon, u) > 0$ tal que

$$\|u - v\|_* < \delta \Longrightarrow |N[u](0) - N[v](0)| < \varepsilon,$$

donde $N[u](k)$ por 1.25. $\|\cdot\|_*$ representa a una norma arbitraria en el espacio de entrada.

La influencia del pasado de la entrada sobre la salida en un sistema continuo es independiente del tiempo transcurrido. Es decir lo que aconteció en un pasado remoto, tiene igual influencia en la salida que lo ocurrido recientemente. Por el contrario, para un sistema *causal* con memoria evanescente la influencia de la entrada sobre la salida va

[2]En un sistema no lineal sin memoria la salida en cada instante de tiempo es solo función de la entrada en ese mismo tiempo. Ej.:$y(k) = g(u(k))$

disminuyendo a medida que se avanza en el pasado de las entradas. Por lo tanto, una forma más conveniente de definir la norma $\|\cdot\|_*$ del espacio de entrada es considerar una norma pesada $\|\cdot\|_w$ por la secuencia w. Esta secuencia $w : [0, 1, 2, ...,) \to (0, 1]$, que es no creciente, no negativa y con $\lim_{k\to\infty} w(k) = 0$, marca la influencia recién mencionada:

$$\|u\|_w = \sup_{k\leq 0} |u(k)|\, w(-k).$$

En este sentido, un sistema *causal* con memoria evanescente es un sistema que tiende a 'olvidar' sus entradas en una forma bien definida en el tiempo. En otras palabras en un sistema con memoria evanescente, secuencias de entrada que están cercanas en su *pasado reciente* (medidas por la norma $\|u\|_w$) producen secuencias de salida semejantes (Figura 1.3). Un sistema causal $\Sigma = (\mathbf{U}, \mathbf{X}, \mathbf{Y}, \mathbf{f}, h, x_0)$ tiene *memoria evanescente* ($\mathcal{ME}$) en un subconjunto $\mathbf{K}$ 1.21 ([6], [42]), si dado $\varepsilon > 0$ y para cada $u, v \in \mathbf{K}$, existe $\delta(\varepsilon, u) > 0$ tal que

$$\|u - v\|_w < \delta \Longrightarrow |N[u](0) - N[v](0)| < \varepsilon. \tag{1.26}$$

La caracterización $y(k) = N[u](k)$ constituye la representación externa de un sistema con memoria evanescente. Ahora veremos que al aproximar la representación interna de un sistema con memoria evanescente, se obtiene un modelo de memoria infinita; mientras que al aproximar su representación externa se obtiene un modelo con memoria finita.

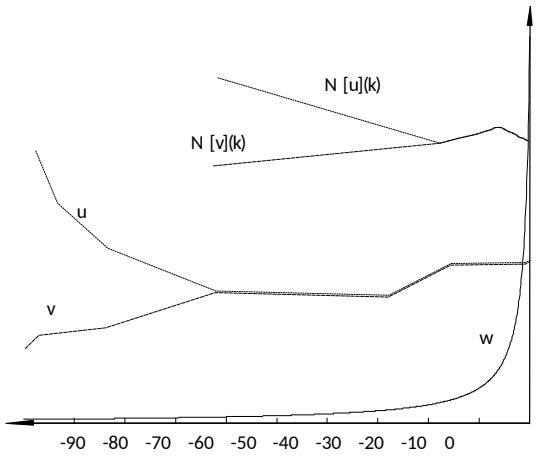


Figura 1.3: Sistema con Memoria Evanescente.

1.4.1 Representación Interna de Sistemas no Lineales.

Las funciones **f** y h constituyen la representación interna del sistema 1.20. Para obtener estas representaciones se requiere un conocimiento físico a priori del sistema, esto es conocer sus estados físicos y tener acceso a ellos, los cuales en muchos casos resultan inaccesibles. Estimar a los estados inaccesibles se constituye en una solución posible, aunque cuando la dimensión del espacio de estados es grande, este solución resulta impráctica. Se aplica en estos casos la teoría de estimadores de orden reducido. Sin embargo por ser un problema no lineal existen dificultades para asegurar la estabilidad de los observadores. Una opción alternativa consiste en estimar modelos de la forma de 1.23:

$$\widetilde{y}(k) = \widetilde{g}\left(\left[\widetilde{y}(k-1), ..., \widetilde{y}(k-n_y)\right], \left[u(k-1), ..., u(k-n_u)\right]\right),$$

o en forma vectorial por 1.11 y 1.8

$$\widetilde{y}(k) = \widetilde{g}\left(\widetilde{\mathbf{y}}_{ny}(k), \mathbf{u}_{nu}(k)\right), \tag{1.27}$$

donde $\widetilde{g}(\cdot)$ es una aproximación de $g(\cdot)$. Este modelo puede ser utilizado en simulación, esto es, dada una secuencia de entradas $\{u(k+1), u(k+2), ...\}$ de longitud arbitraria predecir cual será la de salida $\{\widetilde{y}(k+1), \widetilde{y}(k+2), ...\}$ sin disponer de las salidas reales del sistema $\{y(k+1), y(k+2), ...\}$. Narendra [50] denomina estructura paralelo a la de la Figura 1.2b, y expone la gran dificultad para conseguir estimadores estables con esta estructura; consideraciones similares pueden ser halladas en [43]. Si se hace extensiva la metodología utilizada en el caso lineal para superar este inconveniente utilizando a las entradas verdaderas en lugar de las del modelo, se llega a la siguiente formulación (Figura 1.2a):

$$\widetilde{y}(k) = \widetilde{g}\left(\mathbf{y}_{ny}(k), \mathbf{u}_{nu}(k)\right). \tag{1.28}$$

Supongamos que el modelo fue estimado de acuerdo con 1.28 y que

$$y(k) = \widetilde{y}(k) + e(k). \tag{1.29}$$

En ciertas aplicaciones como las de control predictivo es necesario estimar el comportamiento del sistema sobre horizontes tiempo arbitrariamente largos [44]. Supongamos el caso en que fuera necesario predecir $\widetilde{y}(k+20)$ en el instante de tiempo k. En este

caso, habría que utilizar al vector $[y(k+19), ..., y(k+19-n_y)]$. Dado que el sistema es causal, no es posible obtener $\mathbf{y}_{ny}(k)$ por lo cual habría que realimentar $[\widetilde{y}(k+19), ..., \widetilde{y}(k+19-n_y)]$. Tomando en cuenta 1.29 se obtendría

$$[\widetilde{y}(k+19)+e(k+19-n_y), ..., \widetilde{y}(k+19-n_y)+e(k+19-n_y)].$$

Se aprecia que el error se realimenta a través del modelo, produciendo tanto un gran deterioro en la performance de predicción para más de un paso en el futuro como graves problemas de inestabilidad. Es sabido que esta estructura es útil para predecir sólo un paso hacia adelante sin ser extremadamente inestable ni deteriorar la performance de las predicciones. Se ha visto que el utilizar salidas (tanto $\mathbf{y}_{ny}(k)$ como $\widetilde{\mathbf{y}}_{ny}(k)$) en la representación externa, conduce a modelos que dependen continuamente de los valores iniciales, (equivalente no lineal de un IIR). Además que las características de ambas representaciones son muy diferentes. Por un lado, si se utiliza la formulación 1.28 el modelo puede ser ajustado por mínimos cuadrados mediante manipulaciones muy simples. Sin embargo, es posible simular solo un número pequeño de instantes en el futuro, dado la rápida degradación de las predicciones debido a la realimentación del error. Por el otro, cuando es necesario predecir sobre horizontes arbitrariamente extensos, hay que utilizar una formulación como la mostrada en 1.27. En este caso, la complejidad con el algoritmo de estimación, es muy grande y de dificultosa concreción. Una posible solución consiste en aproximar a la representación externa del sistema.

1.4.2 Representación Externa de Sistemas no Lineales.

De la ecuación 1.26 es claro que si a un sistema con memoria evanescente se aplica la misma secuencia de entrada pero partiendo de dos condiciones iniciales distintas, las salidas correspondientes convergerán asintóticamente. La propiedad asintótica de memoria evanescente implica que un sistema que tiene memoria finita, posee memoria evanescente. De hecho un sistema discreto en el que su salida depende de sólo un número finito de valores pasados de la entrada (como en un FIR) tiene memoria evanescente.

FIR no Lineal.

Al aproximar la representación externa de un sistema de memoria evanescente se obtiene un modelo no lineal de memoria finita, en el cual la salida en cualquier instante de tiempo, es función de sólo un número finito de valores pasados de la entrada. Existen algunos pocos resultados disponibles que prueban que un tipo específico de estructura puede aproximar a una representación dada de un sistema no lineal. Para la clase de sistemas de memoria evanescente no lineales Boyd y Chua [6] demostraron que cualquier operador con memoria evanescente puede ser aproximado uniformemente bien por un operador lineal invariante seguido de una transformación polinomial. Cuando ese operador lineal dinámico se toma como una línea de retardos se tiene un FIR no lineal. Sandberg [60] demostró que cualquier sistema no lineal discreto causal y con memoria aproximadamente finita, puede ser aproximado arbitrariamente bien por una conjunto de valores retrasados de la entrada seguido de un Perceptrón de una sola capa oculta. Un Perceptrón de una capa oculta es una red neuronal artificial compuesta por una combinación lineal de transformaciones lineales afines saturadas. El Perceptrón es un modelo paramétrico que permite modelar un conjunto de funciones continuas, siendo uniformemente denso dentro del espacio de funciones continuas. En otras palabras, permite aproximar uniformemente bien cualquier función continua en un conjunto compacto. Cuando la memoria del sistema es grande, estos esquemas de aproximación son de dificultosa implementación debido a la gran dimensión de la transformación de entrada-salida involucrada. Supongamos que la memoria del sistema fuera 40. Luego el vector de entradas contendría valores de las 40 entradas pasadas:

$$\mathbf{u}_{40}(k) = [u(k), u(k-1), \ldots, u(k-39)],$$

y la salida se expresaría como:

$$y(k) = g(\mathbf{u}_{40}(k)) = g([u(k), u(k-1), \ldots, u(k39)]),$$

donde $g : R^{40} \rightarrow R$. Los resultados de Stone [71] sugieren que si la función es desconocida y la dimensión es elevada (por ejemplo mayor a 10), la única posibilidad de estimar $g(\cdot)$ es asumir una gran suavidad. Si la función es desconocida como en el caso que tratamos y no es suave, el total de información requerida para estimar a la función $g(\cdot)$ podría ser

totalmente impracticable.

Estructura Propuesta: LNet.

Como fuera visto para sistemas lineales, una aproximación de la representación externa de dichos sistemas mediante series funcionales lleva a una importante reducción en la cantidad de parámetros involucrados. En el caso de la estructura LNet, se busca aproximar modelos de memoria evanescente no lineales mediante una combinación no lineal de sistemas discretos de Laguerre. Esta idea sigue los pasos de Wiener [77] en la cual un sistema no lineal continuo es aproximado por una combinación polinomial de sistemas continuos de Laguerre. La utilización de un Perceptrón de una capa oculta para realizar la combinación no lineal se justifica por varias razones. Entre ellas se encuentra la reconocida ventaja de las redes respecto de la cantidad de términos necesarios para realizar una dada aproximación, comparada con la cantidad desmesuradamente grande de términos que utiliza un polinomio. También cuenta el inherente comportamiento patológico de los polinomios que ante una entrada desmesuradamente grande producen una salida desmesuradamente grande. Consecuentemente la estructura LNet permite aproximar a la clase de sistemas que admiten una representación como no lineales discretos, causales, invariantes en el tiempo y que poseen $\mathcal{ME}$, en forma similar a lo mostrado en 1.19 para el caso lineal. Se expresa mediante una combinación no lineal de m sistemas de Laguerre 1.15 como:

$$\widetilde{y}(k) = NN\left(\left[L_o[u](k), L_1[u](k), \ldots, L_{m-1}[u](k)\right]\right), \tag{1.30}$$

donde $NN(\cdot)$ representa un Perceptrón de una capa oculta. Considerando no neuronas en la capa oculta:

$$\widetilde{y}(k) = \sum_{i=1}^{no} w2_i \phi\left(\mathbf{w1}^T \mathbf{u}_L(k) + b1_i\right) + b2, \tag{1.31}$$

donde

$$\mathbf{u}_L(k) = \left[L_o[u](k), L_1[u](k), \ldots, L_{m-1}[u](k)\right] \tag{1.32}$$

es el vector de los sistemas de Laguerre con $\mathbf{w1}^T \in \mathbb{R}^m$, $b1_i$, $w2_i$, $b2 \in R$, ϕ cualquier función sigmoidal continua.

Para el cálculo de la estructura, hay que definir al polo generador de los sistemas

de Laguerre (a); cuántos de ellos utilizar (m), y al número de neuronas de la capa oculta. Para seleccionar la cantidad m de sistemas se parte del concepto de continuidad del operador asociado a la estructura LNet. Como este operador es continuo también es Lipschitz acotado. De forma tal que definiendo convenientemente a los denominados coeficientes de Lipschitz, es posible estimar al número m. Para evaluar la cantidad de neuronas *no* se parte de una concepto de poda ("pruning"). Es decir, comenzando con un número elevado de neuronas se va decreciendo hasta llegar a una performance aceptable con el mínimo de neuronas. Para implementar está técnica de poda, se utilizan valores singulares. El modelo resultante es no lineal, fácilmente identificable a partir de datos de entrada-salida y puede ser utilizado en simulación para predecir el comportamiento del sistema sobre horizontes de tiempo arbitrariamente largos.

1.5 Objetivos de esta Tesis.

El objetivo de esta tesis es presentar a la estructura de aproximación LNet conjuntamente con una metodología para su utilización en la identificación de sistemas no lineales discretos. Dicha estructura está compuesta por un conjunto de sistemas discretos de Laguerre relacionados de forma no lineal mediante un Perceptrón de una capa oculta. Para cumplimentar el objetivo principal perseguido se desarrollarán los siguientes partes:

1. Presentar un marco general para especificar sistemas no lineales discretos que incluyan redes neuronales, conjuntamente con resultados que ilustran la ventaja de utilizar redes neuronales sobre otro tipo de aproximadores.

2. Demostrar que la estructura LNet es capaz de aproximar a sistemas susceptibles de ser caracterizados como no lineales discretos, causales, invariantes en el tiempo y que posean un cierto tipo de continuidad denominada memoria evanescente.

3. Desarrollar una metodología de identificación para dicha estructura.

4. Mostrar a través de ejemplos de aplicación las ventajas de la estructura propuesta sobre otros esquemas de identificación, tanto convencionales como que contengan redes neuronales, con fuertes basamentos teóricos.

A continuación se presenta un esquema del desarrollo de la tesis.

1.6 Desarrollo de la Tesis.

Esta tesis está estructurada de la siguiente forma. El Capítulo I está constituido por la presente introducción. En el Capítulo II se referencian diversos métodos de aproximación y se presentan una revisión de redes neuronales artificiales y un marco general para notarlas. En el Capítulo III se formulan los resultados de aproximación de la estructura propuesta. En el Capítulo IV se desarrollan los métodos de caracterización de la estructura, entrenamiento y validación del modelo. En el Capítulo V se presentan diversos ejemplos para ilustrar la aplicación de la metodología de modelación propuesta, resaltando cada uno facetas específicas de los aspectos de modelado. El primer ejemplo ilustra la capacidad de la metodología de modelación presentada para hallar la estructura correcta de un sistema no lineal discreto. En segundo término se presenta un caso de cancelación de eco no lineal en una línea telefónica, culminando con el modelado de una columna de destilación binaria de alcoholes. Adicionalmente se consideran una posible extensión para sistemas MISO y pautas de diseño que permiten utilizar al modelo LNet de la columna en una estrategia de control predictivo. Concluye el Capítulo VI con algunas consideraciones y recomendaciones.

Capítulo 2

Aproximación de Sistemas.

En este capítulo se presentan varias estructuras de aproximación entrada-salida, basadas tanto en modelos convencionales como en redes neuronales. Para una correcta comprensión se definen los conceptos involucrados en la constitución de una red neuronal: neuronas, capas, topologías, etc. Conjuntamente se define un marco general en el cual es posible especificar sistemas no lineales discretos que incluyan redes neuronales. Dentro de este marco es factible notar diferentes clases de redes que permiten modelar tanto sistemas dinámicos como estáticos. Respecto de este último tópico, se ilustra sobre la conveniencia de utilizar redes neuronales como aproximadores universales de funciones no lineales en lugar de otros tipos de aproximadores (polinomios, splines, etc.). Concluye el capítulo un resumen de lo presentado.

2.1 Introducción.

La teoría de sistemas, que en los útimos años ha evolucionado como una disciplina científica de gran aplicabilidad, trata sobre la síntesis y el análisis de sistemas dinámicos. Los aspectos de esta teoría mejor desarrollados tratan sistemas definidos por operadores lineales utilizando técnicas bien establecidas basadas en el álgebra lineal, la teoría de variables complejas y la teoría de ecuaciones diferenciales lineales ordinarias. Producto del gran avance de la teoría en este área existe una significativa cantidad de técnicas diversas para el análisis y síntesis de sistemas lineales. Estas técnicas abordan dichos problemas desde ópticas variadas respecto del grado de conocimiento requerido del sistema en cuestión. Abarcan desde las que requieren un total conocimiento, pasando

por las que admiten un cierto grado de incertidumbre en la descripción del sistema hasta las que identifican por completo al sistema. En contraste, y a pesar del gran esfuerzo hecho en el estudio de sistemas no lineales, la mayor parte del trabajo realizado en este área requiere del conocimiento total de los modelos (ver [2, Banks], [29, Isidori]). En muchos casos ese conocimiento no está disponible al igual que el acceso a los estados que describen al sistema, debiendo en dicho caso ser estimados. Cuando los sistemas son de grandes dimensiones el hecho de estimar estados en sistemas no lineales se convierte en prohibitivo. Sin embargo, en una variada cantidad de situaciones es posible recurrir a modelos que se construyen en base a medidas de los datos provenientes de las entradas y salidas disponibles del sistema. Lo cual naturalmente conduce a identificar modelos no lineales entrada-salida.

En décadas pasadas fueron desarrollados una gran variedad de métodos de identificación de sistemas no lineales dinámicos en base a datos entrada-salida. En la mayoría de los casos (si no en todos) la identificación de dichos esquemas involucra determinar algún tipo de función no lineal, como por ejemplo los núcleos en las series de Volterra. Más aún, la mayoría de ellos supone el conocimiento *a priori* de la estructura del sistema. Y aun cuando existen formas de estimar dichas estructuras (por complicadas que estas sean), estos métodos encontraron una escasa aplicación debido a la inherente dificultad de estimar a las funciones no lineales involucradas en sus estructuras. En este sentido la aparición de técnicas diversas como las de redes neuronales produjo cambios sustantivos.

La aplicación de técnicas basadas en redes neuronales artificiales produce un resurgimiento tonificado y una amplia expansión en el campo de los sistemas no lineales. Gran parte de este resurgimiento se explica por la relativa facilidad que poseen ciertas estructuras como el Perceptrón Multicapas para modelar funciones no lineales en espacios de grandes dimensiones. En este campo del conocimiento coexisten tanto estructuras totalmente novedosas, como también una importante cantidad provenientes de la modificación de esquemas de aproximación existentes. En esta capítulo serán presentados modelos convencionales y otros que utilizan redes neuronales, por lo que para una correcta comprensión, la temática de redes será definida en la siguiente sección.

2.2 Redes Neuronales.

Las redes neuronales artificiales (RNA) comenzaron a ser investigadas en un intento por reproducir algunas de las propiedades destacables de sus homólogas biológicas: extracción de caracterísmos[1], asociaciones causa-efecto, identificación y reconocimiento de patrones, etc. Desde los comienzos de Minsky en la década del '50, el tópico conocido en la literatura como redes neuronales artificiales, se ha constituído como un conjunto de algoritmos y heurísticas que busca emular algunas de las tareas que un ser humano realiza muy bien en forma natural. Objetivo que no debe ser confundido con el de modelar matemáticamente al comportamiento de las neuronas biológicas, que es objeto de estudio de otras áreas del conocimiento [73]. Por lo tanto, las semejanzas que las RNA mantienen con las biológicas se reducen a: imitar algunas de sus cualidades y compartir la terminología. De acuerdo a estas analogías, diremos que una *neurona* artificial es el mínimo elemento de procesamiento de información encontrado en una red artificial. Luego, una *red* está conformada por una gran cantidad de estos simples elementos densamente interconectados. La forma en que las neuronas se conectan entre sí definen en general a la *topología* de la red y en particular a subestructuras denominadas *capas*. Cabe aclarar que no siempre es posible definir capas en la topología de una red. Un hecho relevante en una red lo constituye la posibilidad de que exista o no realimentación entre cualesquiera de sus partes, como por ejemplo, entre neuronas, entre entradas y salidas, y/o entre capas, etc. Esta propiedad genera una primera gran división a saber de las redes existentes entre: aquellas *con realimentación o recurrentes* y aquellas *sin realimentación o feedfordward*. Estas últimas generalmente son capaces de modelar a objetos sin dinámica (sistemas de funciones no lineales) mientras que las primeras permiten modelar a objetos dinámicos (sistemas de ecuaciones diferenciales no lineales). Ambos tipos de redes necesitan ajustar sus parámetros constitutivos y por analogía a lo que ocurre en una red neuronal biológica se dice que una RNA *aprende*.

El concepto aprender se refiere a la manera en que los algoritmos utilizados modifican a los parámetros de la red en forma tal de lograr un objetivo dado. Por ejemplo, si se desea clasificar a un conjunto de datos en varias clases distintas y se conoce a que clase pertenece cada dato, un mecanismo de aprendizaje *supervisado* cumplirá eficientemente la tarea. Para implementar este tipo de algoritmo es usual proceder minimizando

[1] **caracterísmo**: conjunto de rasgos que distinguen a una cosa de las demás.

un índice dado de performance entre lo que es deseado y la salida de la red. Dentro de esta clase el algoritmo más conocido es, sin duda, el "Back Error Propagation [58]". Sin embargo la información relativa a lo que es esperado obtener a la salida no siempre se encuentra disponible. Un ejemplo típico consiste en tener que clasificar a un conjunto de datos en varias clases sin conocer a que clase pertenece cada dato ("clustering"). Esta tarea es efectuada por un algoritmo de aprendizaje *no supervisado*. Dentro de esta clase, los dos algoritmos más importantes son: "Kohonen's Self-Organizing Map [30]" y "Grossberg's Adaptive Resonance Theory [10]". La Figura 2.1 muestra a una posible clasificación de redes de acuerdo a la forma de interconectarse y al tipo de algoritmos de entrenamiento.

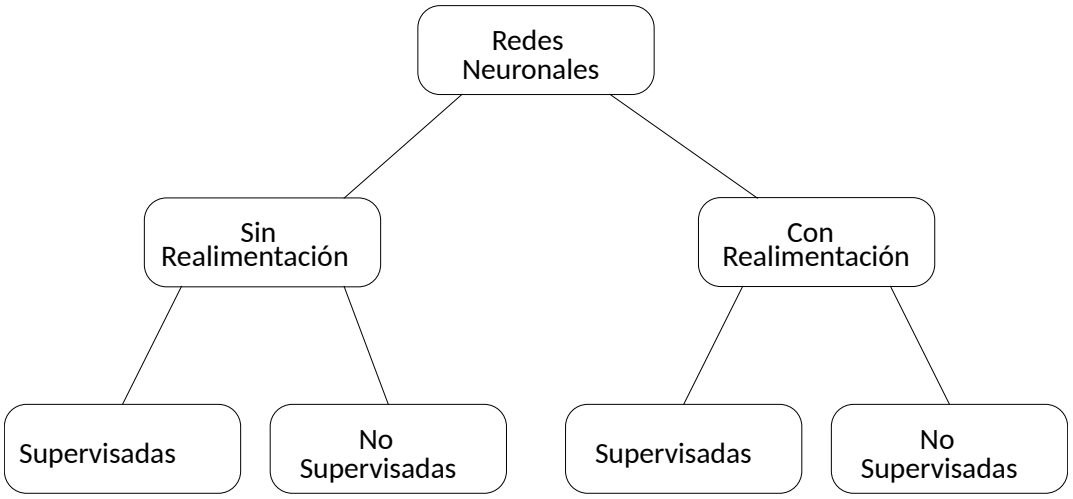


Figura 2.1: Esquema de Clasificación de Redes Neuronales Artificiales.

Como es posible inferir, existe una gran variedad de redes neuronales artificiales, muchas de ellas especializadas y con capacidades específicas como acontece con su contraparte biológica. Estos modelos abarcan desde los más simples, cuyas neuronas calculan alguna medida de la distancia entre las entradas y sus pesos, hasta las que integran, correlacionan o realizan otras operaciones temporales aun más complejas sobre sus entradas [34]. Debido a la gran variedad de modelos neuronales artificiales existentes se explicitará solamente el modelo de red con el que se ha de trabajar, brindando las referencias bibliográficas necesaria cada vez que sea preciso. La Figura 2.2 muestra a una neurona artificial con:

$u_1, u_2, \ldots, u_m$: un conjunto de *entradas*.

$w_1, w_2, \ldots, w_m$: un conjunto de *pesos* sinápticos.

b : el valor de *umbral* (o "bias").

ϕ : la *función de activación.*

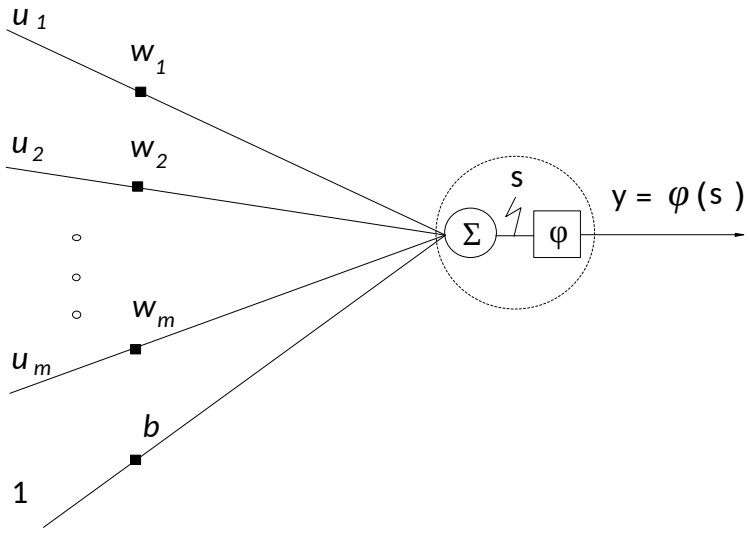


Figura 2.2: Esquema de una Neurona Artificial.

En este diagrama se muestra como puede ser interpretado el flujo de señales en nuestra neurona típica. Un pequeño cuadrado negro, representa a un valor escalar que multiplica a la señal que "circula" por la línea llena (por ejemplo $u_1 w_1$). Los círculos con el símbolo $\sum$ expresan la sumatoria de las señales que llegan a ellos (por ejemplo $w_1 u_1 + w_2 u_2 + \cdots + w_m u_m + b$). El cuadrado con el símbolo ϕ en su interior representa a una transformación no lineal estática que puede adoptar diversas formas: función signo, función arco tangente hiperbólica, o en general a una función cualquiera [35]. El valor de umbral b será considerado como un peso adicional (por simplicidad), suponiendo que existe una entrada utilitaria que se mantiene constante en un valor unitario (por convención). Esta forma de interpretación gráfica es conveniente para comprender las definiciones matemáticas de neurona, capa y red. Por consiguiente el valor s de la salida de una neurona, puede ser expresado como

$$s = \left| \mathbf{w}^T \; b \right| \left| \begin{array}{c} \mathbf{u} \\ 1 \end{array} \right| = w_1 u_1 + w_2 u_2 + \cdots + w_m u_m + b,$$

donde $\mathbf{u} = [u_1\ u_2 \dots u_m]^T$ es el vector de entradas y $\mathbf{w} = [w_1\ w_2 \dots w_m]^T$ el vector de pesos. Para una forma de notación más compacta sean $\mathbf{U}$, $\mathbf{S}$ e $\mathbf{Y}$ espacios vectoriales reales con $\dim(\mathbf{U}) = m$, $\dim(\mathbf{S}) = \dim(\mathbf{Y}) = 1$. Sea $\alpha : \mathbf{U} \to \mathbf{S}$ una transformación real afín de la forma

$$s = \alpha(\mathbf{u}) = \mathbf{w}^T\mathbf{u} + b, \tag{2.1}$$

donde $b \in S$, $\mathbf{u} = [u_1\ u_2 \dots u_m]^T$, $\mathbf{w} = [w_1\ w_2 \dots w_m]^T$, $(\mathbf{u}, \mathbf{w}) \in U$, y $\mathbf{w}^T\mathbf{u} : \mathbf{U} \to \mathbf{S}$. Sea ϕ una función de activación, $\phi : \mathbf{S} \to \mathbf{Y}$ de forma tal que la salida de una neurona puede ser expresada como

$$y = \phi(\alpha(\mathbf{u})) = \phi\left(\mathbf{w}^T\mathbf{u} + b\right).$$

Una capa se define por un agrupamiento de una cantidad *no* de neuronas a las que no les está permitido conectarse entre sí. Sea ahora S un espacio vectorial real de dimensión finita $\dim(S) = no$, que define al orden de la capa. Cabe destacar que la dimensión del espacios S varía de acuerdo a se trate de una neurona $\dim(S) = 1$, o de una capa $\dim(S) = no$. Sea $\alpha : \mathbf{U} \to \mathbf{S}$ una transformación afín tal que

$$s = \alpha(\mathbf{u}) = \mathbf{W}\mathbf{u} + \mathbf{b},$$

donde $\mathbf{b} \in \mathbf{S}$, $\mathbf{W} : [no \times m]$, $\mathbf{W} = [\mathbf{w}_1\ \mathbf{w}_2 \dots \mathbf{w}_{no}]^T$, los $\mathbf{w}_i \in \mathbf{U}$ representan a los vectores de las neuronas**,** $\mathbf{W}\mathbf{u} : \mathbf{U} \to \mathbf{S}$. Sea ϕ la función de activación de la capa, $\phi : \mathbf{S} \to \mathbf{Y}$ de forma tal que

$$\phi(s_1, s_2, \dots, s_{no}) = (\phi_1(s_1), \phi_2(s_2), \dots, \phi_{no}(s_{no})), \tag{2.2}$$

donde cada $\phi_i, i : 1, 2, \dots, no$ es la función de activación de una neurona. Interpretaremos a una capa de orden *no* como a la realización de una función contínua $\mathbf{y} : \mathbf{U} \to \mathbf{Y}$ de la forma $\mathbf{y} = \phi(\mathbf{W}\mathbf{u} + \mathbf{b})$. Este tipo de topologías conforman lo que denominaremos *capas planas*. Luego una capa plana queda definida por el conjunto de valores $(\mathbf{U}, \mathbf{S}, \mathbf{W}, \mathbf{b}, \phi)$ o refiriéndose específicamente a la capa $i - ésima$ mediante un operador de la forma

$$\mathbf{N}_i[\mathbf{u}] = \phi[\mathbf{W}i\ \mathbf{u} + \mathbf{b}i]. \tag{2.3}$$

Se ilustró sobre la forma en que un agrupamiento de neuronas produce una estructura denominada capa. En las siguientes secciones se verá que una red está compuesta por una determinada cantidad de capas interconectadas entre sí. Las diversas forma de

interconectar a las capas da lugar a redes multicapas, redes recurrentes o redes generalizadas. Cada categoría será ilustrada con un ejemplo considerado típico o sumamente representativo de esta, brindándose las correspondientes referencias para otros tipos de su clase.

2.2.1 Redes Multicapas.

La Figura 2.3 muestra una red multicapas, sin realimentación o *feedforward* típica, compuesta de una capa de m entradas, dos capas con no_1 y no_2 neuronas respectivamente y una capa de d salidas. En forma de operadores esta red se puede expresar como

$$\mathbf{y} = \mathbf{N}[\mathbf{u}] = \mathbf{N}_3\mathbf{N}_2\mathbf{N}_1[\mathbf{u}] = \phi[\mathbf{W}3\phi[\mathbf{W}2\phi[\mathbf{W}1\mathbf{u} + \mathbf{b}1] + \mathbf{b}2] + \mathbf{b}3].$$

El agregado de más capas no incorpora conceptualmente ninguna complejidad extra. En la Figura 2.4 se muestra un diagrama en bloques de la misma red. La característica principal de este tipo de redes radica en que producen en su salida una transformación no lineal estática de la señal de sus entradas. Cabe destacar que existen otros tipos de redes multicapas como las Radial Basis Network [47], constituyendo un ejemplo clásico de esta clase el denominado Perceptrón Multicapas.

Perceptrón Multicapas.

Quizás sea esta la red neuronal más conocida y que ha sido objeto de los más variados estudios, comenzando por Minsky en la década del '50. El Perceptrón Multicapas es un tipo de red neuronal artificial que consta de nc capas planas como las descriptas por la ecuación 2.3. Las capas que queden entre la salida y la entrada se denominan ocultas por razones históricas, considerando que cada capa cuenta con no_i nodos o neuronas, $i : 1, ..., nc$. La Figura 2.3 muestra tal disposición de tres capas, para las capas ocultas 1 y 2 y la capa 3 de salida.La Figura 2.4 muestra un diagrama pictórico en el cual cada capa es representada sólo por su matriz $\mathbf{W}i$. Un lugar destacado lo ocupa dentro de este tipo de redes, el Perceptrón de una única capa oculta.Esta red neuronal constituye un aproximador de funciones continuas parametrizado por los pesos sinápticos de sus no

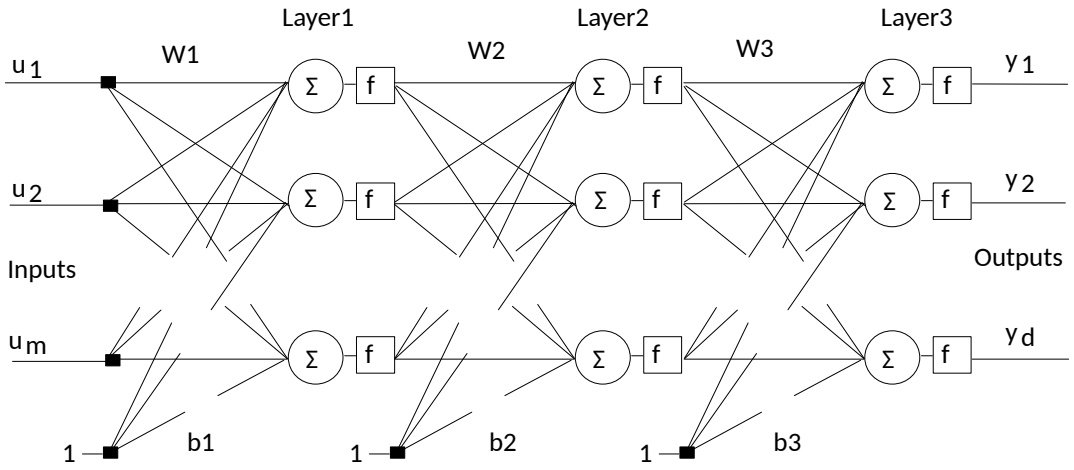


Figura 2.3: Estructura de Red Multicapas.

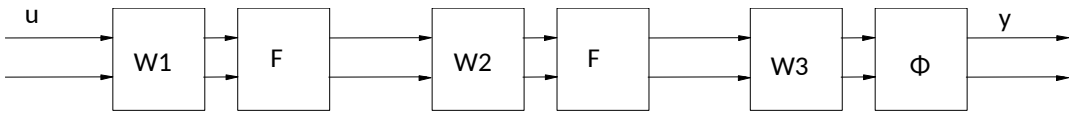


Figura 2.4: Diagrama Pictórico de una Red Multicapas.

neuronas en la capa oculta. Para el caso particular de $y : \mathbb{R}^m \to \mathbb{R}$:

$$y = \sum_{k=1}^{no} w2_k \phi\left(\mathbf{w1}_k^T \mathbf{u} + b1_k\right) + b2, \tag{2.4}$$

o en su forma de operador como

$$y = NN\left(\mathbf{u}\right). \tag{2.5}$$

Dada su relativa importancia, cabe citar el siguiente teorema.

Teorema 1 (Cybenko, 1989)**.** *Sea $C\left(\mathbf{I}_m\right)$ el espacio de funciones continuas definidas en el cubo unitario $\mathbf{I}_m$ de dimensión m. Entonces, dadas cualquier $g \in C\left(\mathbf{I}_m\right)$, cualquier función sigmoidal continua ϕ y $\varepsilon > 0$, existe un suma finita de no términos*

$$g_{no}\left(\mathbf{u}\right) = \sum_{k=1}^{no} w2_k \phi\left(\mathbf{w1}_k^T \mathbf{u} + b1_k\right) + b2,$$

donde $\mathbf{w1}_k^T \in \mathbb{R}^m$, $b1_k$, $w2_k$, $b2 \in R$, los parámetros de la red neuronal, para los cuales se cumple que

$$\left|g_{no}\left(\mathbf{u}\right) - g\left(\mathbf{u}\right)\right| < \varepsilon$$

para todo $\mathbf{u} \in \mathbf{I}_m$.

Las diferentes formas de expresar a un Perceptrón de una capa oculta serán de utilidad en los futuros desarrollos. Veremos en las siguientes secciones otros tipos de redes: aquellas que incorporan realimentación entre sus partes.

2.2.2 Redes Recurrentes.

Como fuera expresado en secciones anteriores las redes no recurrentes se distinguen de las que no lo son debido a que incorporan algún tipo de realimentación en su estructura. Existe una gran variedad de topologías que realimentan señales provenientes de otras neuronas, de estados internos y/o de las salidas. La forma lógica de representarlas es a través de sistemas no lineales dinámicos. Dentro de las aplicaciones destacables en que se utilizan este tipo de redes cabe mencionar la identificación de sistemas no lineales, procesamiento no lineal de señales e identificación y reconstrucción de patrones con ruido. Es precisamente en esta última aplicación donde se reconoce la aparición de redes recurrentes: la red de Hopfield. Por una recopilación de esta clase de redes referirse a [23] y a las referencias allí citadas. Las redes recurrentes fueron originalmente presentadas en los primeros trabajos de Hopfield en el área [27]. Desde ese instante han sido extensamente investigadas como una alternativa de solución a diversos problemas, entre los que se encuentra la reconstrucción de patrones con ruido. A continuación se comentará la versión discreta de la red de Hopfield, esquematizada en la Figura **??**. Se puede apreciar que esta red consta de una única capa de neuronas con igual número de entradas que de salidas, las cuales son respectivamente realimentadas a su entrada. La realimentación se realiza a través de un conjunto de operadores retardo q^{-1}. Es fácil ver que esta red puede ser descripta por el siguiente sistema no lineal discreto

$$\mathbf{x}(k+1) = \phi[\mathbf{W}\,\mathbf{x}(k)], \qquad \mathbf{x}(0) = \mathbf{x}_0, \tag{2.6}$$

donde $\mathbf{x}(k)$ representa a los estados de la red en el instante k. Otra forma de representarlo es mediante el operador $\mathbf{N}_1[\cdot]$ de la capa plana que interviene:

$$\mathbf{x}(k+1) = \mathbf{N}_1[\mathbf{x}](k), \qquad \mathbf{x}(0) = \mathbf{x}_0.$$

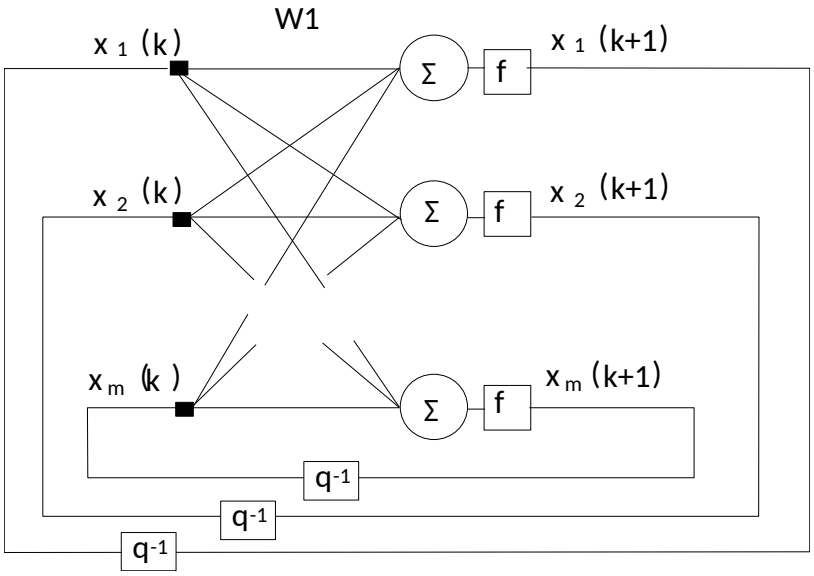


Figura 2.5: Representación de la Red de Hopfield.

Supongamos que se dispone de un conjunto de patrones con ruido y se desea un medio filtrado para quitarles el ruido. Para ello se dispone de una red como la que se trata, previamente entrenada con los patrones sin ruido cuya información se almacena en la matriz $\mathbf{W}$. La forma de funcionamiento de esta red es muy particular, ya que los patrones sin ruido son almacenados como atractores extraños[2]. Luego, los patrones con ruido son incluídos como el estado inicial $\mathbf{x}_0$ de la red. De esta forma, el sistema dinámico descripto por 2.6 evoluciona hasta llegar a un nuevo punto de equilibrio (atractor extraño) que resulta ser el patrón sin ruido deseado (sin ruido). La Figura 2.6 muestra un diagrama esquemático de está red. Esta red tiene una evolución dinámica muy compleja debido a la particular forma de utilización. Este hecho pone de manifiesto una de las situaciones que presenta mayor dificultad para ser tratada en las redes recurrentes: la estabilidad. Condiciones de la estabilidad para la red de Hopfield han sido establecidas en términos de la matriz $\mathbf{W}$ que representa al sistema no lineal discreto 2.6. Cabe resaltar como hecho interesante que una red de una dinámica muy compleja, resulta de la combinación de capas estáticas como 2.3 y elementos de retardo muy simples como 1.6. Si en lugar de un operador retardo simple se utilizan sistemas dinámicos lineales, este concepto puede ser extendido a lo que se denominará Redes generalizadas.

[2] *Atractor extraño:* región del espacio de estados que produce la atracción de las órbitas del sistema que circulan cercanas sin ser ni un punto de equilibrio, ni un ciclo límite, ni un ciclo quasi-estacionario. Una vez en la región del atractor extraño, las órbitas permanecen en el.

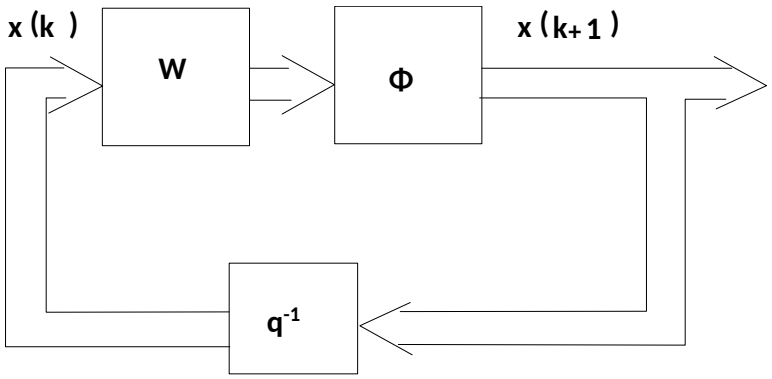


Figura 2.6: Representación en Diagrama de Bloques de la Red de Hopfield.

2.2.3 Redes Generalizadas.

En la sección anterior fue ilustrado cómo a partir de elementos tales como el operador capa $\mathbf{N}_i[\cdot]$ 2.3 y el operador retardo unitario $q^{-1}[\cdot]$ 1.6 conectado en la realimentación, es posible construir redes recurrentes como la 2.6. Estos conceptos pueden ser generalizados [50], dando lugar a estructuras más complejas desarrolladas en base a elementos más simples y bien conocidos. Este hecho es ventajoso ya que provee de un marco generalizado para notar tanto a redes que realizan transformaciones estáticas como a redes que al tener recurrencia, deben ser modeladas como sistemas dinámicos. Los elementos generadores de las redes generalizadas son:

$\mathbf{N}_i[\cdot]$: capas de transformaciones no lineales estáticas.

$\mathbf{G}_i(\cdot)$: matrices de funciones transferencias.

De la combinación de estos elementos deviene una gran diversidad de redes distintas. La Figura 2.7 ilustra sobre cuatro posibles estructuras generalizadas en las que se encuentran representadas una gran variedad de modelos conocidos.En la siguiente sección serán descriptos diversos esquemas de aproximación de entrada-salida, tanto que utilizan redes neuronales en su estructura con otros convencionales que no hacen uso de ellas.

2.3 Diversos Modelos de Aproximación Entrada-Salida.

En esta sección se presentarán diversos esquemas de aproximación entrada-salida que para una mejor diagramación están divididos en convencionales y no convencionales.

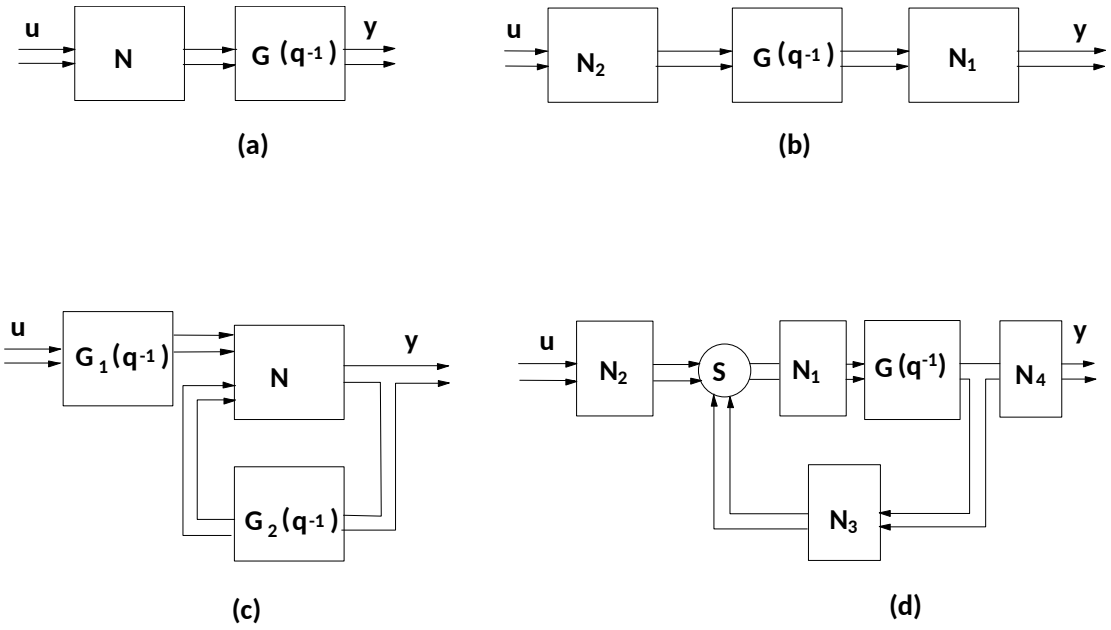


Figura 2.7: Estructuras de Redes Generalizadas: Diversos Esquemas.

Entre los primeros se encuentran los métodos de aproximaciones funcionales basados en series de Volterra y de Wiener, modelos de bloques en cascada y modelos de bloques en cascada-paralelo. Entre los segundos, caracterizados por contar con redes neuronales en sus estructuras, se detallarán: FIR e IIR no lineales y un esquema de aproximación interna de sistemas no lineales con memoria evanescente. En todos los casos serán tratados sistemas no lineales discretos como los descriptos por 1.20 con una entrada $u(k)$ y una salida $\widetilde{y}(k)$ que aproxima a la salida $y(k)$ del sistema como se ve en la Figura 2.8.

2.3.1 Esquemas Convencionales.

Métodos de Expansiones Funcionales.

Se entiende por expansión funcional de un sistema a una representación del sistema desde el punto de entrada-salida como:

$$y(t) = Fun\left[u(t'); t' \leq t\right],$$

donde $y(t)$, $u(t)$ constituyen la salida y entrada del sistema en el tiempo t y $Fun[\cdot]$ representa a la funcional deseada. De forma tal que resulta posible evaluar al valor de la salida en cualquier instante de tiempo t, conociendo la evolución de la entrada $u(t')$,

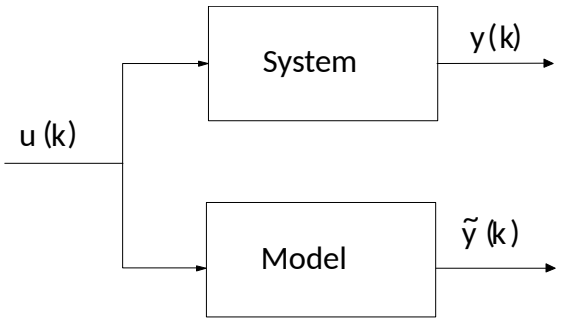


Figura 2.8: Esquema del Sistema y el Modelo que lo Aproxima.

para todo tiempo $t' \leq t$. La implementación de estas estrategias de aproximación en el caso lineal lleva a representaciones como muestran las ecuaciones 1.14 y 1.19. Cuando se trata de métodos de expansiones funcionales en el contexto de identificación de sistemas no lineales se habla naturalmente de las series de Volterra y de Wiener.

Método de la Serie de Volterra. El estudio de funcionales analíticas comenzó en 1887 con las investigaciones de Volterra quien introdujo la representación

$$y(t) = \sum_{n=1}^{\infty} \int_{\Omega} \cdots \int k_n(\tau_1, \tau_2, \ldots, \tau_n) \prod_{i=1}^{\infty} u(t - \tau_i)\, d\tau_i, \tag{2.7}$$

conocida ampliamente como serie de Volterra. Las funciones $k_n(\tau_1, \tau_2, \ldots, \tau_n)$ en las variables τ_i de la ecuación 2.7 se denominan núcleos de Volterra, válidos en el dominio Ω. Para sistemas no lineales continuos, causales e invariantes al desplazamiento, los núcleos son acotados, simétricos y continuos con respecto a cada τ_j, con $k_n(\tau_1, \tau_2, \ldots, \tau_n) = 0$ para cualquier $\tau_j < 0$. La solución del problema de identificación basado en series de Volterra, involucra la medición de los núcleos de Volterra [1]. Se puede observar que la serie 2.7 es infinita, lo que indica que para identificarla en primer lugar hay que truncarla. A continuación se presenta a la serie de Volterra discreta:

$$\widetilde{y}(k) = \sum_{m=0}^{mv} \sum_{i_1=0}^{lm-1} \cdots \sum_{i_m=0}^{lm-1} k_m(i_1, \ldots, i_m)\, u(k - i_1) \cdots u(k - i_m). \tag{2.8}$$

En la ecuación 2.8 m es el orden de la serie, que tiene memoria finita lm y donde k_m es un núcleo simétrico de orden *e-mésimo*. Esta serie puede aproximar arbitrariamente bien en forma uniforme a sistemas discretos no lineales, que tengan memoria finita, causales

e invariantes, sobre un conjunto de entradas uniformemente acotadas, siempre y cuando se consideren un orden m suficientemente alto. Precisamente este punto se constituye en el cuello de botella del método de series de Volterra, aún para núcleos de dimensiones moderadas. Para la medición de los núcleos $k_m(\cdot)$ se han utilizado desde técnicas de minimización por gradiente, pasando por mediciones en el dominio de la frecuencia, hasta correlaciones de órdenes superior [4]. Las dificultades de estimar a estos núcleos han restringido las aplicaciones a expansiones con núcleos de dimensión ≤ 2 [4], [43]. Los trabajos desarrollados por Volterra fueron retomados y continuados por Wiener en la década del '50.

Método de la Serie de Wiener. Wiener fue uno de los primeros autores en considerar la identificación de sistemas no lineales. Consideremos un sistema no lineal continuo causal e invariante en el tiempo con $y(t)$, la salida y $u(t)$ la entrada del sistema en el tiempo t. La funcional utilizada por Wiener para expandir al sistema se puede expresar como

$$y(t) = \sum_{n=1}^{\infty} \sum_{m_0=0}^{\infty} \sum_{m_1=0}^{\infty} \cdots \sum_{m_n=0}^{\infty} c_{m_0 m_1 \cdots m_n} ph_{m_0}(vv_0(t))\, ph_{m_{01}}(vv_1(t)) \cdots ph_{m_n}(vv_n(t)), \tag{2.9}$$

donde $c_{m_0 m_1 \cdots m_n}$ representa a los coeficientes de la expansión, $vv_p(t)$ variables auxiliares combinadas por los polinomios de Hermite $ph_{m_n}(\cdot)$. Las variables auxiliares $vv_p(t)$ representan la convolución de la señal de entrada $u(t)$ con el sistema de Laguerre $l_p(t)$ de orden

$$vv_p(t) = \int_0^{\infty} l_p(\tau)\, u(t-\tau)\, d\tau, \qquad p = 0, 1, \ldots$$

El polinomio de Hermite $ph_{m_n}(\cdot)$ parcialmente normalizado está definido por

$$ph_{m_n}(u) = (-1)^{m_n} 2^{-m_n/2} \frac{e^{u^2}}{\sqrt{m_n!}} \frac{d^{m_n}}{du^{m_n}} \left\{ e^{-u^2} \right\}.$$

La síntesis de un sistema no lineal utilizando el método de Wiener puede ser visualizado como una cascada de tres bloques distintos como se ve en la Figura 2.9. El primero es un sistema lineal con múltiples salidas compuesto por los sistemas de Laguerre. Sigue en cascada una transformación no lineal sin memoria que representa a los polinomios de Hermite. Culminando con una red de amplificadores y sumadores: los coeficientes

$c_{m_0 m_1 \cdots m_n}$ de la expansión.

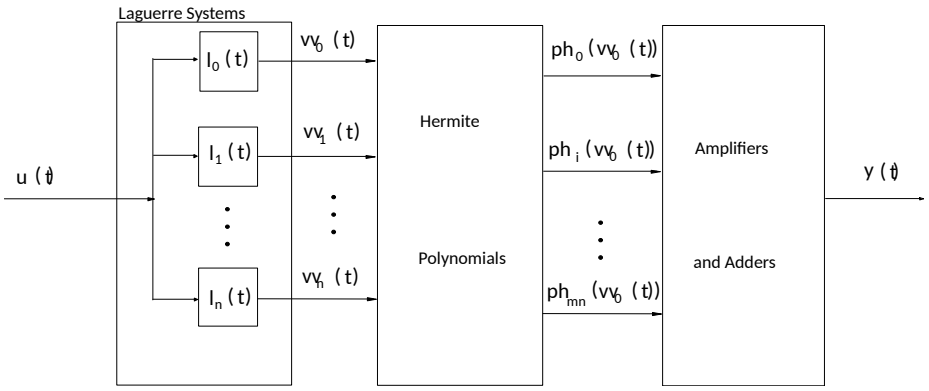


Figura 2.9: Método de Wiener

Aunque la formulación de Wiener es teóricamente muy elegante, es impráctica y dificultosa de aplicar debido al alto número de coeficientes requerido. Si se utilizan n sistemas de Laguerre y polinomios de Hermite de orden m_n, se necesitarán $(m_n)^n$ coeficientes para caracterizar al sistema. Es así que aún para un sistema compuesto por una no linealidad de segundo orden utilizando 10 sistemas de Laguerre, se precisarían del orden de 2^{10} coeficientes. Causa por la cual la mayoría de las aplicaciones prácticas se han restringido a sistemas cuadráticos [4] , aunque existen resultados teóricos que muestran dificultades fundamentales para la evaluación de núcleos de orden ≥ 3 [54]. Por el contrario a lo que acontece en series de Volterra, las versiones discretas de estas series han sido utilizadas en pocos casos [32].

Las expansiones en series de Wiener y Volterra se han limitado a realizaciones donde el orden de los núcleos es bajo, debido a la gran cantidad de parámetros asociados que es necesario identificar. Los sistemas de bloque en cascada surgen como un intento de resolver el problema de identificación buscando representaciones más compactas respecto del número de parámetros.

Identificación de Modelos de Bloques en Cascada.

Los sistemas de bloques en cascada comenzaron a ser estudiados por varios autores en una búsqueda por reducir la alta carga computacional asociada a las aproximaciones mediante series funcionales. La Figura 2.10 esquematiza a estos modelos por medio de la interconexión de sistemas dinámicos lineales y elementos no lineales estáticos como se puede apreciar en [32]. El esquema consta de dos sistemas lineales dinámicos

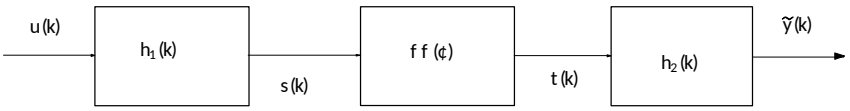


Figura 2.10: Modelo General de Cascadas.

representados por las respuestas impulsivas $hgc_1(k)$ y $hgc_2(k)$ y un sistema no lineal sin memoria representado por $ff(\cdot)$. Se trata de aproximar al sistema desde un punto de vista entrada-salida teniendo en cuenta que las señales $t(k)$, y $s(k)$ no son accesibles para la medición. Como una consecuencia directa, los métodos para la estimación de $hgc_1(k)$ y $hgc_2(k)$ han sido muy variados. Sin embargo todas estas técnicas tienen en común que requieren un gran tiempo de experimentación y adquisición de datos que puede ser prohibitivo en muchos casos. Un método más simple de resolver el problema de identificación fue desarrollado por Korenberg [32], utilizando técnicas de correlación y transformadas de Fourier para identificar a los valores de $hgc_1(k)$ y $hgc_2(k)$. Una vez estimadas estas respuestas impulsivas se pueden evaluar los valores de las señales $t(k)$ y $s(k)$ procediéndose a graficar la función $ff(\cdot)$. Las desventajas de este método consisten en:

1. Es un método gráfico (es necesario graficar a la función $ff(\cdot)$).

2. Y de acuerdo a si esta función es par o impar, se deben calcular correlaciones de orden superior para poder identificar completamente al modelo.

Como una forma de simplificar los cálculos involucrados surgieron otros modelos muy utilizados que constituyen subestructuras del modelo general. Se pueden citar a los casos muy conocidos de los modelos de Wiener, con $hgc_2(k) = \delta(k)$[3] y de Hammerstein [49] con $hgc_1(k) = \delta(k)$. Se ha visto que los métodos de bloques en cascadas aventajan a los de expansiones funcionales respecto de la cantidad de términos que es necesario utilizar. Sin embargo, por ser métodos gráficos no han sido de amplia utilización. Los métodos de cascada de bloques en paralelo constituyen una mejora respecto de ambos tópicos.

[3] $\delta(k)$: representa al impulso unitario.

Modelos de Cascadas de Bloques en Paralelo.

Este método desarrollado por Korenberg [33], consiste en la conexión en paralelo de varias secciones compuestas por la cascada de un sistema lineal dinámico y una no linealidad estática como se ve en la Figura 2.11. Se puede pensar que la filosofía

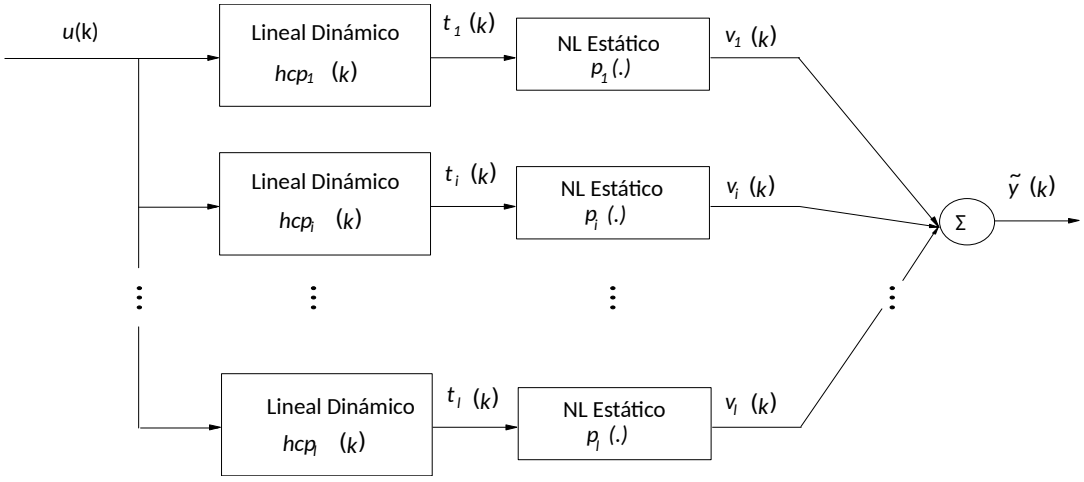


Figura 2.11: Método de Secciones en Cascada/Paralelo.

de aproximación implícita, resume a la de los métodos de expansiones funcionales y cascadas de bloques. Por un lado, se tienen cascadas de sistemas lineales dinámicos y no lineales estáticos a semejanza de los sistemas de bloques en cascadas. Por otro, se van incorporando ramas en paralelo de cascadas de bloques (como en las series funcionales), hasta lograr paulatinamente la aproximación deseada. La esencia del método consiste en aproximar la salida del sistema no lineal por una primer cascada de un sistema lineal con una no linealidad estática. Luego se calcula el residuo entre la salida de esta primer cascada y el sistema no lineal, ajustando dicho residuo por una segunda cascada. Continuando con este proceso se logra la convergencia del algoritmo en el sentido de la media cuadrática [33]. Este método es aplicable a cualquier sistema no lineal discreto invariante en el tiempo y causal. Matemáticamente esto puede ser expresado como:

$$y(k) = \sum_{i=1}^{I} v_i(k) + e(k),$$

donde $v_i(k)$ es la salida del la *i-ésima* cascada e $y(k)$ la salida del sistema como es usual. El subsistema lineal de la *i-ésima* cascada queda caracterizado por su función impulsiva $hcp_i(m)$, cuya longitud de memoria $lm = r$, mientras que la no linealidad está

caracterizada por el polinomio $p_i(\cdot)$. Suponiendo que ha sido calculada hasta la sección $i-1$ y dados np datos:

1. se calcula $\widetilde{y}_{i-1}(k), \quad k = 0, 1, \ldots, np$ el residuo remanente $\left(\widetilde{y}(k) - \sum_{j=1}^{i-1} v_j(k)\right)$ luego de la $(i-1)$-*ésima* iteración, donde $\widetilde{y}_0(k) = y(k)$

2. **SI** el residuo $\widetilde{y}_{i-1}(k)$ es lo suficientemente pequeño, **PARAR,** si no aproximar a $\widetilde{y}_{i-1}(k)$ con cascada i ésima.

3. La respuesta impulsiva $hcp_i(m), \quad m = 0, 1, \ldots, r$, es seleccionada al azar de entre dos correlaciones a saber: la primera

$$hcp_i(k) = \sum_{k=r}^{k=np} \widetilde{y}_{i-1}(k)\, u(k-m),$$

ó como la correlación de orden superior

$$hcp_i(m) = \sum_{k=r}^{k=np} u(k-a)\, u(k-m)\, \widetilde{y}_{i-1}(k) \pm kk\ \delta(m-k),$$

donde:

- el signo del término $\delta(m-k)$ es elegido aletoriamente.
- la constante a es seleccionada aleatoriamente entre $\{0, 1, \ldots, r\}$.
- el término kk se hace tender a cero a medida que la media cuadrática de los residuos tiende a cero $kk = \sum_{k=0}^{np} \widetilde{y}_{i-1}^2(k) \,/\, \sum_{k=0}^{np} \widetilde{y}_0^2(k)$.

4. Calcular $t_i(k) = \sum_{m=1}^{r} hcp_i(k)\, u(k-m), \quad k = 0, 1, \ldots, np.$

5. Luego se calcula al polinomio $p_i(\cdot)$ con entrada t_i que mejor ajusta a $\widetilde{y}_{i-1}$ sobre el intervalo $[0, 1, \ldots, np]$ con lo cual se determina la no linealidad en la cascada. Luego se puede evaluar la salida v_i, tomar $i = i + 1$ y volver al punto **1**.

Con este último caso se concluye con los métodos convencionales pasándose a describir a los esquemas no convencionales.

2.3.2 Esquemas No Convencionales.

Dentro de esta sección serán incluidos algunos de los modelos que utilizan redes para la identificación de sistemas. Dos modelos ampliamente utilizados que se ilustrarán son los casos de FIR y de IIR no lineales en los cuales las no linearidades son Perceptrones de una capa oculta. En forma anexa será presentado un caso de aproximación de la estructura interna de un sistama no lineal discreto con memoria evanescente, dado lo particular de la estructura resultante.

Redes Valores Retrasados.

Este caso es el conocido como FIR no lineal, que en el marco de las redes generalizadas corresponde al ilustrado por Figura 2.7b. Para este modelo Boyd y Chua [6], demostraron que cualquier operador no lineal discreto invariante en el tiempo y con memoria evanescente puede ser aproximado mediante una línea de retardo seguido de una transformacion no lineal sin memoria, es decir un polinomio. Sandberg [60] demostró que cualquier sistema no lineal discreto, invariante en el tiempo y con memoria aproximadamente finita, puede ser aproximado uniformemente por una línea de retardos seguido de un Perceptrón de una sola capa oculta. Mediante otras consideraciones, el mismo tipo de estructura fue desarrollado en base a diferentes suposiciones por Matthews [42]. Considérese al modelo con una sola entrada, una sola salida y longitud de memoria n_u. Luego $\mathbf{G}\left(q^{-1}\right) = R^{nu}\left(\cdot\right)$, donde $R^{nu}\left(\cdot\right)$ está expresado por 1.7, $\mathbf{N}_2 = \mathbf{I}$, es el operador identidad y un Perceptrón de *no* neuronas en la capa oculta:

$$\widetilde{y}\left(k\right) = \sum_{i=1}^{no} w2_i \phi\left(\mathbf{w1}^T \mathbf{u}_{nu}\left(k\right) + b1_i\right) + b2,$$

donde $\mathbf{u}_{nu}\left(k\right)$ está expresado por 1.8. Tambien puede ser expresado como

$$\widetilde{y}\left(k\right) = \mathbf{w}2\phi\left[\mathbf{W}1\ \mathbf{u} + \mathbf{b}i\right] + b2. \tag{2.10}$$

Este esquema de aproximación, si bien es intuitivamente simple desde el punto de vista conceptual, resulta de dificultosa concreción al estimar los parámetros de la red. Esto acontece cuando la memoria del sistema n_u es elevada. A continuación veremos el caso equivalente a un filtro ARMAX donde los regresores de entradas y salidas están

relacionades por un Perceptrón de una capa oculta.

Modelos NARMAX con Redes.

Este tipo de modelos, que fue presentado por Narendra y col. [50] consiste simplemente de líneas de retardo de la entrada y la salida como en un filtro ARMAX común solo que relacionadas no linealmente por un Perceptrón de una capa oculta. Este modelo corresponde a la estructura de la Figura 2.7c. Suponiendo regresores de la entrada de orden nu, de la salida de orden ny, y un Perceptrón de no neuronas en la capa oculta $\mathbf{G}_1\left(q^{-1}\right) = R^{nu}\left(\cdot\right)$, $\mathbf{G}_2\left(q^{-1}\right) = R^{ny}\left(\cdot\right)$

$$\widetilde{y}\left(k\right) = \sum_{i=1}^{no} w2_i \phi\left(\mathbf{w1}^T\left[\mathbf{u}_{nu}\left(k\right)^T \ \widetilde{\mathbf{y}}_{ny}\left(k\right)^T\right]^T + b1_i\right) + b2,$$

donde $\mathbf{u}_{nu}\left(k\right)$ está expresado por 1.8 y $\widetilde{\mathbf{y}}_{ny}$ por 1.11. También puede ser expresado como

$$\widetilde{y}\left(k\right) = \mathbf{w}2\phi\left[\mathbf{W}1 \ \left[\mathbf{u}_{nu} \ \widetilde{\mathbf{y}}_{ny}\right] + \mathbf{b}i\right] + b2.$$

Esta estructura, si bien es concisa en términos de la descripción lograda, conserva problemas de estabilidad para su ajuste debido a la realimentación presente [50]. La próxima sección muestra un modelo de la representación interna de sistemas con memoria evanescente.

Representación Interna de Esquemas de Memoria Evanescente.

El esquema de aproximación que será ilustrado a continuación difiere de la filosofía de los esquemas entrada-salida que han sido presentados en esta sección, sin embargo se incluye por la forma simple que adopta su estructura. Para aproximar la representación interna de un sistema no lineal discreto, invariante al desplazamiento y que posea memoria evanescente, es suficiente utilizar la siguiente representación

$$\begin{array}{rl} \mathbf{x}\left(k+1\right) = & \phi\left[\mathbf{A}\mathbf{x}\left(k\right) + \mathbf{B}\mathbf{u}\left(k\right)\right] \qquad k \in \mathbb{Z}^+ \\ \mathbf{y}\left(k\right) = & \mathbf{C}\mathbf{x}\left(k\right) \end{array}, \tag{2.11}$$

donde $\mathbf{x}\left(k\right) = \left[x_1\left(k\right), x_2\left(k\right), \cdots, x_n\left(k\right)\right]$, representa a los n estados; $\mathbf{u}\left(k\right) = \left[u_1\left(k\right), u_2\left(k\right), \cdots, u_p\left(k\right)\right]$, a las p entradas e $\mathbf{y}\left(k\right) = \left[y_1\left(k\right), y_2\left(k\right), \cdots, y_m\left(k\right)\right]$ a las m salidas. Las ma-

trices de las estructura se muestran como $\mathbf{A} : \mathbb{R}^n \times \mathbb{R}^n$, $\mathbf{B} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ y $\mathbf{C} : \mathbb{R}^n \rightarrow \mathbb{R}^m$. Este esquema puede ser notado en el marco de las redes generalizadas, coincidiendo con el esquema que muestra la Figura 2.7d, para $\mathbf{N}_1[\cdot] = \phi$, $\mathbf{N}_2[\cdot] = \mathbf{B}$, $\mathbf{N}_3[\cdot] = \mathbf{A}$, $\mathbf{N}_4[\cdot] = \mathbf{C}$, $\mathbf{G}(\mathbf{q^{-1}}) = q^{-1}\mathbf{I}$. Sin embargo, más alla de la simple estructura de aproximación resultante, este modelo conserva las dificultades encontradas en las redes recurrentes: dificultad en asegurar la estabilidad, y algoritmos de entrenamiento difíciles de implementar. En [42] se propone un algoritmo recursivo para estimar los parámetros de 2.11, demostrándose que si los autovalores de la matriz $\mathbf{A}$ son menores que 1($\text{eig}(\mathbf{A}) < 1$) el sistema es estable. Sin embargo son conocidos los inconvenientes que presenta para un algoritmo de estimación recursivo tener que calcular los autovalores de una matriz. Este hecho impone una restricción severa en término de los cálculos involucrados.

Han sido presentados diversos casos de esquemas de aproximación que utilizan redes y de tipo convencional. En la siguiente sección será tratado el caso de la estructura LNet.

2.4 Estructura LNet.

En esta sección se ilustrará sobre las ventajas que surgen de utilizar un Perceptrón de una capa oculta en la estructura LNet en lugar de otros aproximadores como podrían ser, por ejemplo polinomios. La clase de modelos que utilizan polinomios en sus estructuras es conocida en la bibliografía como *filtros polinomiales* [43], [26], siendo el modelo de la serie de Wiener 2.9 un ejemplo típico. La Figura 2.9 muestra el esquema de una realización del método de las serie de Wiener para sistemas no lineales continuos. Como fuera mencionado en secciones previas, determinadas estructuras de aproximación que utilizan redes provienen de modificar modelos preexistentes. La Figura 2.12 muestra a un esquema de la estructura LNet, donde se puede apreciar que existe un conjunto de sistemas de Laguerre al igual que en la estructura de la Figura 2.9. Sin embargo, ambas estructuras se diferencian en la manera en que dichos sistemas están relacionados en forma no lineal. En la estuctura de Wiener de la Figura 2.9 dicha relación es llevada a cabo por un conjunto de polinomios de Hermite. La Figura 2.12 representa la combinación no lineal de m sistemas de Laguerre 1.15 mediante un Perceptrón de *no* neuronas en su

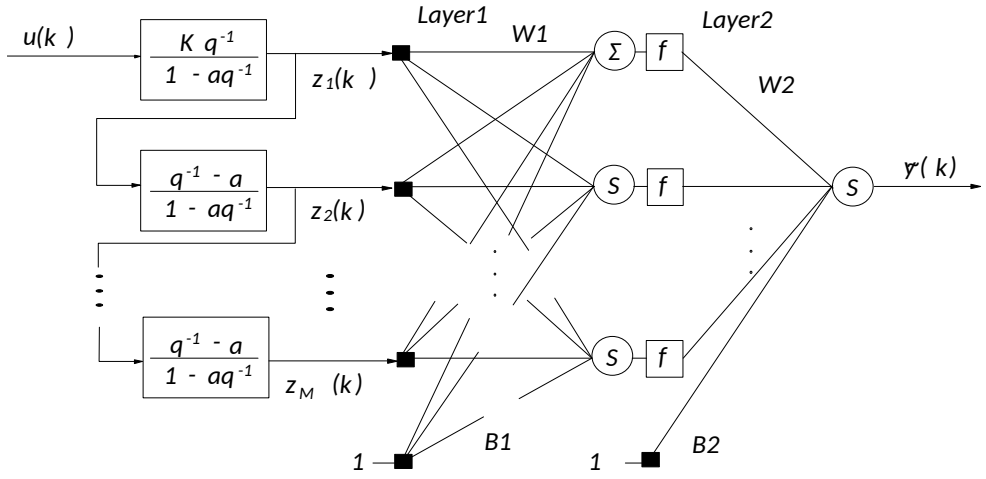


Figura 2.12: Estructura LNet

única capa oculta. La salida $\widetilde{y}(k)$ es

$$\widetilde{y}(k) = \sum_{i=1}^{no} w2_i \phi\left(\mathbf{w}1_i^T \mathbf{u}_L(k) + b_i\right) + b2,$$

donde $\mathbf{u}_L(k)$ está indicado por 1.32. Una forma alternativa más compacta de expresar a la anterior ecuación resulta en

$$\widetilde{y}(k) = \mathbf{w}2\phi\left(\mathbf{W}\mathbf{1}^T \mathbf{u}_L(k) + \mathbf{b}\right) + b2.$$

El Perceptrón de una única capa oculta resulta ser el elemento característico de la estructura LNet. Su utilización se justifica por varias de las ventajas que presenta la estructura desarrollada sobre los filtros polinomiales. La estructura LNet aventaja a los filtros polinomiales en aspectos relacionados con la estabilidad, la cantidad de términos necesarios para realizar una dada aproximación y la capacidad de generalización. Estos factores se detallarán a continuación.

Enunciado 1. *Supongamos que se desea aproximar a una función dada* $g{:}\mathcal{C}(\mathbf{U}) \to \mathbb{R}$ *sobre el dominio compacto* $\mathbf{U} \subset \mathbb{R}^m$ *mediante* g_n *un polinomio homogéneo de orden* n *y mediante un Perceptrón de una capa oculta* g_{no} *con* no *neuronas. Con la red neuronal* g_{no} *se obtendrá un error de aproximación integral de* $O(1/no)$ *utilizando una cantidad de parámetros de* $O(m\,.\,no)$*. Con el polinomio* g_n *se obtendrá un error de aproximación integral de* $O\left(1/n^{2/m}\right)$ *utilizando una cantidad de parámetros de* $O(n^m)$*. Esto demuestra*

el hecho ventajoso de aproximar funciones con redes cuando la dimensión del espacio $\mathbf{U}$ *involucrado es* $m \geq 3$.

Este hecho fue demostrado por Barron [3] para funciones $g \in C(\mathbf{U})$, $g : \mathbf{U} \to \mathbb{R}$, $C(\mathbf{U})$ espacio de funciones continuas que toman valores en el dominio compacto $\mathbf{U} \subset \mathbb{R}^m$, y que presentan ciertas condiciones de suavidad. Concretamente estamos interesados en aproximar dichas funciones g mediante polinomios g_n de orden n y mediante g_{no} un Perceptrón de una capa oculta con *no* neuronas. Para facilitar la comparación utilizaremos una notación que permita expresar conjuntamente tanto a polinomios como a redes. Sean por lo tanto $g_a : \mathbf{U} \to \mathbb{R}$ los aproximadores de la forma

$$g_a(\mathbf{u}) = \sum_{i=0}^{nt} a_i \Psi_i(\mathbf{u}), \tag{2.12}$$

donde tanto$\Psi_i(\cdot)$, las funciones bases con que se realiza la aproximación, como n_t dependen del tipo de aproximador que se está utilizando. En el caso de los polinomios al subíndice i le será asociado un índice multiple $[i_1, i_2, \ldots, i_m]$, para expresar a la potencias involucradas, de la siguiente forma

i	$[i_1, i_2, \ldots, i_{m-1}, i_m]$
0	$[0, 0, \ldots, 0, 0]$
1	$[1, 0, \ldots, 0, 0]$
2	$[0, 1, \ldots, 0, 0]$
$\vdots$	$\vdots$
$nt-1$	$[0, 0, \ldots, n, 0]$
nt	$[0, 0, \ldots, 0, n]$

con la restricción usual de que $i_1 + i_2 + \ldots + i_m \leq n$. Tomando en cuenta la entrada $\mathbf{u} = [u_1\, u_2 \ldots u_m]^T$ y en base al índice múltiple $[i_1, i_2, \ldots, i_m]$ las funciones base toman la forma

$$\Psi_i(\mathbf{u}) = (u_1)^{i_1} (u_2)^{i_2} \ldots (u_m)^{i_m}, \tag{2.13}$$

donde $(u_j)^{i_s}$ define a la componente $j-$*ésima* de la entrada elevada a la potencia i_s-*ésima*. Luego $\Psi_0(\mathbf{u}) = 1$, $\Psi_1(\mathbf{u}) = u_1, ...,$ $\Psi_{nt}(\mathbf{u}) = (u_m)^{i_s}$ de forma tal que los polinomios ho-

mogéneos g_n de orden n pueden ser expresados como

$$g_n(\mathbf{u}) = \sum_{i=0}^{nt} a_i \Psi_i(\mathbf{u}),$$

donde $a_i \in \mathbb{R}$ son los coeficientes del polinomio y

$$nt = \sum_{i=0}^{n} \binom{m-i+1}{i}. \tag{2.14}$$

La ecuación 2.14, donde $\binom{\cdot}{\cdot}$ representa la operacion combinatoria, muestra la variación exponencial en la cantidad de términos producida en un polinomio respecto del orden n y de la dimensión m.

En el caso de los Perceptrones de una capa oculta, las funciónes base toman la forma

$$\Psi_i(\mathbf{u}) = \phi\left(\mathbf{w1}_i^T \mathbf{u} + b_i\right), \tag{2.15}$$

donde $\mathbf{w1}_k \in \mathbb{R}^m$, $b_k \in \mathbb{R}$ con la función de activación $\phi(s)$ tal que $\phi(s) \to 1$ cuando $s \to \infty$ y $\phi(s) \to 0$ cuando $s \to -\infty$. El aproximador en este caso puede ser expresado como

$$g_{no}(\mathbf{u}) = \sum_{i=0}^{no} w2_i \Psi_i(\mathbf{u}),$$

donde $w2_k \in \mathbb{R}$ son los pesos de la capa de salida.

Las funciones $g : \mathbf{U} \to \mathbb{R}$ deben además cumplir ciertas condiciones de suavidad definidas a través de su transformada de Fourier:

$$\left.\begin{array}{ll} g(\mathbf{u}) & = \int_{\mathbb{R}^m} e^{j\omega^T \mathbf{u}} \widetilde{g}(\omega)\, d\omega \\ \widetilde{g}(\omega) & = (2\pi)^{-m} \int_{\mathbb{R}^m} e^{-j\omega^T \mathbf{u}} g(\mathbf{u})\, d\omega \end{array}\right\}, \tag{2.16}$$

donde la función compleja $\widetilde{g}(\omega)$ es la transformada de g, siendo $\omega = (\omega_1, \omega_2, \cdots, \omega_m)$ el vector de las frecuencias. La condición de suavidad de g es caracterizada por la propiedad:

$$C_g = \int_{\mathbb{R}^m} \|\omega\| \, |\widetilde{g}(\omega)| \, d\omega < \infty, \tag{2.17}$$

donde $\|\omega\| = \left(\omega^T \omega\right)^{1/2}$. Supongamos que se elije al espacio compacto $\mathbf{U}$ como la bola $\mathbf{B}_r = \{\mathbf{u} : \|\mathbf{u}\| \leq r, r > 0\}$. La condición 2.17 que impone que C_g sea finito implica la

integrabilidad del gradiente de la función g. Denominaremos $\Gamma_{\mathbf{B}_r}$ al conjunto de funciones g con un gradiente integrable y una extensión continua del gradiente de $\mathbf{B}_r$ hacia $\mathbb{R}^m$. Luego es válido el siguiente teorema.

Teorema 2 (Barron, 1993). *Para cada función g en $\Gamma_{\mathbf{B}_r}$, cada función sigmoidal ϕ, cada medida de probabilidad μ, y cada $no \geq 1$, existe una combinación lineal de funciones sigmoidales $g_{no}(\mathbf{u})$, de la forma mostrada en 2.4, tal que*

$$\int_{B_r} \left(g(\mathbf{u}) - g_{no}(\mathbf{u})\right)^2 \mu(d\mathbf{u}) \leq \frac{(2rC_g)^2}{no}.$$

Si la medida de Lebesgue[4] es utilizada como medida de probabilidad μ, se obtiene el sorprendente resultado de que la relación de aproximación conseguida es independiente de la dimensión m, utilizando un número de parámetros $O(m\,.\,no)$, el cual crece solo linealmente con m. Esto contrasta con el número exponencial $O(n^m)$ de parámetros requeridos por métodos como los polinomios tradicionales (ver ecuación 2.14), splines y expansiones en series para alcanzar una relación de aproximación no menor de $O\left(1/n^{2/m}\right)$ (ver [3]). *El factor $(\cdot)^{2/m}$, que funciona como el "curso de la dimensionalidad" en los polinomios, no se encuentra en las redes.* Solo si se asume un alto grado de suavidad en las funciones involucradas, es decir si $\int \|\omega\|^m |g(\omega)|^2 d\omega < \infty$ se pueden lograr para estos aproximadores el mismo orden de aproximación que las redes, pero a expensas de utilizar del orden de $O(n^m)$ parámetros. Lo que muestra una gran ventaja al aproximar con redes dado su gran economía de términos utilizados para el caso de dimensiones $m \geq 3$, como lo demuestra el teorema anterior. Una situación más usual en la problemática de aproximar funciones, resulta ser aquella en la que solo se conocen np valores de la función $g(\cdot)$. Es decir, se dispone de los valores de $g(\mathbf{u}_i)$, para $\mathbf{u}_i \in B_r, i : 1, .., np$. En este caso el teorema anterior especifica la siguiente cota

$$\frac{1}{np} \sum_{i=1}^{np} \left(g(\mathbf{u}_i) - g_{no}(\mathbf{u}_i)\right)^2 \leq \frac{(2rC_g)^2}{no}, \tag{2.18}$$

[4]De funciones medibles solo se necesita conocer esta simple definición dado que merece un tratado en sí mismo.

Definición 1 (Función Medible:). *Diremos que una función $f : R_+ \to R$ es medible si y sólo si $f(u)$ es el límite de una función escalera o constante a tramos para todo u excepto para aquellos u que pertenecen a un conjunto de medida nula ([74, pag. 271]).*

para el error de aproximación [3]. Una explicación que parece razonable a los efectos de ilustrar tal comportamiento, radica en que las redes pueden modificar las funciones base con que realizan la aproximación, de acuerdo a las características de la misma función a aproximar. El siguiente ejemplo busca aclarar tal punto.

Ejemplo 2. *Es fácil apreciar que las funciones* $\Psi_i(\mathbf{u})$ *de la ecuación 2.15 pueden adaptarse a la forma de la función a ser aproximada variando los parámetros* $\mathbf{w1}_k$ *y* b_k*. Este comportamiento difiere del encontrado en los polinomios, donde estas funciones base son tomadas de un conjunto que permanece fijo. Sea por ejemplo los polinomios en* $\mathbb{R}$ *de orden n para el cual el conjunto de funciones base de la ecuación 2.13 está constituído por*

$$\left\{\Psi_i(u)\right\}_{i=0}^{n} = \left\{1, u, u^2, ..., u^n\right\}.$$

Es fácil ver que para dichas funciones no es posible cambiar su forma. Si en cambio se considera a un Perceptrón de una sola capa oculta con no neuronas el conjunto de las funciones base de acuerdo a la ecuación 2.15 sería

$$\left\{\Psi_i(u)\right\}_{i=0}^{no-1} = \left\{\phi(w1_0 u + b_0), \phi(w1_1 u + b_1), \ldots, \phi(w1_{no-1} u + b_{no-1})\right\},$$

donde $\phi(\cdot)$ *es una sigmoide. La Figura 2.13 ilustra como es posible variar la forma de las funciones* Ψ_i *ajustando los parámetrors* $w1_i$*,* b_i*. Es quizás la posibilidad de ajustar su forma respecto a función a aproximar el elemento que brinda tal flexibilidad a las redes.*

■

Cabe destacar que el efecto de la dimensión, puede reflejarse indirectamente a través de la constante C_g, ya que esta involucra una integral en m dimensiones. En estos casos se obtiene una relación en la cual la dimensión m interviene exponencialmente a través de la integral. Comparativamente, para este mismo caso la cantidad de términos para un polinomio sería mucho mayor: sería superexponencial. Este efecto que en una red neuronal puede ser subsanado agregando una capa oculta extra, no tiene forma de ser atemperado en un polinomio. En [24] se muestra que ciertos problemas que requieren de una cantidad exponencial de términos para una red de una única capa oculta, pueden ser resueltos por una red de dos capas ocultas con un número polinomial de términos. Sin embargo este tópico, si bien ampliamente conocido en forma experimental, aún requiere una demostración rigurosa. Continúa siendo completamente oscuro reconocer cuando es

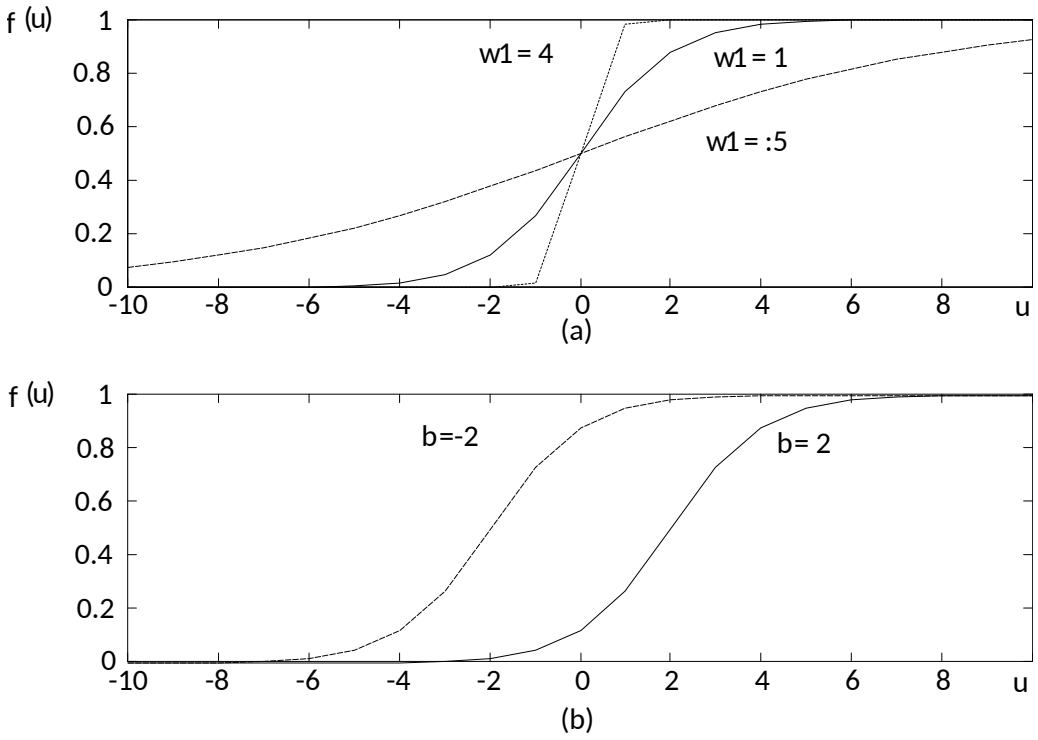


Figura 2.13: Sigmoide para Diversos Parámetros a) $b = cte$. b) $w1 = cte$.

ventajoso utilizar una red con una, dos o más capas ocultas.

Enunciado 2. *Cuando se utilizan polinomios para aproximar a una función no es fácil tratar con la estabilidad numérica aún para espacios de dimensiones moderadas. Adicionalmente los polinomios presentan comportamientos patológicos en el sentido de que si una señal se encuentra fuera del compacto donde se realiza la aproximación, esta puede ser amplificada en forma desmesurada.*

Supongamos que se desea realizar el ajuste de una funcion $g : \mathbf{U} \to \mathbb{R}$, sobre el compacto $\mathbf{U} \subseteq \mathbb{R}^3$, mediante un polinomio de orden 10. Es fácil apreciar que aún para este espacio de dimensión 3, se necesitarían alrededor de 3^{10} coeficientes, con lo cual la matriz de datos requerida para realizar el ajuste está normalmente mal condicionada. Esto produce graves efectos en la estabilidad de los métodos numéricos utilizados para el cáculo de los coeficientes.

La característica de los filtros polinomiales resulta ser justamente la utilización de un polinomio. Más allá del número desmesurado de parámetros requeridos para efectuar una buena aproximación de un sistema de memoria evanescente, en un filtro polinomial la salida crece sin límite para entradas fuera del conjunto compacto $\mathbf{U}$ donde la

aproximación está definida. En la mayoría de los sistemas de la naturaleza, se encuentra algún mecanismo de saturación por el cual sobre un determinado nivel de la entrada, las salidas no cambian de valor. Dicho comportamiento que está presente en los aproximadores con redes, dado que las funciones de activación producen una saturación luego de un determinado nivel de las entradas, es inexistente en los filtros polinomiales. En otras palabras, señales de entrada que se encuentran fuera de $\mathbf{U}$ (denominado también dominio de generalización), son amplificadas desmesuradamente por el filtro polinomial debiendo ser recortadas o bien a la entrada o bien a la salida [42]. En [26] se presenta una aplicación donde se resalta el problema de la estabilidad al que se le da una solución mediante la utilización de una sigmoide a la salida del modelo polinomial, lo que lo asemeja más a una red que a un polinomio. Las propiedades algebraicas de los sistemas polinomiales fueron estudiadas por Sontag [70]. Desafortunadamente los modelos polinomiales no son inherentemente estables y no existe un criterio general de estabilidad para dichos filtros. Asegurar la estabilidad es esencial para la implementación de los algoritmos de estimación de parámetros en línea.

Enunciado 3. *En los polinomios es más difícil tratar el fenómeno de sobreajuste de los parámetros, a diferencia de lo que ocurre en las redes para las cuales existen ciertos mecanismos para morigerar este efecto indeseado.*

Sea el caso de estimar mediante muestras una función continua $y = g(\mathbf{u})$, $g : \mathbf{U} \to \mathbb{R}$ que toman valores en el dominio compacto $\mathbf{U} \subset \mathbb{R}^m$. Se dispone de dos conjuntos de pares de datos disjuntos α y β con realización en $\mathbf{U}$, es decir

$$\alpha : \{(\mathbf{u}_i, y_i) | \, \mathbf{u}_i \in \mathbf{U}, y_i = g(\mathbf{u}_i), \; i : 1, .., n1\}, \tag{2.19}$$

denominado de entrenamiento y

$$\beta : \{(\mathbf{u}_i, y_i) | \, \mathbf{u}_i \in \mathbf{U}, y_i = g(\mathbf{u}_i), \; i : 1, .., n2\}, \tag{2.20}$$

denominado de prueba. En el caso típico de estimación de funciones el conjunto α se utiliza para realizar el ajuste de parámetros del estimador y el conjunto β se dispone para verificar la generalización del estimador. El fenómeno de sobreajuste (conocido en inglés como "overfiting") se manifiesta en la medida en que el modelo obtenido repreduce fielmente el conjunto α de datos de entrenamiento y muy mal al conjunto de prueba

β. La Figura 2.14 muestra a una función continua representada por la curva **c,** de la que se dispone un conjunto de datos (puntos negros) para realizar la aproximación y dos estimaciones distintas representadas por las curvas **a** y **b.** La curva denominada **a** pasa exactamente por los datos mostrando un comportamiento oscilatorio en el resto del dominio. Dicha curva *interpola* a los datos mostrando claramente un caso de sobreajuste. En cambio la curva **b**, es más suave y aún sin pasar exactamente por los puntos *aproxima* a la totalidad de la curva.Como se mostrará en el transcurso de la tesis, existen

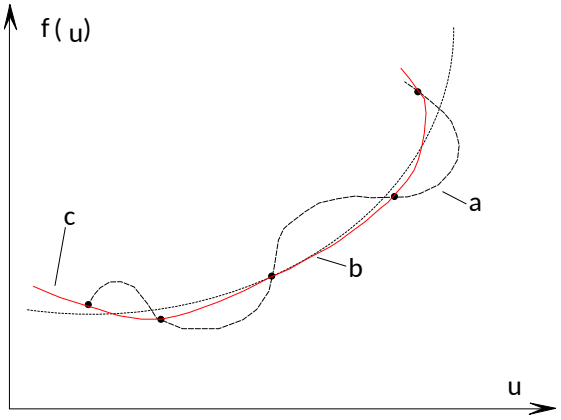


Figura 2.14: Interpolación y Aproximación.

mecanismos varios que sirven para evitar el sobreajuste de los parámetros en redes, que no están disponibles para los polinomios.

2.5 Conclusiones.

En este capítulo han sido presentadas varias estructuras de aproximación entrada-salida, basadas tanto en modelos convencionales como en redes neuronales. Fueron definidos los conceptos de neurona, capa y topología conjuntamente con un marco general para especificar sistemas no lineales discretos que incluyan redes neuronales. Se ilustró respecto de la conveniencia de utilizar redes neuronales como aproximadores universales de funciones no lineales en lugar de otros tipos de aproximadores como los polinomios. En el próximo capítulo serán tratados temas teóricos concernientes a las capacidades de aproximación de la estructura propuesta.

Capítulo 3

LNet: una Estructura para Aproximar Sistemas No Lineales Discretos.

En este capítulo se demuestra que la estructura LNet es capaz de aproximar operadores no lineales, discretos, invariantes en el tiempo y que poseen memoria evanescente. Un sistema puede ser considerado como un operador que transforma una secuencia de entrada en una secuencia de salida. De forma tal que el operador aproximado es aquel que representa el comportamiento entrada-salida del sistema.

El desarrollo del presente capítulo comienza con las definiciones de rigor, para proseguir con una breve discusión sobre operadores y funcionales, lo que permite asimilar el concepto de memoria evanescente. Continúa con la presentación del teorema de aproximación de la estructura LNet, el cual para ser demostrado utiliza una variación del Teorema de Stone-Weierstrass y tres lemas adicionales. Luego de la demostración del teorema que enuncia las capacidades de aproximación de la estructura LNet, concluye el capítulo con una discusión de los resultados y un resumen de lo visto.

3.1 Introducción.

En esta sección se harán precisos los conceptos necesarios para enunciar las capacidades de aproximación de la estructura LNet esquematizada en la Figura 2.12. Dicha estructura permite aproximar la representación externa de un sistema caracterizado por un operador entrada-salida. Procediendo de forma tal, es posible aproximar operadores no lineales discretos, invariantes en el tiempo, y que poseen memoria evanescente. La

prueba de los resultados obtenidos hace uso del concepto de memoria evanescente. Formalmente introducido por Boyd y Chua [6], ha sido utilizado con diversos objetivos en varios campos del conocimiento. Por ejemplo, en [66] se usa una versión modificada del teorema de pequeña ganancia y del concepto de ganancia asintótica de sistemas con memoria evanescente, para establecer condiciones necesarias y suficientes de invertibilidad sobre ciertos operadores de realimentación. Partiendo de premisas semejantes, en [67] se establecen condiciones de estabilidad robusta en sistemas realimentados, lineales y no lineales, con memoria evanescente. Relacionado con redes neuronales, permite el desarrollo de algoritmos de identificación recursivos para las representaciones internas y externas de sistemas no lineales como en [42]. En [16] se caracteriza y define a un conjunto especial de entradas que permite minimizar el peor caso del error de aproximación en la identificación de sistemas con memoria evanescente. Relacionado con la identificación de sistemas lineales variantes en el tiempo y con memoria evanescente, en [56] se demuestran varios postulados respecto de la convergencia en norma, puntual y asintótica de los operadores involucrados. Se mostrará que el concepto de memoria evanescente se puede asimilar a una modificación del concepto de continuidad del operador que se desea aproximar. Se obtiene como resultado que si un operador tiene memoria evanescente esto implica la continuidad de dicho operador. Sin embargo que un operador sea continuo no implica que dicho operador tiene memoria evanescente, lo cual será ilustrado mediante el ejemplo de un operador retenedor de pico máximo. Para ser más preciso son necesarias algunas definiciones y notación extra.

3.1.1 Notación, Definiciones y Comentarios Previos.

El conjunto $\mathbb{Z}$ notará a los enteros, los cuales son distinguidos entre enteros positivos $\mathbb{Z}_+$ y los enteros no positivos $\mathbb{Z}_-$ incluyendo al 0. Como espacio de trabajo se selecciona a l^∞, que representa al espacio de secuencias acotadas, es decir funciones $\mathbb{Z}\to\mathbb{R}$, provisto con la norma del supremo:

$$\|u\|_\infty \triangleq \sup_k |u(k)| .$$

Por lo tanto un elemento $u \in l^\infty$ es una secuencia de números reales tales que $|u(k)| < m_1$, $k \in \mathbb{Z}$ con $m_1 > 0$. La noción de tiempo en las secuencia será expresada en una

forma ligeramente diferente a lo habitual, lo cual permite formular ciertos conceptos con mayor facilidad. Así, una secuencia u que toma valores para $k < 0$, representa a eventos del pasado, mientras que $k > 0$ expresa eventos del futuro, concluyendo lógicamente que el presente está expresado por el elemento $u(0)$ como lo muestra la siguiente tabla.

Tiempo Pasado	*Tiempo Presente*	*Tiempo Futuro*
enteros negativos	0	enteros positivos

El espacio $l^{\infty}(\mathbb{Z}_{-})$ representa a la restricción de l^{∞} para los valores de enteros no positivos. Luego una secuencia $u \in l^{\infty}(\mathbb{Z}_{-})$ representa: desde los eventos acontecidos en un pasado remoto (indicado por $k \to -\infty$), hasta lo que sucede en el presente ($k = 0$). Sin embargo no contiene información sobre sucesos futuros ($k > 0$). A continuación definiremos dos funciones, relevantes para la exposición, que utilizan secuencias como operandos: funcionales y operadores.

Definición 2 (*Funcional*)**.** *Será denominada* funcional*, a toda función* $F : l^{\infty}(\mathbb{Z}_{-}) \to \mathbb{R}$ *que transforma a una secuencia de* $l^{\infty}(\mathbb{Z}_{-})$ *en un número real.*

Definición 3 (*Operador*)**.** *Será denominado* operador *a toda función* $N : l^{\infty} \to l^{\infty}$*, que transforma a una secuencia de* l^{∞} *en otra secuencia de* l^{∞}*.*

Usualmente no serán utilizados los corchetes en los argumentos de funcionales y operadores siempre que en el contexto no se confunda su significado. De forma tal que se notará Fu en lugar de $F[u]$ (un número) y $Nu(k)$ por $N[u](k)$ (una secuencia en el instante de tiempo k). Es fácil ver que un sistema puede ser representado por un operador, en la forma indicada por la siguiente definición.

Definición 4 (*Sistema*)**.** *Un* sistema *queda definido matemáticamente por una función u operador N que transforma una secuencia de entrada u, en una secuencia de salida y [53]. Este hecho, representado esquemáticamente en la Figura 1.1, será notado como* $y(k) = N[u](k)$.

Estamos interesados en la capacidad de la estructura LNet de aproximar operadores $N : l^{\infty} \to l^{\infty}$, no lineales, invariantes en el tiempo y causales. Dichos operadores representan al comportamiento entrada-salida del sistema, transformando secuencias de

entrada acotadas en secuencias de salida acotadas (sistemas BIBO[1] estables). Estos conceptos serán clarificados brindando las correspondientes definiciones, las cuales pueden ser halladas en [53].

Definición 5 (*Invariancia en el Tiempo*). *Un operador N que transforma a la secuencia $u(k)$ en $y(k)$ se dice invariante al desplazamiento, si para todo entero τ, $y(k-\tau)$ es igual a la trasformación de $u(k-\tau)$. Cuando el índice k se refiere al tiempo, hablamos de invariancia en el tiempo. Consecuentemente un operador es* invariante en el tiempo *si $q^{\tau}N = Nq^{\tau}$ para todo $\tau \in \mathbb{Z}$, donde q^{τ} es el operador retardo definido por la ecuación 1.6.*

Definición 6 (*Causalidad*). *En un sistema causal la salida para cualquier instante de tiempo $k = k_o$ depende solamente de la evolución de la entrada para todo tiempo $k \leq k_o$. En términos coloquiales esto significa que el presente no depende del futuro. Entonces diremos que el operador N es* causal, *si dado $u(k) = v(k)$, $k \leq k_o$, implica que $Nu(k) = Nv(k)$, para $k \leq k_o$.*

Definición 7 (*Secuencia Causal*). *Extendiendo la idea de causalidad a secuencias, diremos que una* secuencia u es causal *si toma valores solo para $k \leq 0$, es decir si $u \in l^{\infty}(\mathbb{Z}_{-})$.*

La definición anterior expresa que una secuencia causal no toma valores para $k > 0$, y dado que estamos interesados en operadores $N : l^{\infty} \rightarrow l^{\infty}$, resulta necesario definir una extensión no causal de una secuencia causal. Una posible forma de hacerlo, consiste en decir que todos los futuros valores de la secuencia son iguales al valor actual. Procediendo de manera tal que para toda secuencia causal $u \in l^{\infty}(\mathbb{Z}_{-})$ definiremos una extensión continua no causal $u_e \in l^{\infty}(\mathbb{Z})$ como

$$u_e(k) = \begin{cases} u(k), & k \leq 0 \\ u(0), & k > 0 \end{cases} . \tag{3.1}$$

El camino inverso, trocar una secuencia no causal en una casual, se realiza mediante el operador de truncamiento $P : l^{\infty}(\mathbb{Z}) \rightarrow l^{\infty}(\mathbb{Z}_{-})$ que trunca a un elemento $u \in l^{\infty}(\mathbb{Z})$ en

[1] BIBO: Bounded-Input-Bounded-Output.

otro elemento $l^{\infty}(\mathbb{Z}_{-})$ en la siguiente forma:

$$Pu(k) \triangleq \begin{cases} u(k), & \text{para } k \leq 0 \\ 0, & \text{para } k > 0 \end{cases} .$$

La Figura 3.1a muestra una secuencia causal con su correspondiente extensión no causal en el apartado (b), mientras que el apartado (c) ilustra como puede obtenerse la secuencia causal original mediante la utilización del operador de truncamiento P.

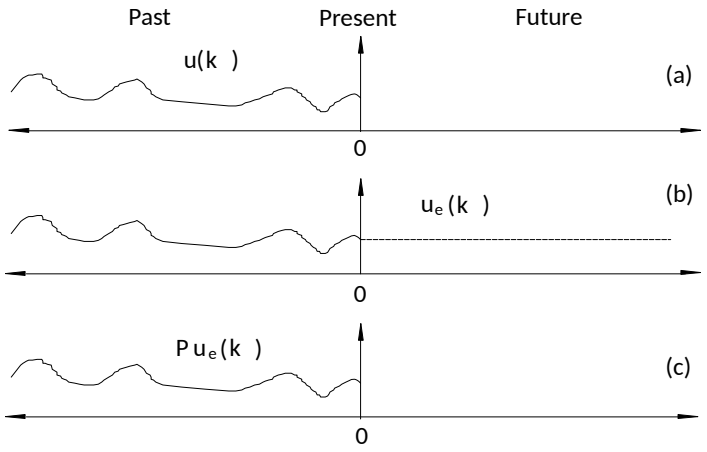


Figura 3.1: Secuencia Causal, su Extensión no Causal y uso del Operador de Truncamiento.

Hemos visto como un operador N puede representar el comportamiento entrada-salida de un sistema. Si además el operador N es invariante en el tiempo, es posible asociarle una funcional F en $l^{\infty}(\mathbb{Z}_{-})$ (como en [6]) definida como

$$Fu \triangleq Nu_e(0), \tag{3.2}$$

donde el valor u_e es la extensión no causal de u de la ecuación 3.1. Es fácil ver que el número $Nu_e(0)$ representa al valor actual de la salida del sistema, el cual es 0 por convención. Esta consideración permite interpretar que la funcional F transforma al *pasado de la entrada* u en la salida presente del sistema. Bajo esta óptica el operador N puede ser visto como una funcional que transforma al pasado de la entrada en la salida actual para cada instante de tiempo posible. Este consideración, plantea la posibilidad de reconstruir al operador N partiendo de su funcional F asociada. Para realizar dicha

reconstrucción se utiliza la siguiente relación

$$Nu\,(k) = FPq^k u, \tag{3.3}$$

mediante la cual se recupera al operador N a medida que la variables k toma valores distintos. A continuación presentaremos un ejemplo de un sistema lineal para clarificar estos conceptos, donde la Figura 3.2 ilustra al procedimiento de extensión de secuencias y la Figura 3.3 al procedimiento utilizado para recuperar a un operador de su funcional asociada.

Ejemplo 3. *La Figura 3.2 esquematiza: en (a), la secuencia de entrada $u\,(k)$; en (b), la secuencia $u_e\,(k)$ extensión no causal de $u\,(k)$; en (c), $Nu\,(k)$, la respuesta del sistema a la entrada $u\,(k)$ y en (d), $Nu_e\,(k)$ la respuesta a la entradas $u_e\,(k)$. El valor de Fu se muestra resaltado en el apartado (d).*

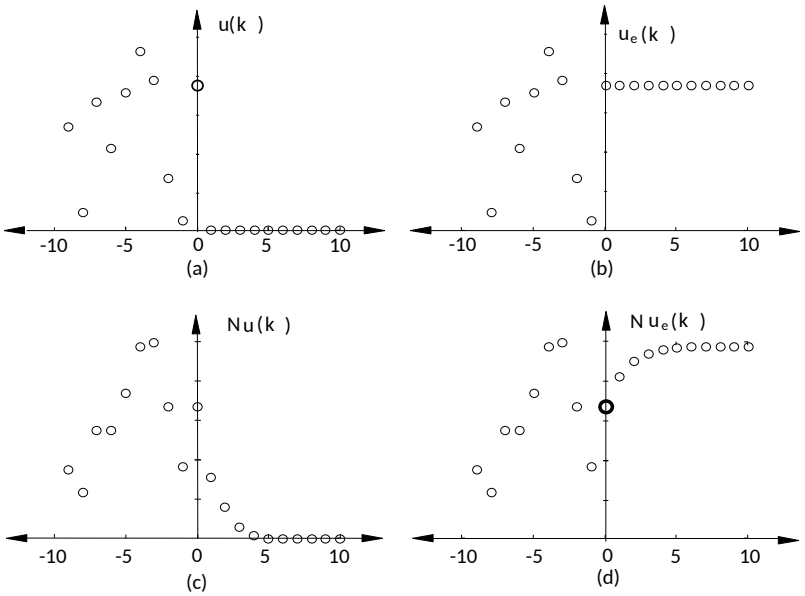


Figura 3.2: Secuencias Causal, Extendida y Respuestas Asociadas.

En la Figura 3.3 veremos como a partir del valor de la funcional F, es posible recuperar al operador N, lo cual será ejemplificado tomando el caso $k = -1$ en la ecuación 3.3. En el apartado (a) se observa la señal $u\,(k)$ afectada por q^{-1}, secuencia sobre la que actúa el operador de truncamiento P generando la secuencia $Pq^{-1}u\,(k)$ del apartado (b). La versión no causal $(Pq^{-1}u)_e\,(k)$ de la secuencia del anterior se puede observar en el apartado (c), mientras que el apartado (d), muestra al valor de la funcional deseado

$FPq^{-1}u$ (valor resaltado). Este proceso ha sido ilustrado par el valor $k = -1$. El operador N es recuperado de su funcional F repitiendo este procedimiento para cada k. ■

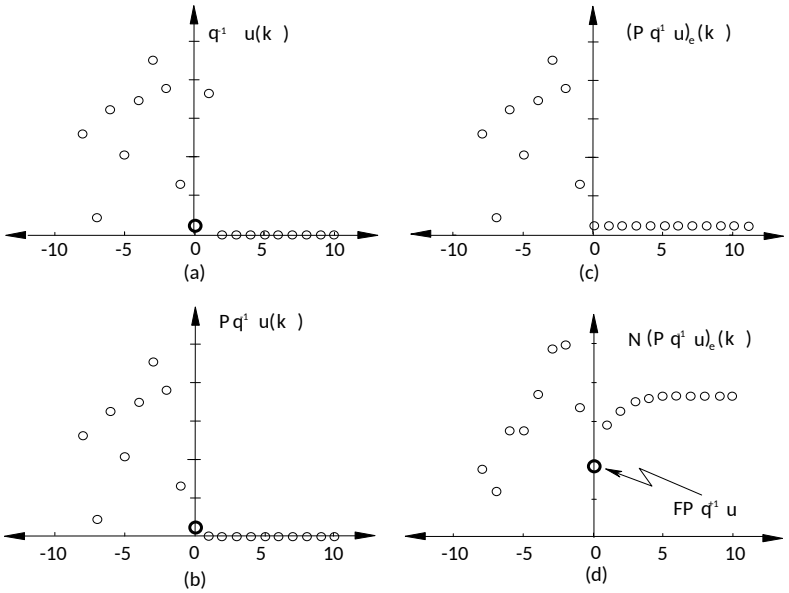


Figura 3.3: Reconstrucción del Operador N a Partir de su Funcional Asociada F.

Se ha visto la forma en que un operador representa a un sistema, se han definido sus propiedades y expresado la forma de asociar a cada operador una funcional y como recuperar al operador de su funcional asociada. En base a las definiciones y discusiones previas es posible expresar en una forma compacta la noción de continuidad y causalidad para un operador que es invariante en el tiempo:

Definición 8. *Un operador N invariante en el tiempo es causal y continuo si y sólo si para cada $u, v \in l^{\infty}(\mathbb{Z})$ y cada $\varepsilon > 0$, existe $\delta > 0$ tal que*

$$\sup_{k \leq 0} |u(k) - v(k)| < \delta \Rightarrow |Nu(0) - Nv(0)| < \varepsilon. \tag{3.4}$$

La definición anterior expresa que para un operador continuo la salida actual del sistema $Nu(0)$, depende continuamente de toda la historia previa de la entrada. Es decir que un suceso acontecido en su pasado remoto ($k \to -\infty$) afecta de igual manera a la salida actual, que un evento ocurrido en su pasado reciente (k cercanos a 0). Un circuito biestable es un ejemplo clásico de un sistema de este tipo: para conocer la salida actual, es necesrio conocer toda la secuencia de entrada y el estado inicial. Sin embargo la meta

última de toda teoría es explicar la realidad, y para una gran cantidad de sistemas reales la influencia del pasado de las entradas sobre la salida presente, disminuye a medida que se retrocede en el tiempo. Cuando se incorpora este concepto, se arriba naturalmente al tipo de sistemas que tienen memoria evanescente.

3.2 Memoria Evanescente.

Intuitivamente un operador tiene memoria evanescente si dadas dos señales de entrada que están cercanas en algún sentido en el pasado reciente (pero no necesariamente en su pasado remoto), producen salidas que en el presente se encuentran cercanas. El concepto de memoria evanescente expresa que a medida que se retrocede en el pasado ($k \to -\infty$), la influencia de la entrada $u(k)$ sobre la salida presente $Nu(0)$ *se hace despreciable o se evanesce*. Una forma de expresar este efecto consiste en generar una secuencia que decrezca a medida que k aumenta y que "pesa" distinto los efectos de la entrada sobre la salida de acuerdo al tiempo transcurrido. Procediendo de dicho modo, sea la secuencia decreciente $w : \mathbb{Z}_+ \to (0,1]$, con $\lim_{k\to\infty} w(k) = 0$ en base a la cual se define a la siguiente norma pesada

$$\|u\|_w \triangleq \sup_{k\leq 0} |u(k)|\, w(-k)\,. \tag{3.5}$$

Es fácil ver que el efecto práctico de la norma 3.5 es hacer *evanescer o desaparecer* a la entrada $u(k)$ cuando $k \to -\infty$. Con estos elementos se está en condiciones de definir al concepto de memoria evanescente.

Definición 9 (*Memoria Evanescente*)**.** *Un operador causal $N : l^\infty \to l^\infty$ tiene memoria evanescente en $\mathbf{K} \subset l^\infty$ si dado $\varepsilon > 0$ existen: 1) una secuencia decreciente $w : \mathbb{Z}_+ \to (0,1]$, con $\lim_{k\to\infty} w(k) = 0$ y 2) $\delta > 0$, tal que para cada $u, v \in \mathbf{K}$*

$$\sup_{k\leq 0} |u(k) - v(k)|\, w(-k) < \varepsilon \Longrightarrow |Nu(0) - Nv(0)| < \delta. \tag{3.6}$$

La definición anterior expresa conceptualmente como la salida del sistema es influenciada cada vez menos por señales remotas de la entrada. La *función de peso* $w(k)$ simula hacer desaparecer o evanescer al pasado remoto de la entrada hasta que en el límite lo anula. De la comparación de las ecuaciones 3.6 y 3.4 es fácil ver que si un operador tiene

memoria evanescente también es continuo, es decir que puede interpretarse a la memoria evanescente como a una forma más "física" de la continuidad. Sin embargo la recíproca no es válida como se muestra en el siguiente ejemplo de un operador que es continuo pero que no posee memoria evanescente.

Ejemplo 4 (*Operador Detector de Pico*)**.** *: Sea* $N_{dp} : l^{\infty}(\mathbb{Z}) \to l^{\infty}(\mathbb{Z})$, *el operador detector de pico definido como*

$$N_{dp}u(k) = \sup_{n \leq k} u(n),$$

lo que significa que retiene el valor de pico de la señal que ingresa. Es fácil ver que el operador N_{dp} *no tiene memoria evanescente, dado que independientemente de lo que suceda en su pasado, la salida mantiene al valor máximo de la señal de entrada. Suponiendo que la secuencia de entrada constara de un único valor distinto de cero, digamos* $u_0 = 1$, *la salida mantendría indefinidamente el valor* $N_{dp}u(k) = 1$. *Sin embargo el operador* N_{dp} *si es continuo, para lo que basta ver que para todo* $u, v \in l^{\infty}(\mathbb{Z})$

$$\|N_{dp}u - N_{dp}v\|_{\infty} \leq \|u - v\|_{\infty}.$$

Cabe aclarar que N_{dp} *opera sobre secuencias discretas a pesar de que la gráfica de la Figura 3.4 utiliza señales continuas por facilidad en su visualización.* ■

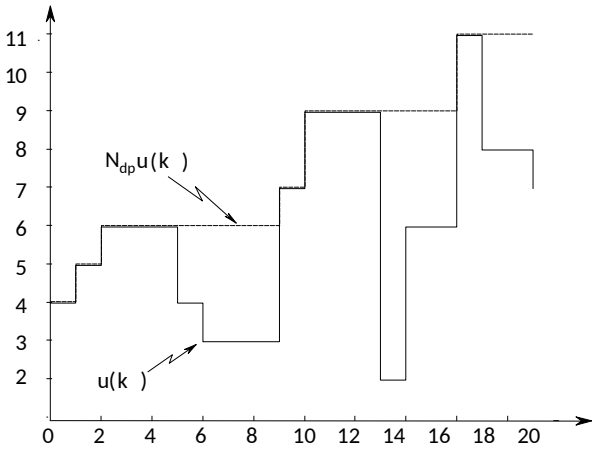


Figura 3.4: Operador Detector de Pico.

Hasta aquí han sido expuestos los conceptos y las definiciones necesarios para poder comprender las capacidades de aproximación de la estructura LNet, las cuales se

demuestran en un teorema de la siguiente sección.

3.3 Teorema de Aproximación de la Estructura LNet.

En esta sección se enunciará el teorema que establece las capacidades de aproximación de la estructura LNet. Una versión de dicho teorema fue preliminarmente demostrada por Sentoni y col. [65], siendo la versión completa la que se encuentra a continuación.

Teorema 3 (Estructura LNet). *Sea* $\mathbf{K}$ *una bola en* l^∞, $\mathbf{K} \triangleq \{u \in l^\infty \mid \|u\| \leq m_1\}$, *con* $m_1 > 0$, *y sea* $N : l^\infty \to l^\infty$ *cualquier operador invariante en el tiempo, causal y con memoria evanescente en* $\mathbf{K}$. *Entonces, existen un conjunto de* m *operadores de Laguerre* $\{L_0(\cdot), L_1(\cdot), \ldots, L_{m-1}(\cdot)\}$ *y un Perceptrón de una capa oculta* $NN(\cdot)$, *tales que para todo* $u \in \mathbf{K}$

$$\left\| Nu - \widetilde{N}u \right\| \leq \varepsilon,$$

donde $\widetilde{N}u$ *está dado por*

$$\widetilde{N}u(k) = NN(L_0u(k), L_1u(k), \ldots, L_{m-1}u(k)),$$

siendo $NN(\cdot)$ *un Perceptrón de una capa oculta de* m *entradas y no neuronas expresado por2.5 mientras que los sistemas de Laguerre se toman de acuerdo a 1.15.*

A continuación serán descriptos los pasos involucrados en la demostración del teorema LNet los cuales son esquematizados por la Tabla 3.1. Estamos interesados en demostrar que el operador LNet $\widetilde{N}$ es capaz de aproximar a cualquier operador N no lineal, invariante en el tiempo, causal y que posea memoria evanescente. Dicho operador N tiene una funcional asociada F, al igual que los operadores $L_i(\cdot)$ tienen sus correspondientes funcionales asociadas G_i. El punto 1) de la tabla indica el comienzo de la demostración, que se realiza utilizando una versión del Teorema de Stone-Weierstrass, el cual expresa que cualquier funcional F continua puede ser aproximada arbitrariamente bien en un espacio compacto[2] $\mathbf{E}$, por una combinación polinomial de un conjunto $\mathbf{G}$ de

[2] *Un espacio métrico* $\mathbf{E}$ *es compacto si y sólo si es totalmente acotado y completo* [31, Teorema 2, pag 100]. Por ser completo toda secuencia en $\mathbf{E}$ tiene límite Como consecuencia *un espacio métrico* $\mathbf{E}$ *es compacto* si y sólo si de toda secuencia infinita de $\mathbf{E}$, se puede extraer una subsecuencia que también

	Teorema Involucrado	Resultado Obtenido
1	*Teorema de Stone-Weierstrass*	$\left\|Fu - \widetilde{F}u\right\| \leq \varepsilon_1$
	1.1 *Lema I*	Compacidad de $\mathbf{K}_-$ con $\|u\|_w$
	1.2 *Lema II*	$\{G_i\}$ son continuas con $\|u\|_w$
	1.3 *Lema III*	$\{G_i\}$ separa ptos. en $l^\infty(\mathbb{Z}_-)$
2	*Teorema de Cybenko*	$\left\|Fu - \widetilde{F}u\right\| \leq \varepsilon_2$
3	*Recuperar al operador* $\widetilde{N}$	$\left\|\left\|Nu - \widetilde{N}u\right\|\right\| \leq \varepsilon$

Cuadro 3.1: Esquema de Teoremas y Resultados Involucrados en la Demostración del Teorema LNet.

funcionales continuas que separan puntos en dicho compacto. Para utilizar dicho teorema como herramienta es necesario demostrar previamente los lemas indicados en la tabla como 1.1, 1.2 y 1.3. los cuales establecen que: el espacio involucrado es compacto respecto de la norma $\|\cdot\|_w$(ver [6]), las funcionales G_i utilizadas separan puntos en $\mathbf{E}$ y que son continuas con respecto a $\|\cdot\|_w$.

Una vez demostrados estos tres lemas, se cumple con las hipótesis del Teorema de Stone-Weierstrass, por el cual se demuestra que la funcional $\widetilde{F}$ asociada al operador LNet $\widetilde{N}$, puede aproximar a cualquier funcional en el espacio compacto $\mathbf{E}$ mediante una combinación de sistemas discretos de Laguerre realizada por un polinomio $p(\cdot)$.

Este punto de la demostración está indicado por el item 2) de la Tabla 3.1. Haciendo uso del teorema 1, se muestra que a su vez ese polinomio $p(\cdot)$, puede ser aproximado por una red neuronal $NN(\cdot)$.

En este punto, indicado como 3) en la Tabla 3.1, se está en condiciones de culminar la demostración recuperando al operador LNet $\widetilde{N}$ de su funcional asociada mediante la ecuación 3.3. La Tabla ayuda a seguir la demostración indicando qué teorema se utiliza y qué resultado es obtenido, por lo tanto comencemos entonces enunciando el Teorema de Stone-Weierstrass.

converge en $\mathbf{E}$.

Ejemplo: un subconjunto M del espacio R^n es compacto si es cerrado y acotado.

3.3.1 Teorema de Stone-Weierstrass.

Teorema 4 (*Stone-Weierstrass*). *Sea* $\mathbf{E}$ *un espacio métrico compacto y sea* $\mathbf{G}$ *un conjunto de funcionales continuas en* E *que separan puntos, es decir que para cualquier* $u, v \in \mathbf{E}$ *existe* $G \in \mathbf{G}$ *tal que* $Gu \neq Gv$. *Entonces dados* $\varepsilon > 0$ *y cualquier funcional continua* F *en* $\mathbf{E}$, *existen un polinomio* $p : \mathbb{R}^m \to \mathbb{R}$ *y funcionales* $\{G_1, G_2, \cdots, G_m\} \in \mathbf{G}$ *tales que para todo* $u \in \mathbf{E}$

$$|Fu - p(G_1 u, G_2 u, \cdots, G_m u)| < \epsilon.$$

Como lo indica la Tabla 3.1, hay que demostrar tres lemas señalados como I, II y III los cuales específicamente expresan que:

1. El espacio $\mathbf{K}_-$ definido por B.1 con la norma $\|u\|_w$ es compacto en $l^\infty(\mathbb{Z}_-)$.
2. El conjunto de las funcionales G_i asociado a los operadores discretos de Laguerre es continuo respecto de la norma $\|u\|_w$.
3. El conjunto de las funcionales G_i separa puntos en $l^\infty(\mathbb{Z}_-)$.

Comencemos entonces demostrando el siguiente Lema.

3.3.2 Lema I.

Lema 1. *Debido a que la prueba de dicho lema sigue los lineamientos generales del propio demostrado en [6], la demostración se incluye como el Apéndice B.*

3.3.3 Lema II.

Lema 2. *El conjunto de las funcionales* G_n *asociado a los operadores discretos de Laguerre es continuo respecto de la norma pesada* $\|\cdot\|_w$ *de la ecuación 3.5.*

Prueba. Considere el conjunto de funcionales $\mathbf{G} = \{G_0, G_1, \cdots\}$, donde $G_n u = \sum_{i=0}^{\infty} l_n(i)\, u(-i)$ es la funcional asociada al operador $L_n(\cdot)$. Diremos que la función de peso $w'(i)$ *domina* a $w(i)$, si $w'(i) \geq w(i)$ para todo i. Si se encuentra una secuencia $w'(i)$ que domina simplemente se elige $w(i) = w'(i)$ y la demostración no varía. Ademas ha sido probado que si un sistema tiene memoria evanescente en una norma pesada por

una secuencia, luego posee memoria evanescente para toda secuencia pesante [42]. Por lo tanto sea $w(i) = 1/(1+i)$ la función de peso, entonces

$$|G_n u - G_n v| = \left| \sum_{i=0}^{\infty} l_n(i)\, u(-i) - \sum_{i=0}^{\infty} l_n(i)\, v(-i) \right|,$$

$$|G_n u - G_n v| \leq \sup_{i \geq 0} \left(|u(-i) - v(-i)|\, w(i) \right) \sum_{i=0}^{\infty} |l_n(i)|\, w(i)^{-1},$$

$$|G_n u - G_n v| \leq \|u(-i) - v(-i)\|_w \sum_{i=0}^{\infty} |l_n(i)|\, w(i)^{-1}. \tag{3.7}$$

Los sistemas de Laguerre son exponencialmente estables como se demuestra en el Apéndice A, por lo tanto por la ecuación A.1 el último término en la ecuación 3.7 se puede expresar como:

$$\sum_{i=0}^{\infty} |l_n(i)|\, w(i)^{-1} \leq (n+1) \sum_{i=0}^{\infty} r^i (i+1), \qquad |a| < r < 1.$$

Sea

$$S(r, N) = \sum_{i=0}^{N} r^i = \frac{1 - r^N}{1 - r}. \tag{3.8}$$

Tomando la derivada del primer término de 3.8,

$$\frac{d}{dr} \sum_{i=0}^{N} r^i = \sum_{i=0}^{N} \frac{d}{dr} r^i = r^{-1} \sum_{i=0}^{N} i\, r^i, \tag{3.9}$$

la derivada del segundo término de 3.8

$$\frac{d}{dr} \frac{1 - r^N}{1 - r} = \frac{1 - r^{N-1}}{(1-r)^2}, \tag{3.10}$$

e igualando obtenemos que

$$\sum_{i=0}^{N} r^i (i+1) = \frac{1 - 2r^N + r^{N+1}}{(1-r)^2}. \tag{3.11}$$

Utilizando esta última ecuación se puede acotar a

$$\left| G_n^N u - G_n^N v \right| \leq \|u(-i) - v(-i)\|_w (n+1) \frac{1 - 2r^N + r^{N+1}}{(1-r)^2}, \tag{3.12}$$

donde la funcional $G_n^N u = \sum_{i=0}^{N} l_n(i)\, u(-i)$ utiliza solo N términos de la respuesta al impulso $l_n(i)$. Tomando el límite para $N \to \infty$, es decir considerando a la respuesta infinita al impulso se obtiene

$$\lim_{N\to\infty} \left|G_n^N u - G_n^N v\right| = |G_n u - G_n v| \leq \|u(-i) - v(-i)\|_w \frac{(n+1)}{(1-r)^2}. \tag{3.13}$$

Luego dado $\varepsilon > 0$, elijiendo $\|u(-i) - v(-i)\|_w < \delta = \varepsilon(1-r^2)/(n+1)$, por la ecuación 3.13

$$|G_n u - G_n v| < \varepsilon,$$

lo que prueba al Lema 2. □

3.3.4 Lema III.

Lema 3. *El conjunto de las funcionales G_n separa puntos en $l^\infty(\mathbb{Z}_-)$.*

Prueba. Hay que demostrar que el conjunto de las funcionales G_n separa puntos en $l^\infty(\mathbb{Z}_-)$, es decir que para cualquier $u_1, u_2 \in l^\infty(\mathbb{Z}_-)$ existe G_n tal que $G_n u_1 \neq G_n u_2$. Si no separan puntos, significa que para $u_1, u_2 \in l^\infty(\mathbb{Z}_-)$ existe G_n tal que $G_n u_1 = G_n u_2$ para todo n. Sea $u = u_1 - u_2$, de forma que $G_n u = 0$ para todo n. Para demostrarlo basta comprobar que $u = 0$ (la secuencia nula), lo que probará que las funcionales discretas de Laguerre separan puntos en $l^\infty(\mathbb{Z}_-)$. Los G_n pueden ser expresados como

$$G_n u = \sum_{i=0}^{\infty} l_n(i)\, a^{-i/2} a^{i/2} u(-i) = 0$$

donde a es polo generador de los sistemas de Laguerre 1.15. Es fácil ver que los elementos $\left(u(-i)\, a^{i/2}\right)$ y $\left(l_n(i)\, a^{-i/2}\right) \in l^2(\mathbb{Z}_+)$. Como el conjunto de las funciones $\left\{l_n(i)\, a^{-i/2}\right\}$ forma una base para $l^2(\mathbb{Z}_+)$ es no nulo, por lo que se puede concluir que $u(-i)\, a^{i/2} = 0$ y por lo tanto $u = 0$. Expresado de otra forma, significa que como no es posible que una combinación de funcionales G_n genere la secuencia nula, la única forma posible de que $G_n u = 0$, es que $u = 0$. Esto demuestra que las funcionales discretas de Laguerre separan puntos en $l^\infty(\mathbb{Z}_-)$, probando al Lema 3. □

3.3.5 Prueba del Teorema de la Estructura LNet.

Prueba. Aplicando el Teorema 4 de Stone-Weierestrass, por los Lemas 1, 2 y 3, podemos concluir que toda funcional F asociada a un operador N no lineal invariante en el tiempo y que posea memoria evanescente puede ser aproximada por un conjunto de funcionales asociadas a los sistemas de Laguerre seguidos por un polinomio $p(\cdot)$ como

$$|Fu - p(G_0u, G_1u, \cdots, G_{m-1}u)| < \varepsilon/2, \quad \text{con } \varepsilon_1 > 0.$$

Dicho polinomio debe ser ahora aproximado por una red neuronal por lo que dado $\varepsilon_2 > 0$, y por el Teorema 1 existe un Perceptrón de una sola capa oculta $NN(\cdot)$ para el cual

$$|NN(x) - p(x)| < /2.$$

Como $u \in \mathbf{K} \Longrightarrow \|u\|_w \leq m_1$, es fácil ver que $|x_i| < \|L_{i-1}u\|_w \leq c_i, \quad c_i > 0, \quad i : 1, \ldots, m$. Tomando $\xi_i = x_i/c_i \quad 0, \quad i : 1, \ldots, m$ es fácil ver que $\xi_i \in I_n$ y que $p(\xi) \in C(I_n)$. Por lo tanto dado $\varepsilon > 0$, por el teorema 1, existe una red $NN(\xi)$ que aproxima a $p(\xi)$ arbitrariamente bien y para la cual

$$|Fu - NN(G_0u, G_1u, \cdots, G_{m-1}u)| < \varepsilon. \tag{3.14}$$

Hasta este punto fue demostrado que toda funcional F asociada a un operador N no lineal invariante en el tiempo, causal y que posee memoria evanescente puede ser aproximada por un conjunto de funcionales asociadas a los sistemas de Laguerre seguidos por un Perceptrón de una capa oculta $NN(\cdot)$. Para probar que puede aproximar cualquier operador con memoria evanescente primero se utiliza la ecuación 3.3 mediante la cual se recuperan los operadores asociados en la ecuación 3.14. Sea $k \in \mathbb{Z}$, luego $Pq^k u \in \mathbf{K}_-$, entonces

$$\left|FPq^k u - NN\left(G_0Pq^k u, G_1Pq^k u, \cdots, G_{m-1}Pq^k u\right)\right| = \left|Nu(k) - \widetilde{N}u(k)\right| < \varepsilon.$$

Como esta última ecuación es válida para todo $k \in \mathbb{Z}$, concluimos que para todo $u \in \mathbf{K}$

$$\left\|Nu - \widetilde{N}u\right\| < \varepsilon,$$

lo que concluye la prueba. □

Este teorema asegura que la clase de sistemas no lineales discretos, causales y con memoria evanescente, pueden ser aproximados por la estructura LNet. En la siguiente sección se harán ciertas consideraciones sobre la clase de aproximación obtenida.

3.4 Consideraciones sobre la Aproximación Obtenida.

Ha sido mostrado que para que un sistema pueda ser aproximado por la estructura LNet, son necesarias solo unas pocas suposiciones razonables desde un punto de vista físico: ser causal, invariante en el tiempo y poseer memoria evanescente. El concepto de memoria evanescente está relacionado con una característica asociada al operador que representa al sistema entrada-salida. Sin embargo, puede ser que no exista un operador entrada-salida que represente al sistema; pero si el sistema tiene memoria evanescente, este puede ser aproximado por una estructura LNet.

Es conocido el hecho de que todos los sistemas físicos tienen un cierto grado de saturación. La Figura 3.5 muestra diversos tipos de saturación encontrados comúnmente en los sistemas físicos. La estructura LNet tiene capacidades de aproximación similares a las de una Serie de Volterra. Sin embargo, la estructura LNet aventaja a la Serie de Volterra en la cantidad de parámetros necesarios para realizar una aproximación equivalente, ventaja que se acrecienta cuando el sistema presenta algún tipo de saturación como lo hacen la mayoría de los sistemas físicos [43]. Dicha ventaja se encuentra relacionada a las que posee un Perceptrón de una capa oculta para aproximar funciones continuas como fuera expresado en secciones anteriores.

La caracterización de sistemas que poseen memoria evanescente, sigue siendo aún motivo de estudio como lo puntualiza Shamma [67]. Algunos ejemplos de sistemas con memoria evanescente, se encuentran en los lineales, las cascadas de sistemas lineales dinámicos con no linealidades estáticas (Modelos de Wiener y de Harmerstein) y sistemas no lineales con unicidad de estado estacionario. Por ejemplo, si en un punto de equilibrio el campo vectorial es continuamente diferenciable y el sistema linealizado en ese punto es exponencialmente estable y controlable, luego para entradas suficientemente pequeñas el operador que relaciona la entrada con los estados tiene memoria evanescente.

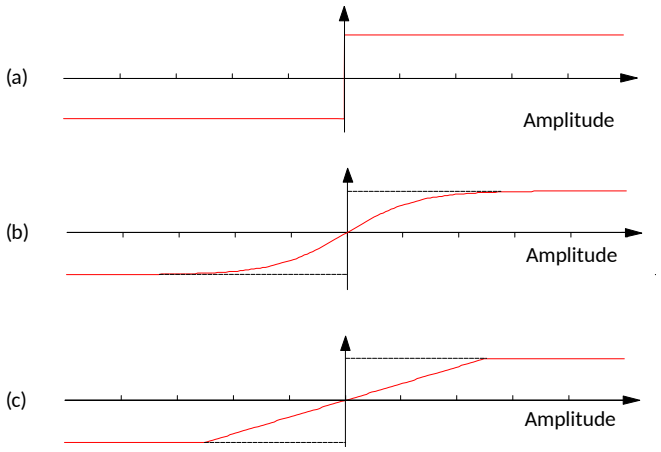


Figura 3.5: Diversos Tipos de Saturación.

3.5 Conclusiones.

Ha sido mostrado que la estructura LNet es capaz de aproximar operadores no lineales, discretos, casuales, invariantes en el tiempo y que poseen memoria evanescente. La aproximación es realizada sobre el operador que representa al sistema desde el punto de vista entrada-salida. Para realizar la demostración de las capacidades de aproximación de la estructura LNet se definieron los conceptos necesarios, dentro de los cuales el de memoria evanescente juega una papel importante. Fue mostrado que este concepto puede ser visto como una cierta forma de continuidad del operador relacionado al sistema. Se concluyó el capítulo con un discusión de los resultados obtenidos. En el siguiente capítulo serán tratadas las formas de identificar los parámetros de esta estructura.

Capítulo 4

Determinación de la Estructura LNET.

Este capítulo presenta la metodología a seguir para determinar la estructura LNet: cantidad de sistemas de Laguerre y número de neuronas en la capa oculta. La utilización de los denominados coeficientes de Lipschitz, cuyo uso se fundamenta en la continuidad del operador LNet, servirá para la evaluación del número de sistemas. En la estimación de la cantidad de neuronas de la capa oculta, se utilizará una variación de las técnicas de poda. Dicha técnica se basa en una descomposición en valores singulares de la matriz de datos propagada a través de la capa oculta. Concluye el capítulo, tras la presentación de los métodos utilizados para la validación del modelo obtenido, con una discusión sobre lo expuesto y algunas consideraciones generales.

4.1 Introducción.

En este capítulo se desarrollará el procedimiento de identificación de la estructura LNet de orden (m, no) esquematizada por la Figura 2.12, para m sistemas de Laguerre y un perceptrón de no neuronas en la capa oculta. En general la construcción de un modelo a partir de datos involucra tres componentes básicos: la recolección de datos, el conjunto de modelos candidatos y reglas mediante las cuales es posible determinar un modelo de dicho conjunto utilizando los datos obtenidos.

En determinadas ocasiones los datos de entrada-salida pueden ser recolectados a través de un experimento de identificación. En tal caso es posible definir qué señales son medibles, cuándo hacerlo y eventualmente hasta qué tipo de señales de entrada utilizar. El objeto de diseñar el experimento, sujeto a las restricciones que puedan existir, es

tomar las decisiones adecuadas de forma tal de que los datos recolectados brinden la mayor cantidad de información posible. Cuando no es posible diseñar al experimento de recolección de datos, se deben utilizar aquellos que provienen de la operación normal del sistema. Aún así, los datos obtenidos deben poseer la información suficiente para poder obtener un modelo "suficientemente bueno" del conjunto de modelos candidatos.

El conjunto de modelos candidatos queda determinado cuando se especifica la colección de modelos de la cual se espera determinar uno apropiado. Utilizaremos al conjunto de modelos LNet, que como fuera demostrado en el capítulo anterior, es capaz de aproximar en forma uniforme a la clase de sistemas no lineales discretos, invariantes al desplazamiento, causales y que poseen memoria evanescente. Cada estructura LNet queda definida por un conjunto de m sistemas de Laguerre generados por el polo a y un Perceptrón de una capa oculta de no neuronas. El polo de la expansión puede ser estimado de acuerdo a:

$$a = 1 - T/t_d, \tag{4.1}$$

donde t_d expresa a la constante de tiempo dominante del sistema y T representa al período de muestreo (para sistemas discretos $T = 1$). Será supuesto que esta constante se conoce o puede ser fácilmente estimada [80]. Un método que puede ser utilizado por su sencillez consiste en tomar muestras de la respuesta al escalón del sistema y luego aproximar dicha respuesta en algún sentido óptimo mediante el término pasabajos $L_0\left(q^{-1}\right)$ de los sistemas de Laguerre. Una vez estimado el polo a, el conjunto de sistemas de Laguerre queda totalmente definido. De forma tal que sólo resta evaluar el número m de dichos sistemas y la cantidad no de neuronas en la capa oculta del perceptrón.

El número m de sistemas será evaluado basándose en el concepto de continuidad del operador LNet. Como dicho operador es continuo también debe serlo la transformación no lineal que produce el Perceptrón. En base a este concepto se define un índice, denominado coeficiente de Lipschitz, que sirve para evaluar la continuidad de la función involucrada. La información así obtenida es útil para estimar la cantidad necesaria de sistemas a utilizar, con lo cual solo resta evaluar la cantidad de neuronas de la capa oculta.

Para acotar el número de neuronas de la capa oculta se utiliza una técnica basada en un concepto de poda ("pruning") introducido por Sentoni y col. [63]. Dicha técnica consiste en iniciar el entrenamiento con una cantidad sobreabundante de neuronas, y

mediante un cierto análisis en valores singulares de los datos de la capa oculta acotar el número no de neuronas en dicha capa. Realizado lo antedicho se continúa con el proceso de entrenamiento que permite identificar el valor de los parámetros de la red neuronal.

Una vez definida la estructura LNet por su orden (m, no) y el valor del polo a solo resta obtener el valor de sus parámetros. Estos son la matriz de pesos de la capa de entrada $\mathbf{W}1 : (m \times no)$ y su vector de bias $\mathbf{b}1 : (no \times 1)$ conjuntamente con el vector de pesos de la capa de salida $\mathbf{w}2 : (1 \times no)$ y el valor $b2$. Para obtener dichos valores se utiliza un algoritmo de optimización, mediante el cual se minimiza algún criterio específico como puede ser el error de salida. Luego de proceder con la identificación, se obtiene un modelo $\widetilde{\Sigma}$ de orden (m, no) (no necesariamente único) que aproxima en forma uniforme al sistema Σ en subconjunto $\mathbf{K}$ de l^∞, $\mathbf{K}$ dado por la ecuación 1.21. Dicho modelo es el que mejor describe a los datos de acuerdo al critrerio elegido. Solo resta comprobar si este modelo en particular es "lo suficientemente bueno", es decir si es válido para el propósito para el cual es pretendido. El conjunto de técnicas utilizadas para realizar tal comprobación es conocido bajo el nombre de validación del modelo. Este proceso involucra varios pasos para comprobar como se relaciona el modelo a los datos observados, al conocimiento previo y al uso que se intenta hacer de él. El comportamiento deficiente de un modelo lo es en relación a dichos conceptos, mientras que una buen desempeño está siempre relacionado con una cierta confianza. De forma tal que un modelo nunca debe ser aceptado como una descripción final y acabada del sistema. A lo sumo debe ser concebido como una descripción suficientemente buena de ciertos aspectos del sistema que son de particular interés. Lo cual da una idea de lo interactivo que resulta un proceso de identificación.

Planteado en esta forma, el proceso de identificar a un sistema tiene un flujo natural: primero recolectar los datos, luego seleccionar la estructura del modelo y finalmente estimar los parámetros del mejor modelo para dicha estructura. Es bastante probable que el primer modelo obtenido no pase las pruebas de validación. En este caso se debe volver atrás y revisar varios pasos del procedimiento. El modelo puede ser deficiente por varias razones:

- El procedimiento numérico utilizado no fue capaz de encontrar al mejor modelo de acuerdo al criterio elegido.
- El criterio puede no estar correctamente seleccionado.

- La estructura del modelo puede no haber sido apropiada, es decir, no contiene ninguna descripción lo suficientemente buena del sistema.

- Los datos no contienen la cantidad de información necesaria para desarrollar la identificación.

La mayor parte de un proceso de identificación implica la resolución, guiada por la experiencia obtenida en pasos previos, de los problemas planteados por los puntos recientemente mencionados en una forma iterativa [39]. Culminada esta introducción, a continuación se desarrollará la técnica que permiter estimar el número m de sistemas de Laguerre que es necesario utilizar.

4.2 Evaluación del Número de Sistemas de Laguerre.

La estructura LNet representa a un operador con memoria evanescente, que tal como fuera establecido en el capítulo III, resulta ser una generalización de los operadores continuos. Dicho operador transforma de manera continua las señales de entrada en señales de salida mediante la composición de dos transformaciones: la producida por los sistemas de Laguerre seguida por la del Perceptrón. El Perceptrón de una capa oculta produce una transformación multivariable y continua sobre una región dada, de las señales provista por los sistemas de Laguerre:

$$\widetilde{y}(k) = Nu(k) = NN\left(L_0 u(k), L_1 u(k), \cdots, L_{m-1} u(k)\right).$$

En forma individual cada transformación es continua, por lo tanto, también debe serlo su composición. La técnica para determinar la cantidad de sistemas se basa en la posibilidad de evaluar como varía la continuidad del operador LNet de acuerdo al número m de sistemas utilizados. Por simplicidad notaremos a la estructura LNet como

$$\widetilde{y}_k = g(\mathbf{z}_k) = g\left([z_1(k), z_2(k), \ldots, z_m(k)]\right), \tag{4.2}$$

donde $g(\cdot)$ representa al Perceptrón y $\mathbf{z}_k$ es un vector fila de $[1 \times m]$

$$\mathbf{z}_k = [z_1(k), z_2(k), \ldots, z_m(k)], \tag{4.3}$$

	z_1	z_2	z_3	y
a)	0	0	0	1
b)	0	ϵ	1	0

Cuadro 4.1: Valores de la Función con la Totalidad de los Datos Utilizados.

donde cada componente $z_j(k) = L_{j-1}u(k)$ representa a la señal de entrada $u(k)$ filtrada por el $(j-1)$*ésimo* sistema de Laguerre. Sea $\mathbf{Z} : [np \times m]$ la matriz en la cual son agrupados los np datos disponibles:

$$\mathbf{Z} = \begin{bmatrix} \mathbf{z}_1 \\ \mathbf{z}_2 \\ \vdots \\ \mathbf{z}_k \\ \vdots \\ \mathbf{z}_{np} \end{bmatrix}, \tag{4.4}$$

donde cada $\mathbf{z}_k$ está compuesta por el vector de la ecuación 4.3 para $k : 1, \ldots, np$. Una vez determinado el valor del polo a que especifica a todo el conjunto de los sistemas de Laguerre, es posible calcular a las señales $z_j(k)$. La cantidad m de sistemas utilizados se refleja en la dimensión del dominio de la función $g(\cdot)$. Por ejemplo, si $m = 1$, $g(\cdot) : \mathbb{R} \to \mathbb{R}$; si $m = 2$, $g(\cdot) : \mathbb{R}^2 \to \mathbb{R}$ y en general $g(\cdot) : \mathbb{R}^m \to \mathbb{R}$. El problema de estimar la cantidad de sistemas puede ser visto como el de estimar cuál es la dimensión para la cual la función desconocida $g(\cdot)$ es continua. Es decir qué puntos "cercanos" del espacio de entradas que toma valores de la martiz $\mathbf{Z}$ deben ser tranformados por la función $g(\cdot)$ en puntos "cercanos" en el espacio de salida. El siguiente ejemplo clarificará este concepto.

Ejemplo 5. *Supongamos que se desea estimar la dimensión del dominio de una función continua* $g : [0,1]^3 \to [0,1]$ *a partir de los datos ilustrados por la Tabla 4.1 donde* $\epsilon > 0$ *es un infinitésimo. Si solo se utilizaran las señales* z_1 *y* z_2 *se obtendría que la distancia en el espacio de entradas sería*

$$\|\mathbf{z}_a - \mathbf{z}_b\|_2^2 = (z_{1a} - z_{1b})^2 + (z_{2a} - z_{2b})^2 = \epsilon^2,$$

que es infinitesimal, donde $\|\cdot\|_2$ *nota a la norma 2 en un espacio Euclídeo. De acuerdo al concepto de función continua, dos puntos que se encuentran cercanos en el espacio de*

entradas deben ser transformados en puntos cercanos del espacio de salida. La distancia en el espacio de salidas es igual a

$$\|y_a - y_b\|_2^2 = 1,$$

resultando en puntos alejados dado que la función $g(\cdot)$ *transforma puntos del cubo unitario* $[0,1]^3$ *(donde la distancia máxima es* $\sqrt{2}$*) en el segmento* $[0,1]$*. Sin embargo, cuando se utiliza el número correcto de 3 dimensiones, la distancia entre los dos puntos en el espacio de entradas resulta*

$$\|\mathbf{z}_a - \mathbf{z}_b\|_2^2 = (z_{1a} - z_{1b})^2 + (z_{2a} - z_{2b})^2 + (z_{3a} - z_{3b})^2 = 1 + \epsilon^2,$$

lo cual indica que los puntos en el espacio de entradas ya no están cercanos y se puede establecer una función continua que pase por ellos. ■

El concepto ilustrado por el ejemplo anterior, sugiere un primer método para determinar la dimensión del espacio de entradas basado en la continuidad de la función $g(\cdot)$ que se desea estimar. Supongamos que la cantidad de datos $(\mathbf{z}_k, y_k)$, $k : 1, \ldots, np$ disponibles para estimar la dimensión de $g(\cdot)$ es suficiente. Luego se procede de la siguiente forma:

1. Comenzar con $m = 1$.
2. Verificar por definición la continuidad de la función $g(\cdot)$ para la totalidad del conjunto de datos disponible.

   Es decir que, dado $\varepsilon > 0$ existe $\delta > 0$, tal que para todo par de puntos $(i,\ j) : 1, \ldots, np$ del espacio de entradas se cumple que

   $$\|z_i - z_j\| \leq \delta \Longrightarrow |y_i - y_j| < \varepsilon.$$

3. La función $g(\cdot)$ resulta continua? **Si**, entonces m es el valor deseado. **Parar**.
4. **No**, hacer $m = m + 1$ y volver a $\#\mathbf{1}$.

El algoritmo anterior propone una primera aproximación a la solución del problema de verificar la continuidad de la función desconocida $g(\cdot)$ a partir de los datos

disponibles [62]. Sin bien simple en su concepción y efectivo cuando no existe ruido en las mediciones, el método falla cuando hay ruido presente. Más aun, resulta difícil determinar los ε y δ que indican que está "cercano" en el espacio de entradas y salida respectivamente. Un refinamiento al anterior método consiste en utilizar a los denominados coeficientes de Lipschitz.

4.2.1 Coeficientes de Lipschitz.

Una función continua que toma valores en una región cerrada es Lipschitz acotada. Basados en dicho principio Xiangdong y Asada [78] presentaron el método de los coeficientes de Lipschitz para la evaluar la dimensión de una función multivariable $g(\cdot)$ en modelos no lineales entrada-salida. A continuación definiremos que se entiende por condición de Lipschitz.

Definición 10. *Se dice que la función* $g(\cdot) : \mathbb{R}^m \to \mathbb{R}$ *es Lipschitz acotada en una bola centrada en* $\mathbf{z}_o$, $\mathbf{B} = \{\mathbf{z} \in \mathbb{R}^m : \|\mathbf{z} - \mathbf{z}_o\| \leq r > 0\}$ *si existe una constante finita* k_{lip} *tal que*

$$|g(\mathbf{z}_i) - g(\mathbf{z}_j)| \leq k_{lip} \|\mathbf{z}_i - \mathbf{z}_j\|_i, \forall \mathbf{z}_i, \mathbf{z}_j \in \mathbf{B}, \tag{4.5}$$

donde k_{lip} *es conocida como la constante de Lipschitz y* $\|\cdot\|_i$ *representa a un norma arbitraria en el espacio de entradas.*

En el caso específico de una Perceptrón de una capa oculta en [72] se demuestra que la transformación que produce la red es Lipschitz acotada, es decir cumple con lo establecido por la ecuación 4.5. Una función que cumple con la condición 4.5 posee sus derivadas parciales acotadas [74, pag. 45]:

$$|g_j| = |\partial g / \partial z_j| \leq k_{lip}, \ j : 1, \ldots, m. \tag{4.6}$$

Luego, los coeficientes de Lipschitz λ_{ij} son definidos como

$$\lambda_{ij} = \frac{|y_i - y_j|}{\|\mathbf{z}_i - \mathbf{z}_j\|}, \ (i \neq j),$$

donde $y_i = g(\mathbf{z}_i)$ por la ecuación 4.2 para $i, j : 1, ..., np$. Estos cocientes se expresan como la relación de dos cantidades: $\|\mathbf{z}_i - \mathbf{z}_j\|$ que es la distancia entre dos puntos del

espacio de entradas y $\|\delta y\| = |y_i - y_j|$, la diferencia entre los valores $g(\mathbf{z}_i)$ y $g(\mathbf{z}_j)$. Como la función $g(\cdot)$ es contínua, la condición de Lipschitz establece que los cocientes de Lipschitz deben ser acotados:

$$0 \leq \lambda_{ij} = \frac{|y_i - y_j|}{\|\mathbf{z}_i - \mathbf{z}_j\|} < \infty.$$

Aplicando análisis de sensitividad a la formulación entrada-salida de la ecuación 4.2 se obtiene que

$$\delta y = g_1 \delta z_1 + g_2 \delta z_2 + \cdots + g_m \delta z_m,$$

donde $\delta y = g(\mathbf{z}_i) - g(\mathbf{z}_j)$ y las g_i notadas por la ecuación 4.6 son las derivadas parciales de $g(\mathbf{z}_i)$ de 4.2 respecto a cada componente i. Luego

$$\lambda_{ij} = \frac{|\delta y|}{\sqrt{(\delta z_1)^2 + (\delta z_2)^2 + \cdots + (\delta z_m)^2}} = \frac{|g_1 \delta z_1 + g_2 \delta z_2 + \cdots + g_m \delta z_m|}{\sqrt{(\delta z_1)^2 + (\delta z_2)^2 + \cdots + (\delta z_m)^2}}.$$

De acuerdo con las definiciones previas, tomando $\delta = \max_{i \in (1,..,m)} |\delta_i|$ y $|g_i| \leq k_{lip}$, la cota en los cocientes de Lipschitz puede ser obtenida mediante la desigualdad de Schwartz:

$$\lambda_{ij}^m = k_{lip} \frac{|\delta z_1| + |\delta z_2| + \cdots + |\delta z_m|}{\sqrt{(\delta z_1)^2 + (\delta z_2)^2 + \cdots + (\delta z_m)^2}} \leq k_{lip} \sqrt{m}, \tag{4.7}$$

donde el supraíndice m en λ_{ij}^m representa la cantidad de sistemas de Laguerre a ser usados. Sea m_0 la cantidad deseada de estos sistemas de Laguerre. Por lo tanto si todas las variables $z_i,\ i : 1, \ldots, m_0$ se encuentran en la reconstrucción de la función $g(\mathbf{z})$, los cocientes de Lipschitz para todos los pares de datos $(\mathbf{z}_i, y_i)$ serán acotados. Dos situaciones posibles pueden darse bajo estos supuestos: si alguna de las variables no se encuentra presente en la reconstrucción, los cocientes de Lipschitz serán arbitrariamente grandes; mientras que si existen más variables que las necesarias, dichos coeficientes serán acotados. Tal cuestión será clarificada a continuación.

1. $m < m_0$, *es decir el número utilizado* m *es menor al número deseado* m_0.

Se desea mostrar que si alguna de las variables no se encuentra presente en la reconstrucción, los cocientes de Lipschitz serán arbitrariamente grandes. Para lo cual supongamos, sin perder generalidad, que la variable z_{m_0} no está incluída en la recons-

trucción de la función desconocida $g(\cdot)$. Supongamos además que para algún par i, j de los datos disponibles se cumple que $\delta z_1 = \cdots = \delta z_{m_0-1} = 0$ y que $\delta z_{m_0} = \epsilon$ una cantidad infinitesimal. A continuación evaluaremos los cocientes de Lipschitz verificando que con z_{m_0} ausente los coeficientes de Lipschitz serán arbitrariamente grandes y que con z_{m_0} presente el coeficiente de Lipschitz será acotado. La distancia en el espacio de salida en ambos casos es la misma

$$\delta y = y_i - y_j,$$

ya que es un dato. La distancia en el espacio de entradas con z_{m_0} ausente será

$$\sqrt{(\delta z_1)^2 + (\delta z_2)^2 + \cdots + (\delta z_{m_0-1})^2}.$$

En estas condiciones el coeficiente de Lipschitz $\lambda_{ij}^{m_0-1}$ es

$$\lambda_{ij}^{m_0-1} = \frac{|\delta y|}{\sqrt{(\delta z_1)^2 + (\delta z_2)^2 + \cdots + (\delta z_{m_0-1})^2}} = \frac{|g_{m_0}|\,\epsilon}{\sqrt{(\delta z_1)^2 + (\delta z_2)^2 + \cdots + (\delta z_{m_0-1})^2}} \to \infty.$$

Sin embargo si se incluye a la variable z_{m_0} en la reconstrucción, el coeficiente $\lambda_{ij}^{m_0}$ es

$$\lambda_{ij}^{m_0-1} = |g_{m_0}|\,.$$

Resulta fácil ver que $\lambda_{ij}^{m_0-1}$ (con z_{m_0} no incluída) será mucho mayor que $\lambda_{ij}^{m_0}$ (en el que todas las variables han sido incluidas).

1. $m > m_0$, *es decir el número utilizado* m *es mayor al número deseado* m_0.

Cuando una variable redundante $z_{m_{0+1}}$ ha sido incluida, del análisis anterior resulta fácil ver que $\lambda_{ij}^{m_0+1}$ será solo ligeramente menor que $\lambda_{ij}^{m_0}$, pero no significativamente.

La anterior discusión presenta las bases para que el número de entradas pueda ser identificado usando la información provista por los cocientes de Lipschitz. Procediendo de acuerdo a este objetivo, se define el siguiente índice

$$\lambda^m = \left(\prod_{k=1}^{mv} \sqrt{m} \lambda^m(k) \right)^{1/mv}, \tag{4.8}$$

donde $mv = cte \cdot np,\ cte \in [.01, .02]$, $\lambda^m(k)$ es el *k-ésimo* mayor coeficiente de Lipschitz calculado con las variables $(z_1, z_2, \cdots, z_m)$ entre todos los λ_{ij}^m de la ecuación 4.7

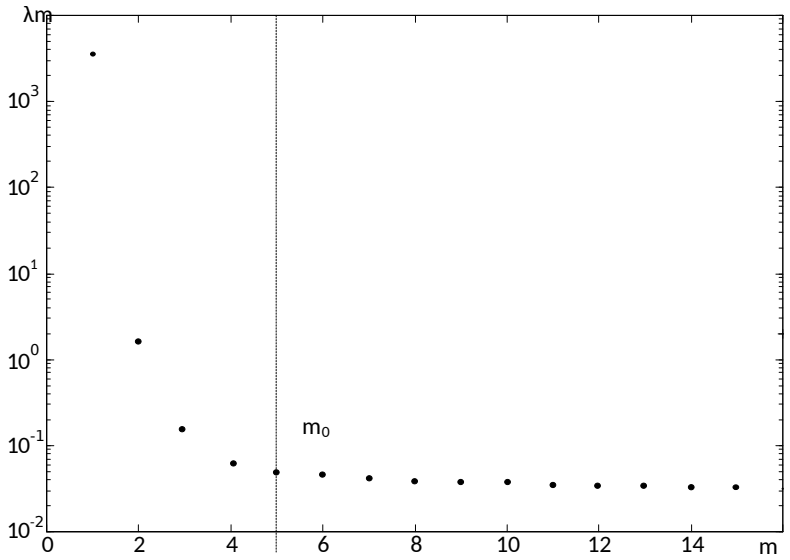


Figura 4.1: Curva típica de los coeficientes de Lipschitz.

$(i \neq j;\ i,j : 1,2,\ldots,np)$. El índice de la ecuación 4.8 es definido como el promedio geométrico de los mv mayores valores de los λ_{ij}^m para disminuir el efecto producido por el ruido que pudiera estar presente. Del análisis previo se puede apreciar que si λ^{m_0} es el número deseado de variables, λ^{m_0+1} es muy próximo a $\lambda_{ij}^{m_0}$. Sin embargo $\lambda_{ij}^{m_0-1}$ es mucho mayor que $\lambda_{ij}^{m_0}$ y $\lambda_{ij}^{m_0-2}$ es mucho mayor que $\lambda_{ij}^{m_0-1}$. Si se grafica una curva en donde se muestre el valor de λ^m en la ordenada y el de m en la abscisa podrá ser observado (Ver Figura 4.1) que a partir de un dado punto que definiremos como λ^{m_0}, la curva entra en una región de saturación. Es fácil apreciar que si se selecciona un m menor que m_0, λ^m se incrementará significativamente. En cambio, si se selecciona un $m > m_0$ no se obtiene una disminuición significativa en el valor de λ^m. De forma tal que en el proceso de selección es conveniente tomar una constante de corte γ, tal que m_0 pueda ser seleccionado como:

$$m_0 = \min_m \left[\lambda^m / \lambda^{m+1} < \gamma\right]. \tag{4.9}$$

La expuesto recientemente puede ser resumido en el siguiente algoritmo:

1. Comenzar con $m = 1$.

2. Verificar la continuidad de la función $g(\cdot)$ para la totalidad del conjunto de np datos disponible mediante los coeficientes de Lipschitz.

   Es decir que, dado una constante de corte γ verificar que los coeficientes entraron

en la zona de saturación indicada por

$$m_0 = \min_m \left[\lambda^m/\lambda^{m+1} < \gamma\right].$$

3. La función $g(\cdot)$ resulta continua? **Si**, entonces m es el valor m_0 deseado. **Parar**.

4. **No**, hacer $m = m + 1$ y volver a #**1**.

Se presentó la forma de estimar la cantidad de sistemas de Laguerre en base a un concepto relacionado a la continuidad del operador LNet. A continuación se tratarán algunos aspectos relacionados a las señales utilizadas para la identificación.

Consideraciones sobre las Señales Utilizadas en el Cálculo de los Coeficientes.

Un aspecto importante en la identificación de sistemas es considerar el tipo de señal de excitación a utilizar. Dichas señales deben ser admisibles por el sistema como entradas y deben poseer características que las hagan útiles para la identificación y posterior validación del modelo. Para identificar sistemas lineales es necesario utilizar señales que posean excitación persistente[1]. En sistemas no lineales existen exigencias adicionales para la señal de excitación debido a la complejidad inherente a los mismos. No solo es necesario que las señales utilizadas pertenezcan al rango de frecuencias de interés, sino que además deben poseer los niveles apropiados para excitar al sistema, de forma tal que manifieste su naturaleza no lineal, en diversas zonas de su región operativa. Se debe tener en cuenta, como fuera mencionado, que las señales utilizadas deben ser útiles en el momento de validar al modelo.

Billings y Voon [5] desarrollaron técnicas de validación para modelos entrada-salida para las cuales se requiere que las señales de excitación utilizadas posean una distribución de probabilidad simétrica. La señales PRBS (Pseudo Random Binary Signals) y aquellas que poseen tanto una distribución normal como uniforme cumplen con este requisito. Las señales tipo PRBS han sido ampliamente utilizadas en la identificación de sistemas lineales, sin embargo no son apropiadas para la identificación de sistemas no lineales. Las señales PRBS varían únicamente entre dos niveles lo cual frecuentemente resulta insuficiente [38] dado que no provee la riqueza de amplitudes necesaria

[1]Para un sistema lineal de orden n las señales con distribución nomal, uniforme y una combinación de n señales sinusoidales de frecuencias diferentes aseguran exitación persitente.

para realizar la identificación. Leonaritis y Billings [38] propusieron la utilización de una señal con distribución uniforme, que toma valores entre los rangos en los cuales interesa identificar al sistema. Sin embargo este tipo de señales suele resultar inaplicable desde un punto de vista práctico: puede variar frecuentemente entre valores muy diferentes. Dificultades similares se producen al utilizar señales que tienen una distribución normal. En [20] se propone la utilización de una señal cuya amplitud varía de acuerdo a una distribución uniforme dentro de la región de interes y sobre la cual se puede especificar la probabilidad de que cambie de valor al fin de cada instante de muestreo.Poder especi-

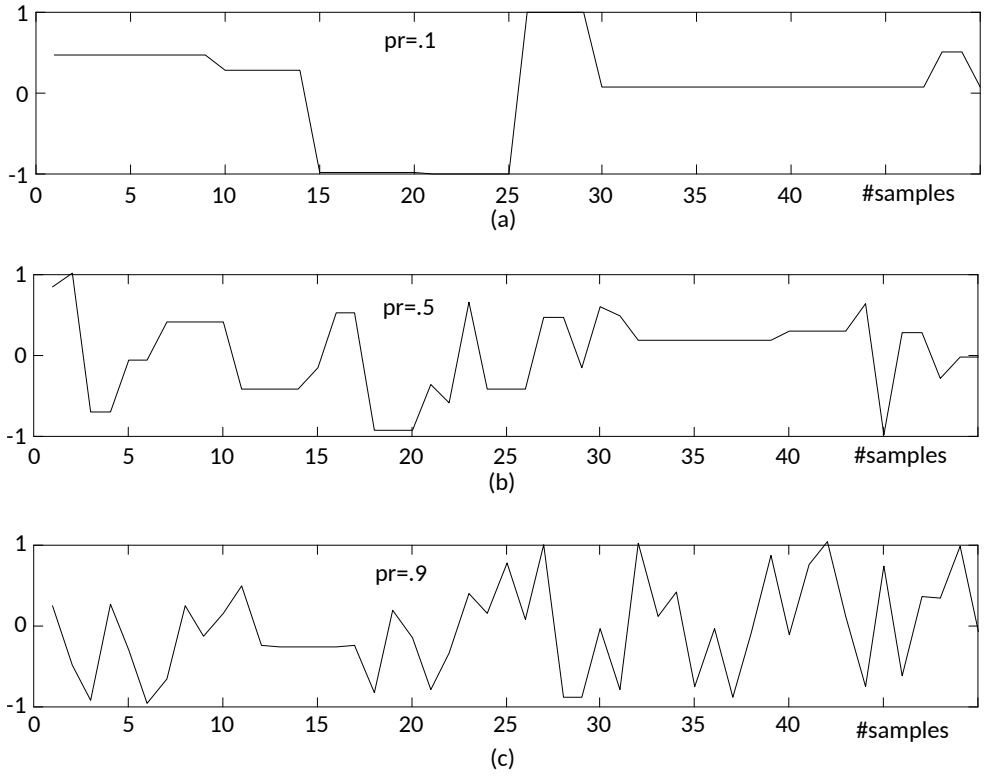


Figura 4.2: Señal Equiprob para Tres Probabilidades *pr* Distintas.

ficar la probabilidad de cambio al final de cada intervalo de muestreo permite adaptar la rapidez con que la señal de excitación varía a las restricciones del sistema. Definiremos como EquiProb (EP) al tipo de señal para la cual tanto su amplitud como la probabilidad de cambio varían de acuerdo a una distribución uniforme. La señal EP es ilustrada en la Figura 4.2 para tres probabilidades de cambio *pr* distintas: en **a**) $pr = .1$, en **b**) $pr = .5$ y en **c**) $pr = .9$. Resulta fácil apreciar que el parámtro *pr* ajusta la frecuencia de cambio. A continuación se presenta un ejemplo que ilustra la variación sufrida en el cálculo de los coeficientes de Lipschitz al utilizar señales con distintas distribuciones de

probabilidad: uniforme, normal y EP.

Ejemplo 6. *El presente ejemplo ilustra el uso de los coeficientes de Lipschitz para la identificación del órden de un filtro FIR utilizando tres señales de excitación distintas. El sistema utilizado es descripto por la ecuación 1.13*

$$y(k) = \overline{\mathbf{b}}^T \mathbf{u}_{nu}(k),$$

donde $\mathbf{u}_{nu}$ *está expresado por la ecuación 1.8 con* $n_u = 5$ *para los siguientes coeficientes*

$$\overline{\mathbf{b}} = \begin{bmatrix} .9 & -.7 & .5 & -.5 & .1 & .1 \end{bmatrix}^T.$$

Resulta claro que son 6 los coeficientes significativos del filtro y que ese debiera ser el valor identificado por los coeficientes de Lipschitz. Dichos coeficientes se calcularon utilizando 200 *muestras entrada-salida para tres señales con distribuciones de probabilidad distintas: una con distribución uniforme, una con distribución normal y una con distribución EP con* $pr = .5$*. En la Figura 4.3 se muestran los resultados obtenidos en los tres casos. Se observa que los coeficientes de Lipschitz calculados tanto para la señal con distribución uniforme del apartado* **a)** *como para la señal con distribución normal del apartado* **b)** *se estabilizan para un valor de* 4*. En el apartado* **c)** *es posible apreciar los coeficientes de Lipschitz calculados con la entradsa EP. Los primeros 6 valores no son graficados, por ser iguales a* ∞*, estabilizándose para el valor* 7*. Dicho valor es el esperado de acuerdo a lo expuesto en la sección anterior, ya que más allá de* 7*, la curva entra en una región de saturación.* ■

En esta sección se presentó la técnica que permite estimar la cantidad de sistemas de Laguerre mediante las utilización de los coeficientes de Lipschitz conjuntamente con algunas consideraciones sobre las señales utilizadas para la identificación. La siguiente sección presentará la metodología para estimar el número de neuronas de la capa oculta del Perceptrón.

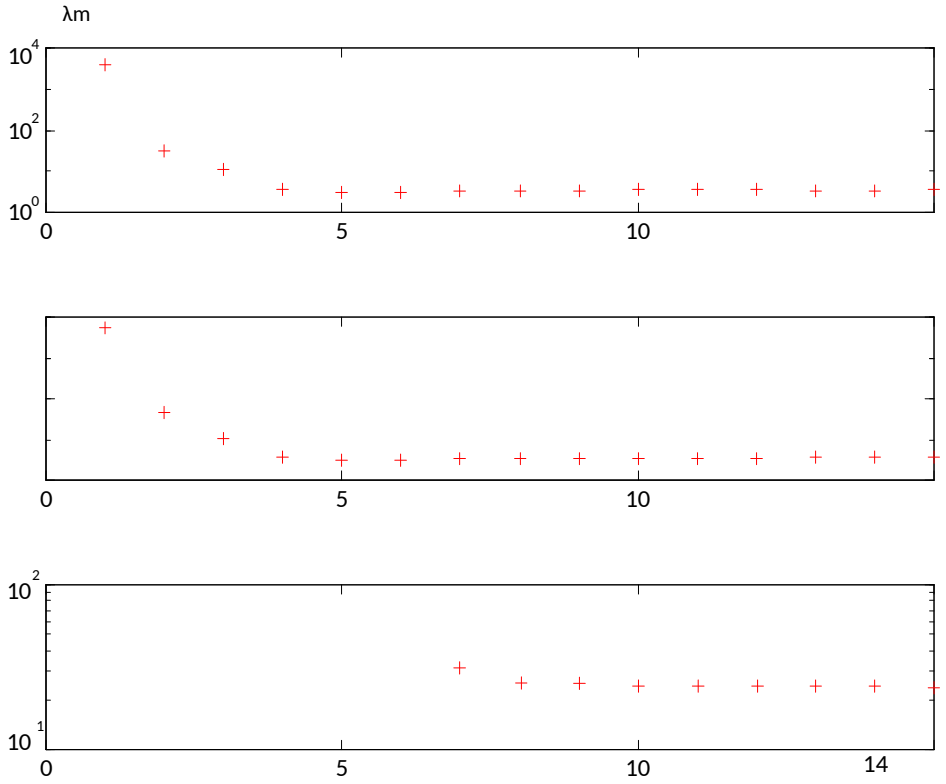


Figura 4.3: Coeficientes de Lipschitz para Distribuciones: a) Uniforme, b) Normal y c) EP.

4.3 Estimación de la Cantidad de Neuronas Mediante Valores Singulares.

En esta sección se presenta la metodología para estimar el número de neuronas *no* de la capa oculta del Perceptrón, mediante una técnica basada en la descomposición en valores singulares de la matriz de datos propagada a través de la capa oculta. La evaluación de los valores singulares permite detectar la existencia en la matriz mencionada de columnas que son linealmente dependientes, lo que indicaría un exceso de neuronas. Tales neuronas no agregan mayor información, sin embargo incrementan el número de parámetros que es necesario estimar lo que reduce la capacidad de generalización del Perceptrón. Por lo expuesto, resulta deseable obtener un buen modelo con el menor número posible de elementos. Existen básicamente dos formas de resolver este inconveniente:

Técnicas de Inclusión. En este tipo de técnica se parte de una red con un número reducido de neuronas en la capa oculta, el cual se va incrementando hasta obtener la precisión deseada sin descuidar la capacidad de generalización.

Técnicas de Poda. En este tipo de técnica se parte de un número sobreabundante de neuronas en la capa oculta y mediante algun criterio, se procede a la "poda" o quita de algunas neuronas.

El método que presentaremos puede ser incluído en esta última categoría dado que partiendo de un número grande de neuronas, dicha cantidad se reduce tomando como criterio el número de condición de la matriz de datos propagada a través de la capa oculta. Para hacerlo utilizaremos una técnica de descomposición en valores singulares presentada en [63] por Sentoni y col. y en [51] por Nebot y col. En [63] se utiliza la descomposición en valores singulares para acotar en número de neuronas de la capa oculta de una red que modela a una función logística caótica, resultados que serán reproducidos en un ejemplo. En [51] se utiliza la misma técnica de descomposición en valores singulares para determinar la cantidad de neuronas de la capa oculta, en la identificación de un brazo robot flexible mediante una red neuronal. Paralelamente, una variación de dicha metodología fue publicada por Psichogios y Ungar [57].

Resultados previos muestran que para np patrones de entrenamiento es suficiente utilizar $no = np - 1$ neuronas en la capa oculta [61], [28]. Sin embargo dichos resultados

fueron desarrollados para estudios de clasificación de patrones. Cuando son utilizados en estimación de funciones, generalmente conllevan una sobreestimación del número de neuronas. Más aún, dada esta primer aproximación existen un variado número de factores que pueden influir en la estimación y que no pueden ser determinados a priori del entrenamiento. Para estimar dicho parámetro se dispone de np patrones de entrenamiento con los cuales se forma la matriz $\mathbf{Z} : [np \times m]$ como en la ecuación 4.4, compuesta por cada patrón de entrada formando una fila. Los restantes parámetros de la red tienen las siguientes dimensiones $\mathbf{W}1 : [m \times no]$, $\mathbf{b}1 : [no \times 1]$ y $\mathbf{w}2 : [no \times 1]$ y $b2 : [1 \times 1]$. A continuación expresaremos de una forma ligeramente distinta a las matrices de pesos y de datos de forma tal de poder formular al problema de descomposición en valores singulares de una forma más simple. Acorde a lo expresado, a la matriz $\mathbf{Z}$ se le anexará un vector unitario que puede ser considerado como una entrada de valor constante unitario tal como fuera indicado en la sección 2.2 (ver Figura 2.2). Al mismo tiempo, en la matriz $\mathbf{W}1$ se reagrupa al vector $\mathbf{b}1$ de la siguiente forma

$$\mathbf{Z} = [\mathbf{Z}\ \mathbf{I}_{np}]\,,\ \mathbf{W}1 = \begin{bmatrix} \mathbf{W}1 \\ \mathbf{b}1^T \end{bmatrix}, \tag{4.10}$$

donde $\mathbf{I}_{np} : [1 \times np]$ es un vector unitario. Como no introduce complejidad adicional y en beneficio de la claridad, dichas matrices serán notadas con el mismo nombre. Además se define a la matriz $\mathbf{X}_o$ resultante de propagar la matriz de datos $\mathbf{Z}$ a través de la capa oculta como

$$\mathbf{X}_o = \phi\left(\mathbf{Z}\mathbf{W}1\right), \tag{4.11}$$

donde $\mathbf{X}_o : [np \times no]$, no el número de neuronas de la capa oculta, np el número de patrones de entrenamiento y $\phi\left(\cdot\right)$ es la función de activación de la capa. Dicha función de activación es aplicada componente a componente como en 2.2, donde la función de activación de cada neurona es

$$\phi\left(x\right) = \frac{(1 - e^{-2x})}{(1 + e^{-2x})}. \tag{4.12}$$

Conjuntamente $\mathbf{b}2 = b2\mathbf{I}_{np}$ con lo cual la red transforma patrones de entrada en patrones de salida en la siguiente forma

$$\widetilde{\mathbf{y}} = \mathbf{X}_o\mathbf{w}2 + \mathbf{b}2, \tag{4.13}$$

donde $\widetilde{\mathbf{y}} : [np \times 1]$ es el vector de salidas de la red. La Figura 4.4 ilustra sobre la reformulación y las dimensiones de las matrices involucradas.

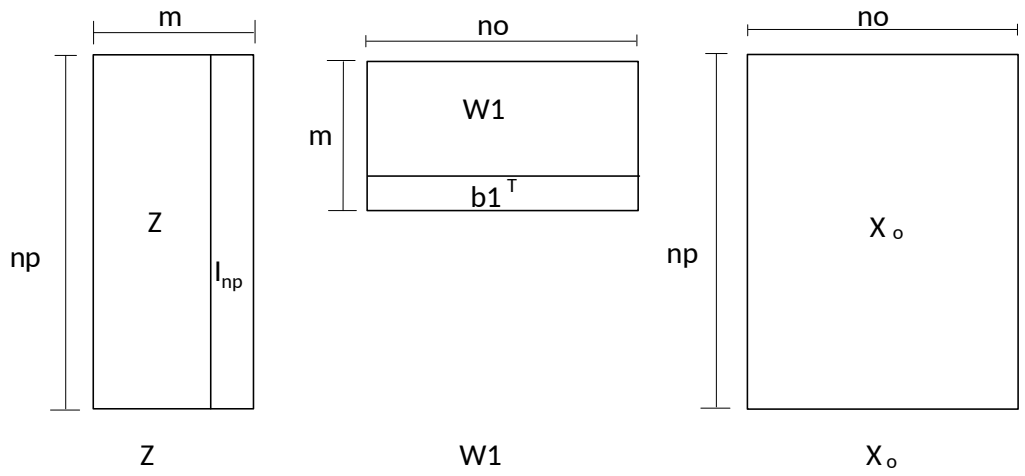


Figura 4.4: Matrices Involucradas en el Entrenamiento.

El algoritmo de entrenamiento está constituído por un algoritmo de optimización que minimiza la siguiente funcional

$$\min_{\Theta} \|\widetilde{\mathbf{y}} - \mathbf{y}\|_2^2 , \tag{4.14}$$

donde Θ representa a los pesos y el bias de la red $\mathbf{W}1$, $\mathbf{b}1$, $\mathbf{w}2$ y $b2$, $\widetilde{\mathbf{y}}$ e $\mathbf{y}$ son los vectores de la salida aproximada por la red y del sistema respectivamente. El algoritmo de minimización de "back error propagation" utilizado no será descripto, dado que es común en la literatura [58] y disponible a través de cualquier paquete de software comercial como por ejemplo, Matlab^{TM}. Adicionalmente consideraremos al valor $b2 = 0$ en la ecuación 4.13 por el resto del desarrollo para facilitar la exposición, con lo cual la salida adopta la expresión

$$\widetilde{\mathbf{y}} = \mathbf{X}_o \mathbf{w}2. \tag{4.15}$$

Dicha consideración no constituye una limitación dado que tanto $\mathbf{X}_o$ como $\mathbf{w}2$ pueden ser modificados utilizando un argumento similar al expuesto en la ecuación 4.10. Finalmente se está en condiciones de comenzar la exposición del tipo de técnica utilizada para acotar al número de neuronas en la capa oculta, técnica esquematizada a continuación:

1. Comenzar el proceso de entrenamiento (minimización) con un número sobreabundante de neuronas.

2. Avanzar en el proceso de entrenamiento por un cierto período de tiempo luego del cual este es detenido. Con los parámetros obtenidos formar la matriz $\mathbf{X}_o$ de la ecuación 4.11.

3. Acotar el número de neuronas *no* de la capa oculta en base a un análisis de los valores singulares de la matriz $\mathbf{X}_o$.

4. Continuar el entrenamiento del Perceptrón de *no* neuronas en la capa oculta hasta finalizar.

5. Validar la red.

A continuación se tratará como acotar el número de neuronas *no* de la capa oculta en base a un análisis de los valores singulares de la matriz $\mathbf{X}_o$. Ha sido argumentado que la mayor parte del tiempo de entrenamiento de un perceptrón es requerido para ajustar los pesos de la capa de salida, dado que los primeros parámetros en ajustarse son los de la capa oculta [36]. Luego es esperable que aunque dichos parámetros no hayan convergido totalmente, estén más cercanos de la convergencia que los parámetros de la capa de salida. Suponer esto es equivalente a decir que la matriz $\mathbf{X}_o$ variará en el proceso de entrenamiento en un forma más lenta que $\mathbf{w}2$, con lo cual es posible analizar a la transformación lineal de salida $\widetilde{\mathbf{y}} = \mathbf{X}_o\mathbf{w}2$ mediante la descomposición en valores singulares de la matriz $\mathbf{X}_o$. Cualquier matriz $\mathbf{X}_o : [np \times no]$, puede ser expresada mediante una descomposición en valores singulares [52] como

$$\mathbf{X}_o = \mathbf{U}_o^T \cdot \mathbf{\Sigma}_o \cdot \mathbf{V}_0, \tag{4.16}$$

donde $\mathbf{U}_o : [np \times no]$, $\mathbf{V}_o : [no \times no]$, y $\mathbf{\Sigma}_o : [no \times no]$. La matriz $\mathbf{\Sigma}_o = diag\{\sigma_i\}, i : 1, ..., no$, contiene a los denominados *valores singulares* de $\mathbf{X}_o$ tales que $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_{no} \geq 0$. Si una matriz $\mathbf{X}_o$ tiene $rango = r_o < no$, entonces $\sigma_{r_o+1} = \sigma_{r_o+1} = \cdots = \sigma_{no} = 0$. En la práctica σ_{r_o+1} será significativamente menor que σ_{r_o}, lo cual implica que existen $no - r_o$ columnas linealmente dependientes en $\mathbf{X}_o$. La información que esas $no - r_o$ columnas linealmente dependientes aportan es prácticamente nula y está en relación directa con la magnitud del valor singular asociado[2]. De esta forma es posible determinar

[2]Si la matriz $\mathbf{X}_o = \mathbf{U}_o^T \cdot \mathbf{\Sigma}_o \cdot \mathbf{V}_0$, $\mathbf{U}_o : [np \times no]$, $\mathbf{V}_o : [no \times no]$, $\mathbf{\Sigma}_o : [no \times no]$, $\mathbf{\Sigma}_o = diag\{\sigma_i\}, i : 1, ..., no$, es aproximada por una matriz de $rango = ro < no$, $\mathbf{X}_o^{ro} = \mathbf{U}_o^T \cdot \mathbf{\Sigma}_1 \cdot \mathbf{V}_0$, donde $\mathbf{\Sigma}_1 = diag\{\sigma_{1i}\}, \sigma_{1i} = \sigma_i$, $i : 1, ..., ro$ y $\sigma_{1i} = 0$, $i > ro$, luego vale que $\|\mathbf{X}_o - \mathbf{X}_o^{ro}\|_2 = \sigma_{ro+1}$

el número de condición de la matriz $\mathbf{X}_o$ mediante el análisis de los valores singulares σ_i. Y así evitar un alto número de condición en la matriz $\mathbf{X}_o$ ajustando el número de neuronas en la capa oculta. De forma tal que el número de valores singulares diferentes de cero brinda una valiosa información sobre la cantidad de neuronas en la capa oculta. Valores de σ_i cercanos a cero, indican que un dado número de neuronas de la capa oculta que están en exceso. Sea $\mathbf{w}2$ la solución en el sentido de mínimos cuadrados de la ecuación 4.14 obtenida mediante las ecuaciones 4.15 y 4.16 como

$$\mathbf{w}2 = \mathbf{V}_0^T \left[diag\left(1/\sigma_i\right) \right] \mathbf{U}_o \mathbf{y},$$

donde $1/\sigma_i = 0$ para todo σ_i muy cercano a cero. Dicha solución es numéricamente muy robusta, y explícitamente esta indicando que $no - r_o$ no están siendo utilizadas, por lo que el número de neuronas seleccionado es r_o. Una vez determinado dicho número, se continúa con el entrenamiento para una red con la cantidad de neuronas r_o evaluadas. Luego de que el entrenamiento llega a su fin se procede a la validación de la red obtenida. La aplicación de la presente metodología permite arribar a una situación de compromiso entre la cantidad de neuronas y la calidad de la aproximación lograda. Es sabido que a mayor cantidad de parámetros, las capacidades de generalización de una red se deterioran para la misma cantidad de datos de entrenamiento. A continuación será presentado un ejemplo para clarificar la metodología propuesta.

Ejemplo 7. *El presente ejemplo es una reproducción del presentado en [63]. Sea la función logística*

$$x\left[k+1\right] = \alpha x\left[k\right]\left(1 - x\left[k\right]\right),$$

donde α es un parámetro y $k \geq 1$ es una variable discreta que representa al tiempo. Esta ecuación representa la dinámica de evolución de la población de algunos sistemas biológicos. El problema que se plantea es el de predecir el valor de $x\left[k+1\right]$ dada la información de $x\left[k\right]$. Este sistema es caótico para algunos valores de $\alpha > 3$. Consideraremos $x\left[1\right] = .1$ y al valor de $\alpha = 4$ para el cual el sistema es reconocido como caótico [7]. Se desea predecir al valor $x\left[k+1\right]$ dado el valor presente $x\left[k\right]$ para lo cual se genera un vector de 50 valores como se aprecia en la Figura 4.5, de los cuales los primeros 15 son utilizados para el entrenamiento y los restantes para validar al modelo. De acuerdo a las discusión previa, utilizando $no = np - 1$ neuronas en la capa oculta debería ser suficiente

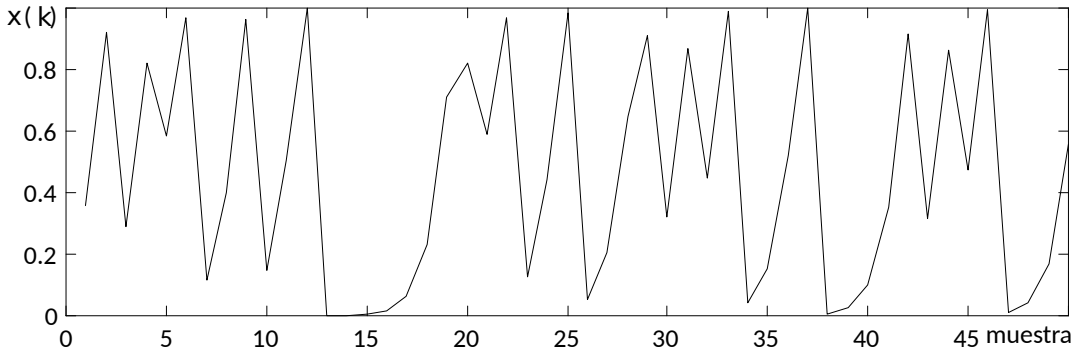


Figura 4.5: Dinámica Caótica de la Población de un Sistema Biológico.

para reproducir al conjunto de los np valores de entrenamiento. Por lo cual se sintetizó una red con una entrada y 14 neuronas en la capa oculta. Se comenzó el entrenamiento y luego de un tiempo se lo detuvo, propagándose la matriz de datos $\mathbf{Z}$ *para formar la matriz* $\mathbf{X}_o$*, que tiene 15 filas por 14 columnas (*$np = 15,\ no = 14$*). Descomponiendo a* $\mathbf{X}_o$ *en valores singulares como en la ecuación 4.16 se obtiene la matriz* Σ_0 *de valores singulares*

$$\Sigma_0 = diag\left\{15.811, 5.817, 0.274, 0.121, 0.005, 0.002, 0.000, \ldots, 0.000\right\}.$$

De acuerdo a los resultados de la presente sección, se puede apreciar que solo 2 neuronas parecen ser necesarias. Para evaluar la perfomance del método se entrenaron cuatro diferentes redes con $no = 1,\ 2,\ 5$ *y* 14 *neuronas en la capa oculta. Para su entrenamiento se utilizó un algoritmo de propagación del error hacia atrás ("Back Error Propagation") con los mismos parámetros en los cuatro casos. El algoritmo de entrenamiento fue utilizado con los 15 primeros datos durante unas 100 iteraciones. La Figura 4.6 ilustra los resultados obtenidos en dichos casosdonde se puede apreciar que para una neurona (parte* $\mathbf{a}$*) el error absoluto es comparable en valor a los datos. En el apartado* $\mathbf{b}$ *se pueden apreciar que la diferencia entre los errores absolutos de aproximación para las redes de 2, 5 y 14 neuronas no es significativa, si bien ocurre que a mayor cantidad de neuronas menor es el error. La Tabla 4.2 expresa el error de aproximación para los 4 casos. Se puede apreciar que el error disminuye aproximadamente con una relación de* $1/n$ *de acuerdo a los resultados de [3] que presenta la ecuación 2.18.* ■

Se presentó la metodología para evaluar la cantidad de m de sistemas de Laguerre

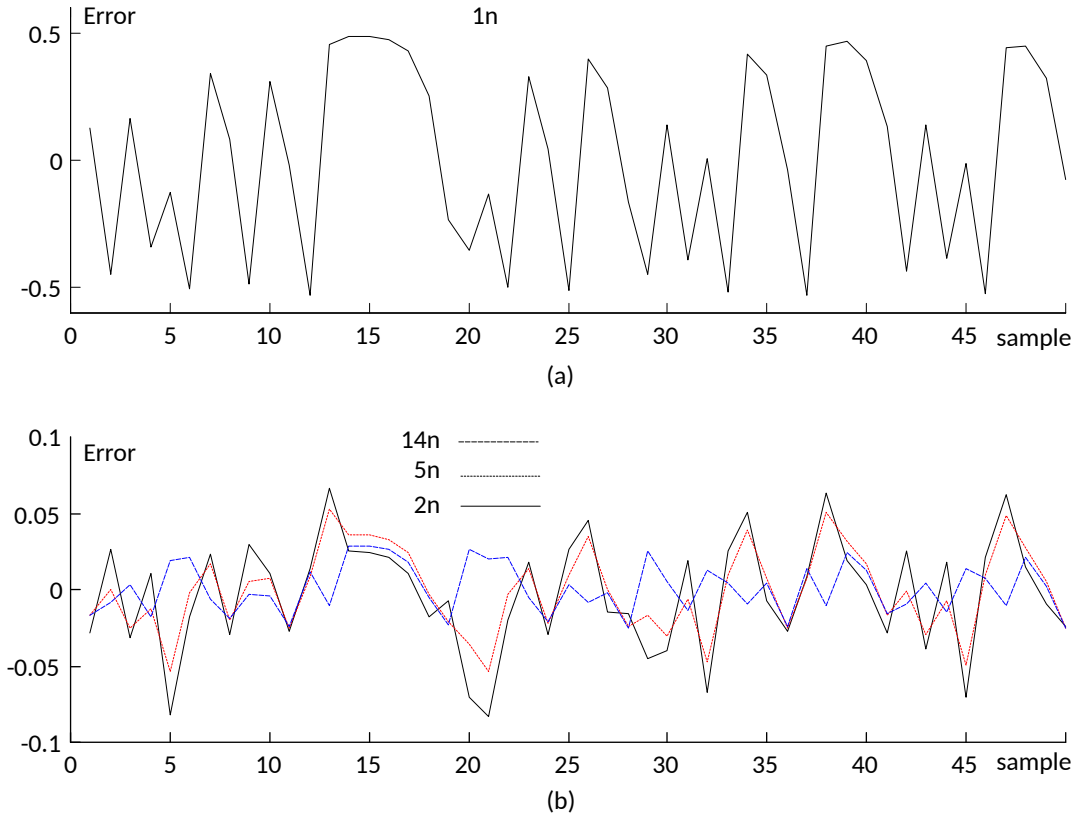


Figura 4.6: Error de Aproximación para el Sistema Caótico para 1, 2, 5 y 14 Neuronas en la Capa Oculta.

Red	Error
$\|x1n - x\|_2$	2.5569
$\|x2n - x\|_2$	0.2577
$\|x5n - x\|_2$	0.1921
$\|x14n - x\|_2$	0.1157

Cuadro 4.2: Error de Aproximación para 1,2,5 y 14 Neuronas.

a utilizar y el número *no* de neuronas de la capa oculta del Perceptrón, parámetros constituyentes de la estructura LNet. Una vez obtenido el modelo deseado, es necesario validarlo.

4.4 Validación.

La validación del modelo forma la etapa final de un proceso de identificación. Básicamente existen dos enfoques complementarios para la validación del modelo:

Validación cruzada ("cross-validation"). Este enfoque consiste en dividir a los datos disponibles en dos conjuntos disjuntos denominados: α de entrenamiento (ver ecuación 2.19) y β de prueba (ver ecuación 2.20). El conjunto de entrenamiento es utilizado para la obtención del modelo, mientras que el conjunto de prueba es usado en la verificación de la generalización del modelo. Este último punto que constituye un tópico de investigación en si mismo, se refiere a la capacidad del modelo de predecir correctamente valores que no se encontraban en el conjunto de prueba. El proceso de entrenamiento comienza con los datos del conjunto α mediante el cual se ajusta al modelo. A medida que el proceso de entrenamiento avanza el error de entrenamiento disminuye en forma monótona, mientras que el error de prueba disminuye hasta un cierto instante t_0 a partir del cual comienza a incrementarse como puede apreciarse en la Figura 4.7. Este instante t_0 indica en qué momento comienza a producirse el sobreajuste de los parámetros. De ésta forma, el conjunto de datos de prueba se utiliza para evaluar como generaliza el modelo ajustado y para prevenir el sobreajuste de parámetros.

Autovalidación ("autovalidation"). Este enfoque consiste en verificar la correlación de algunas señales, típicamente entradas, salidas y residuos, del conjunto α de entrenamiento. Este tipo de prueba provee información valiosa sobre las estructuras de los modelos y sobre posibles términos no modelados. Sin embargo si es utilizado como único elemento de validación, tiende a producir un sobreajuste del conjunto de datos de entrenamiento. Para aliviar este inconveniente han sido utilizado índices similares al de Aikike (Aikike's Prediction Index [48]) etc. Dichos índices ponderan en forma positiva a los modelos que tienen menor número de parámetros en detrimento de aquellos que utilizan un número mayor.

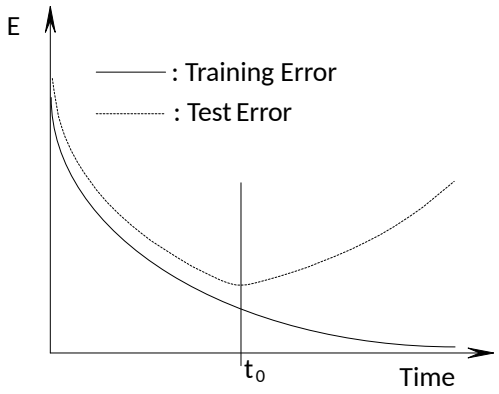


Figura 4.7: Errores de Entrenamiento y Prueba en un Proceso Típico de Aprendizaje.

La mayoría de los pruebas cuantitativas o de autovalidación están basadas en cálculos de ciertas correlaciónes: se verifica si los residuos están correlacionados con las señales de entrada o entre ellos mismos (autocorrelacionados). Llegada esta instancia del proceso de identificación se dispone de un modelo $\widetilde{\Sigma}$ del sistema Σ, tal que para un proceso aleatorio u de la entrada aplicado simultáneamente a $\widetilde{\Sigma}$ y a Σ, la diferencia $\xi = y - \widetilde{y}$ entre sus salidas, es un proceso aleatorio de media cero distribuido idénticamende de forma independiente ($i.d.d$) y el cual es independiente del proceso de salida. Dicha hipótesis debe ser verificada para lo cual se utilizan correlaciones. La correlación entre dos variables cualesquiera u, e y, se define como:

$$\phi_{uy}(\tau) = E[u(k)\, y(k-\tau)] = E[u(k+\tau)\, y(k)],$$

donde $E[\cdot]$ representa al operador matemático esperanza. Cuando la cantidad de datos de que se dispone es finita, la esperanza se convierte en la esperanza muestral, una sumatoria sobre los np valores disponibles

$$\phi_{uy}(\tau) = \frac{1}{N} \sum_{k=1}^{np-\tau} u(k+\tau)\, y(k).$$

Es deseable escalar a estos coefiecientes de forma tal que $-1 \leq \hat{\phi}_{uy}(\tau) \leq 1$, entonces el coeficiente de correlación se define como

$$\hat{\phi}_{uy}(\tau) = \frac{1}{np} \frac{\sum_{k=1}^{np-\tau} u(k+\tau)\, y(k)}{\sqrt{\hat{\phi}_{uu}(0)\ \hat{\phi}_{yy}(0)}}.$$

Para validar sistemas lineales son suficientes correlaciones de entradas salidas y residuos de primer orden, sin embargo para sistemas no lineales es necesario definir momentos de órden superior [5]. Estas son

$$\left|\begin{array}{ll} \phi_{\xi\xi}(\tau) & = \delta(\tau) \\ \phi_{u\xi}(\tau) & = 0 \quad \forall\tau \\ \phi_{\xi\xi u}(\tau) & = E\left[\xi(k)\,\xi(k-1-\tau)\,u(k-1-\tau)\right] = 0 \quad \tau \geq 0 \\ \phi_{u^{2\prime}\xi}(\tau) & = 0 \quad \forall\tau \\ \phi_{u^2\xi^2}(\tau) & = 0 \quad \forall\tau \end{array}\right. , \tag{4.17}$$

donde $u(k)$ es la secuencia de entrada, $y(k)$ e $\widetilde{y}(k)$ las secuencias de salida del sistemas y modelo respectivamente y $\xi(k) = y(k) - \widetilde{y}(k)$ la secuencia de residuos en el instante k, para $k : 1, \ldots, np$. La tilde en una variable indica que le ha sido substraído su valor medio,

$$u'(k) = u(k) - \overline{u}.$$

Si el número de datos np es suficientemente grande el desvío estandar de la estimación de los coeficientes de correlación es de $1/\sqrt{np}$. El intervalo de confianza para un valor de un 95% estará dado entonces por $\pm 1.96/\sqrt{np}$. Este valor sugiere que con un nivel de confianza del 95%, no se puede rechazar la hipótesis de que el modelo es válido si el valor absoluto de los tests presentados está por debajo de $1.96/\sqrt{np}$ [5]. Dichas pruebas representan un medio útil, que usados conjuntamente con la validación cruzada, permite establecer cualitativamente cuán bueno resulta un modelo. En la siguiente sección se muestra un resúmen de la metodología de identificación propuesta.

4.5 Sumario de la Metodología de Modelado.

Se asumirá que existen suficientes pares de datos np de entrada-salida para realizar la aproximación $[u(k), y(k)]$, $k = 1, \ldots, np$. Luego:

1. Evaluar el polo de los sistemas de Laguerre de acuerdo a la ecuación 4.1.

2. Evaluar el número m_0 de sistemas de Laguerre utilizando los coeficientes de Lipschitz λ.

Filtrar a los datos disponibles mediante los sistemas de Laguerre evaluados en #1 para formar la matriz $\mathbf{Z} : [np \times m]$ como en la ecuación 4.4. Luego evaluar m_0 utilizando la ecuación 4.9. Como resultado se obtiene la matriz $\mathbf{Z} : [np \times m_o]$ con $\mathbf{z}(k) = [z_1(k), \cdots, z_{m_0}(k)]$, $k : 1, \ldots, np$. Luego comenzar el proceso de entrenamiento con el conjunto de datos $(\mathbf{z}(k), y_k)$, $k : 1, \ldots, np$.

3. Evaluar el número de neuronas de la capa oculta utilizando la técnica de valores singulares.

   Luego de un tiempo de que el proceso de entrenamiento comenzó, detenerlo y propagar a la matriz de datos $\mathbf{Z}$ a través de la capa oculta para obtener a la matriz $\mathbf{X}_o = \phi(ZW_1)$. En este punto la matriz $\mathbf{X}_o : [np \times no]$, donde no es el número de neuronas de la capa oculta y np el número de patrones de entrenamiento. Descomponer en valores singulares a la matriz $\mathbf{X}_o$ y seleccionar la cantidad de neuronas adecuadas en la capa oculta de acuerdo al criterio expresado en la sección 4.3

4. Continuar el entrenamiento y validar la estructura LNet.

4.6 Conclusiones.

En este capítulo fue presentada la metodología para determinar la estructura LNet: cantidad de sistemas de Laguerre y número de neuronas en la capa oculta. La utilización de los denominados coeficientes de Lipschitz, cuyo uso se fundamenta en la continuidad del operador LNet ha demostrado ser un instrumento útil para la evaluación del número de sistemas. En la estimación de la cantidad de neuronas de la capa oculta, se utilizó una variación de las técnicas de "pruning". Dicha técnica se basa en una descomposición en valores singulares de la matriz de datos propagada a través de la capa oculta. Finalmente se presentaron los procedimientos necesarios para validar al modelo obtenido. En el capítulo siguiente, se ilustrará con varios ejemplos la aplicación de la metodología presentada.

Capítulo 5

Ejemplos de Aplicación.

Este capítulo presenta diversos ejemplos para ilustrar la aplicación de la metodología de modelación presentada, resaltando cada uno facetas específicas de los aspectos de modelado. El primer ejemplo ilustrará la capacidad de la metodología de modelación presentada para hallar la estructura correcta de un sistema no lineal discreto, invariante en el tiempo, causal y que posee memoria evanescente. En segundo término se presentará un caso de cancelación de eco no lineal para ilustrar las ventajas de la estructura LNet sobre un FIR No Lineal, respecto de la cantidad de términos que son necesarios utilizar para aproximar a un sistema dado. El último de los ejemplos que serán presentados considera la aplicación de la metodología propuesta en el modelado de una columna de destilación binaria de alcoholes. Incluído en el aspecto de modelado se considerará una posible extensión a sistemas MISO, para la cual se expondrán los resultados obtenidos. Adicionalmente se presentarán pautas de diseño que permitan utilizar al modelo LNet de la columna en una estrategia de control predictivo, concluyendo el capítulo con algunas consideraciones generales.

5.1 Sistema no Lineal Discreto.

A través del presente ejemplo se ilustrará la capacidad de la metodología de modelación presentada para obtener la estructura correcta de un sistema no lineal discreto, invariante en el tiempo, causal y que posee memoria evanescente. El sistema de la ecuación 5.1 cumple evidentemente con las anteriores condiciones y además por su estructura posee una representación LNet particular. Puede ser pensado como la expan-

sión del sistema lineal mediante sistemas de Laguerre (cuyos coeficientes resultan ser los pesos de una única neurona), seguido por una función sigmoidal. Para dicho sistema se aplicará la metodología de aproximación presentada, comparándose las aproximaciones obtenidas por la estructura LNet y la estructura cascada-paralelo de Korenberg. En el caso del modelo LNet se presentará los resultados de evaluación de la estructura en presencia de ruido aditivo de salida, culminando el ejemplo la validación del modelo obtenido. A continuación se detallará el sistema a ser utilizado.

5.1.1 Descripción del Sistema y Condiciones de Identificación.

Sea el sistema no lineal discreto, similar al presentado en [64], descripto por el siguiente conjunto de ecuaciones:

$$\begin{aligned} x(k+1) &= Ax(k) + Bu(k) \\ y(k) &= Cx(k) + Du(k) \\ yn(k) &= (1+\exp(y(k)+7))^{-1} \end{aligned} \quad , \tag{5.1}$$

donde las matrices involucradas se muestran a continuación:

$$A = \begin{bmatrix} 1.4 & -.61 & .084 \\ 1.0 & 0 & 0 \\ 0 & 1.0 & 0 \end{bmatrix}, B = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, C = \begin{bmatrix} 1.6 & -.61 & .084 \end{bmatrix}^T, D = [0].$$

Claramente se puede apreciar que el sistema representado por el conjunto de ecuaciones

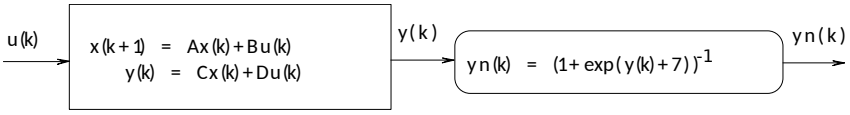


Figura 5.1: Sistema No Lineal Discreto.

5.1 tiene memoria evanescente dado que está compuesto por un subsistema lineal dinámico en cascada con una transformación no lineal como se puede ver en la Figura 5.1. Cabe destacar que la función $yn(k) = (1+\exp(y(k)+7))^{-1}$ involucrada es del tipo sigmoidal. Para proceder a la identificación se generó un secuencia de entrada de 300 valores $\{u(k)\}_{k=1}^{300}$ en base a una distribución Equiprob con una probabilidad de cambio $pr = .5$, escalada entre $[-1, 1]$. Al aplicar dicha secuencia al sistema y registrar su salida

se formó el conjunto de valores $\{u(k), yn(k)\}_{k=1}^{300}$ de los cuales los primeros 150 constituyeron el conjunto α de entrenamiento y los últimos 150 el conjunto β de validación. Con dichos conjuntos se aplicó la metodología de aproximación propuesta obteniéndose los siguientes resultados.

5.1.2 Resultados de Aproximación.

El primer paso de la metodología de aproximación es evaluar el polo de los sistemas de Laguerre. Un simple cálculo muestra que los autovalores de la matriz A son $\text{eig}(A) = \{.7, .4, .3\}$. Para mostrar la robustez del método respecto de la elección del polo, dicho parámetro fue seleccionado como $a = .72$ un valor muy cercano al polo dominante que el subsistema lineal posee en .7. Una vez evaluado dicho polo se formó la matriz de datos $\mathbf{Z} : [150 \times 15]$ como en la ecuación 4.4 mediante los 150 valores de la entrada del conjunto de entrenamiento α filtrados por los sistemas $l_0(k), \ldots, l_{14}(k)$. Para evaluar el comportamiento de la metodología en presencia de ruido aditivo de salida, se adicionó ruido a la salida $yn(k)$ de la siguiente forma

$$\overline{yn}(k) = yn(k) + \zeta(k),$$

donde $\overline{yn}(k)$ es la salida con ruido y $\zeta(k)$ es una variable con distribución gaussiana. El porcentaje de ruido se midió de la siguiente forma

$$\text{Porcentaje de ruido } [\%] = \frac{\|\overline{yn}(k)\|_2}{\|yn(k)\|_2} 100,$$

donde $\|\cdot\|_2$ representa la norma aplicada a una secuencia en l_2. En la Figura 5.2 pueden ser apreciadas dos gráficas que representan a los coeficientes de Lipschitz evaluados según la ecuación 4.8 para la salida $\overline{yn}(k)$ con un ruido gaussiano del 10% y para $yn(k)$ con 0% de ruido. En ambos casos es fácil apreciar que no existe un decrecimiento sensible de los coeficientes de Lipzchits para un $m > 7$, hecho que está indicando un relativa robustez de los coeficientes respecto del ruido.En base a este análisis la cantidad de sistemas de Laguerre fue seleccionada como $m_0 = 7$. El siguiente paso en la metodología, fue comenzar a entrenar una red con 3 neuronas en al capa oculta y 7 entradas. En base al análisis de los valores singulares realizado con los primeros 30 valores de la señal de

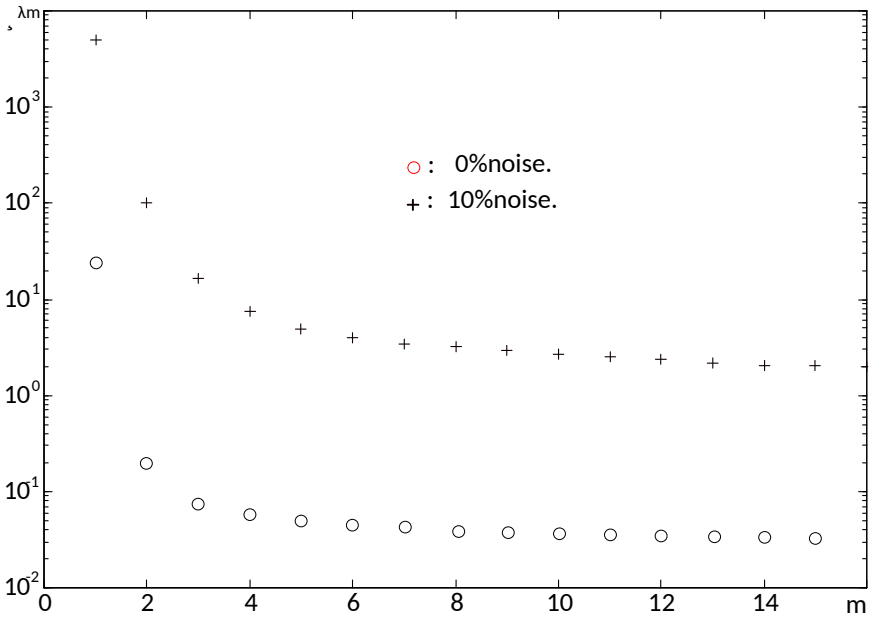


Figura 5.2: Coeficientes de Lipschitz del para el Sistema No Lineal Discreto.

entrenamiento se obtuvo la matriz $\mathbf{\Sigma}_0$ (ver ecuación 4.16)

$$\mathbf{\Sigma}_o = diag\left\{7.9366,\, 0.0781,\, 0.0059\right\},$$

por lo que se evaluó que una neurona sería suficiente. Cabe destacar que dado la particular estructura de este sistema no lineal, una neurona es el número exacto que debería tener el Perceptrón. Es fácil ver que con una neurona, se cubren las necesidades de la transformación no lineal, por lo que el resto de la aproximación realizado por la estructura LNet consiste en aproximar al subsistema lineal mediante los sistemas de Laguerre. Consideremos a continuación la expansión del sistema lineal en base a sistemas de Laguerre. La Figura 5.3 ilustra a los coeficiente escalados por un factor de 2 de la expansión en sistemas de Laguerre del subsistema lineal y a los pesos de la neurona de la capa oculta del Perceptrón. En este caso, los coeficientes de la expansión están estrechamente relacionados a los pesos de la neurona de la capa oculta. La existencia de una factor de 2 se explica por la diferencia en el dominio $[-1, 1]$ de la sigmoide utilizada en el Perceptrón (ecuación 4.12) y el dominio $[0, 1]$ de la función del sistema no lineal en la ecuación 5.1.Cabe destacar que debido a la fuerte saturación que está incluida en el sistema discreto es imposible aproximar al sistema no lineal por uno lineal: por ejemplo, la identificación del sistema no lineal mediante sistemas de Laguerre da como

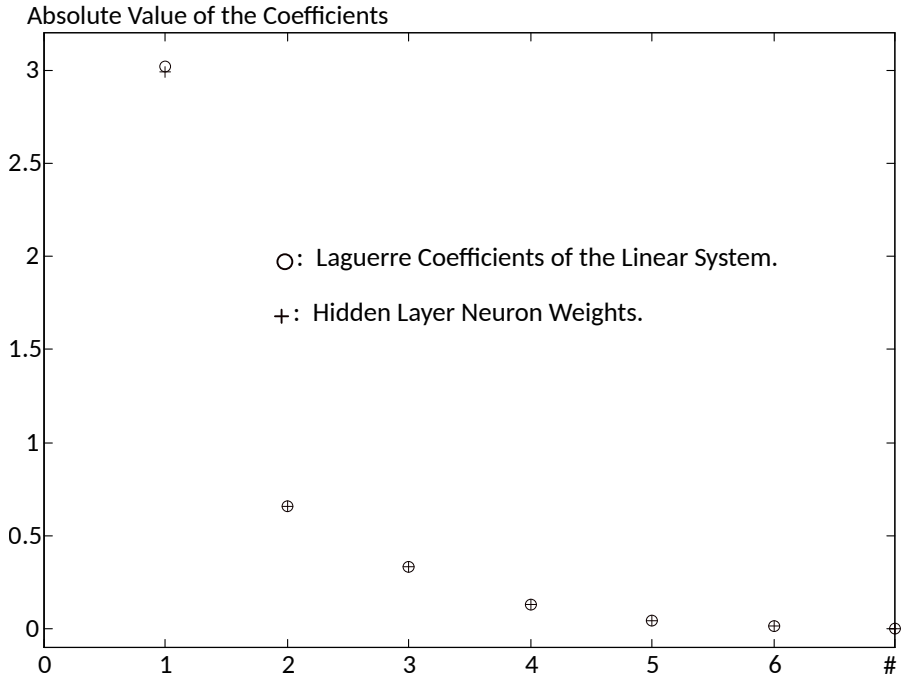


Figura 5.3: Coeficientes de la Expansión de Laguerre del Subsistema Lineal y Pesos de la Neurona de la Capa Oculta del Perceptrón.

resultado un conjunto de coeficientes oscilatorios que no converge. Finalmente el modelo LNet se constituyó con siete sistemas de Laguerre y un Perceptrón de una capa oculta con una única neurona. Los mismos datos fueron utilizados para la aproximación de la estructura LNet y la de Korenberg de cascadas en paralelo. El modelo de Korenberg fue ajustado de acuerdo al procedimiento definido en la Sección 2.3.1 bajo los siguientes supuestos. El número de cascadas en paralelo fue limitado a 12, debido a que al aumentar dicha cantidad solo se conseguía un decrecimiento ínfimo en el error. La longitud de la respuesta impulsiva de cada uno de los sistemas lineales dinámicos fue limitado a 30 dado que no se obtenían mayores mejoras más allá de este número. El orden de los polinomios fue limitado a 12 por la inestabilidad numérica que se producía para calcular los coeficientes de los polinomios para un orden superior. Dentro de ese límite se implementó una búsqueda del orden óptimo. Los resultados de aproximación se pueden apreciar en la Figura 5.4 donde claramente se aprecia que la estructura LNet supera a la de Korenberg, al conseguir un error de aproximación de aproximadamente dos órdenes de magnitud.Los resultados de la validación del modelo pueden ser apreciados en la Figura 5.5 indicando un buen ajuste del modelo LNet. Es fácil apreciar que la correlación $\phi_{\xi\xi}(\tau)$ es un impulso unitario mientras que las restantes correlaciones se ecuentran dentro de

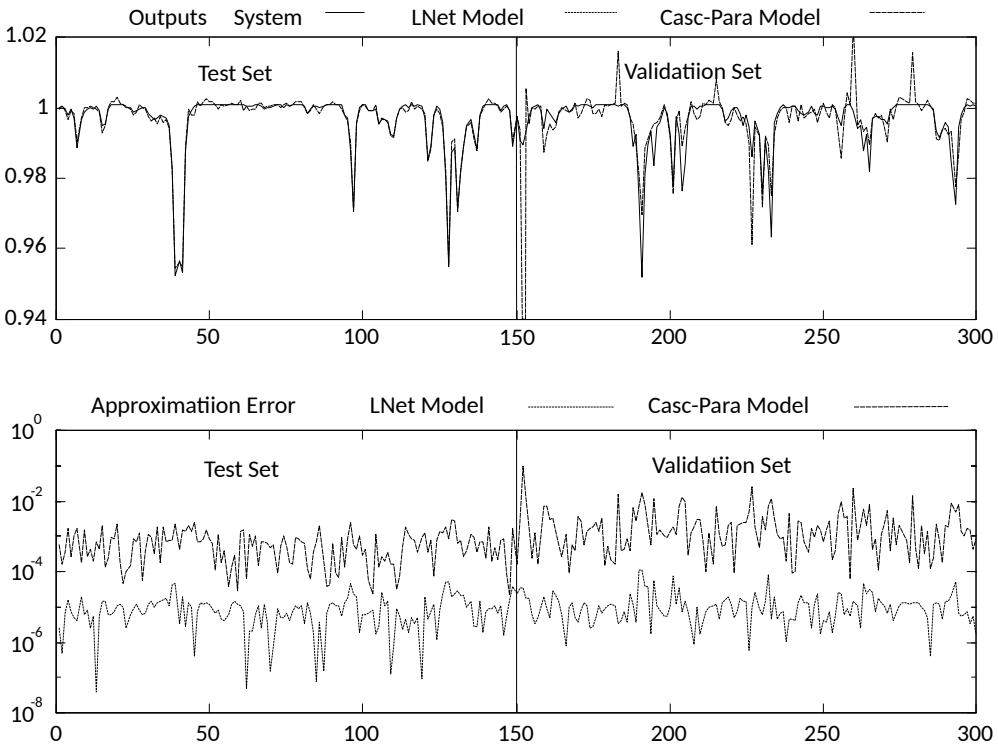


Figura 5.4: Aproximación y Error de Aproximación del Sistema No Lineal Discreto.

los límites de confidencia del 95%. Dicho comportamiento establece que los residuos no pueden ser predichos por ninguna combinación lineal o no lineal de las entradas y las salidas, reflejando un buen ajuste del modelo LNet.

5.1.3 Discusión de los Resultados.

El presente ejemplo ilustró la capacidad de la metodología de modelación presentada para obtener la estructura correcta de un modelo LNet, al modelar a un sistema no lineal discreto, invariante en el tiempo, causal y que posee memoria evanescente. Si bien es cierto que el sistema utilizado no se corresponde con ninguno físico, sí cuenta con una importante característica presente en la mayoría de los sistemas reales: la saturación [43], [42]. Para dicho sistema se implementó la metodología de aproximación presentada, comparándose las aproximaciones obtenidas por la estructura LNet y la estructura cascada-paralelo de Korenberg. Los resultados de aproximación indican claramente que la estructura LNet supera a la de Korenberg, al conseguir un error de aproximación de aproximadamente dos ordenes de magnitud menor. Más aun, la determinación de los parámetros fundamentales se mostró relativamente robusta frente a la presencia de ruido

aditivo a la salida, otra característica habitualmente presente en los sistemas reales.

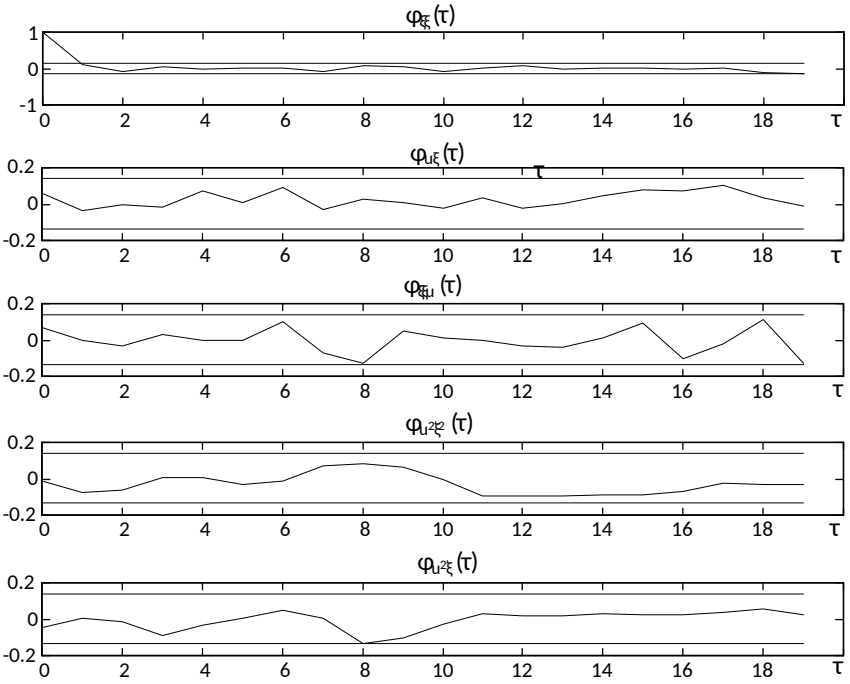


Figura 5.5: Validación del Modelo LNet para el Sistema no Lineal Discreto.

5.2 Cancelación de Eco en un Línea Telefónica.

En el presente ejemplo serán mostradas las ventajas de la estructura LNet sobre un FIR no Lineal respeto de la cantidad de términos que son necesarios utilizar para aproximar un sistema dado. Dicha ventaja se debe a la mayor riqueza dinámica de la estructura LNet y se manifiesta en sistemas que justamente no sean un FIR no Lineal. La comparación se basará en una aplicación de cancelación de eco en una línea telefónica, cuyo esquema básico se encuentra detallado en la Figura 5.6. Dicho ejemplo ha sido seleccionado por dos motivos. En primer lugar, resulta ser la reproducción de uno presentado en [42] lo cual brinda la posibilidad de realizar comparaciones entre los resultados obtenidos. La segunda razón es que el sistema seleccionado pertenece a una clase que resulta difilcultosa de aproximar mediante sistemas de Laguerre [6]. Se aproximará la composición $h_2 \circ g_2 \circ h_1 \circ g_1$ de elementos en cascadas no lineales estáticos ($g_2(\cdot)$, $g_1(\cdot)$) y lineales dinámicos ($h_2(s)$, $h_1(s)$) donde $g_1(\cdot)$ impone un severa no linealidad en la entrada. Este tipo de operadores es dificultoso de aproximar con sistemas de Laguerre,

debido a que resulta ser un sistema que contiene escencialmente la no linealidad en la entrada, y se desea aproximarlo con un modelo que posee su no linealidad a la salida [6]. Se presentarán resultados de las aproximaciones obtenidas para diversas estructuras del tipo LNet y FIR no Lineal, del sistema que se describe a continuación.

5.2.1 Descripción del Sistema.

La Figura 5.6 esquematiza a una aplicación de cancelación de eco en el extremo cercano ("near-end") de una línea telefónica. La señal digital $r(k)$ en el extremo cercano es convertida en analógica por el conversor digital analógico (CDA representado por la función g_1) y conformada por el filtro pasa-bajos lineal de transmisión (cuya respuesta impulsiva es $h_1(s)$) para producir la señal analógica $\widetilde{r}(t)$. El circuito híbrido separa a $\widetilde{r}(t)$ de la señal $s(t)$ recibida en el extremo lejano ("far-end") direccionando a $\widetilde{r}(t)$ por la línea de transmisión. Al mismo tiempo direcciona a $s(t)$ a través del filtro lineal de recepción (cuya respuesta impulsiva es $h_2(s)$) y del dispositivo mantenedor S/H. Se supone que dicho dispositivo mantenedor es ideal. Debido a las pérdidas en el circuito híbrido, la salida $\widetilde{d}(t)$ contiene contribuciones de $s(t)$ y de una forma de "eco" atenuada proveniente de $\widetilde{r}(t)$. El camino del eco a través del circuito híbrido está representado por la función g_2, mientras que la función g_3 representa al camino de la señal del extremo lejano. Las funciones g_1, g_2, g_3, g_4 son estáticas y se suponen sin histéresis.La tarea del cancelador

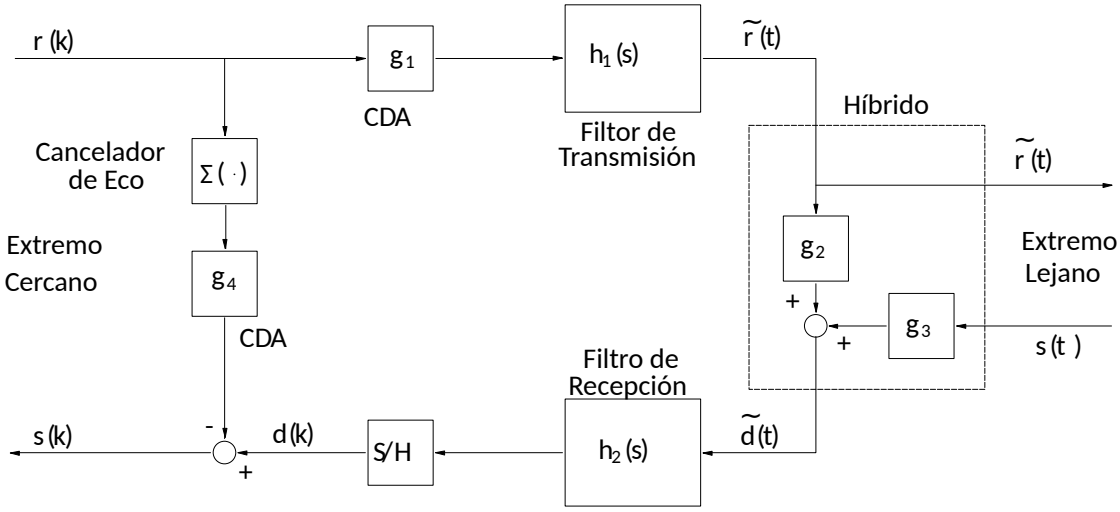


Figura 5.6: Cancelación de Eco en una Línea Telefónica

de eco $\Sigma(\cdot)$ consiste en estimar el componente de eco presente en $d(k)$ y cancelarlo.

Despreciando los efectos de la señal del extremo lejano, la tarea del cancelador de eco no lineal[1] sería la de realizar al sistema $g_4^{-1} \circ h_2(s) \circ g_2 \circ h_1(s) \circ g_1$. Siguiendo el camino de la señal $\widetilde{r}(k)$ es posible expresar que:

$$\widetilde{d}(t) = g_3(s(t)) + g_2(\widetilde{r}(t)).$$

Si se consideran despreciables los efectos de g_3, la expresión anterior puede notarse como

$$\widetilde{d}(t) = s(t) + g_2(\widetilde{r}(t)).$$

Por otro lado

$$\widetilde{r}(t) = h_1 \circ g_1(r(k)),$$

lo cual lleva a considerar a $\widetilde{d}(t) = s(t) + g_2 \circ h_1 \circ g_1(r(k))$ que luego del retenedor S/H notaremos como

$$d(k) = h_2 \circ s(t) + h_2 \circ g_2 \circ h_1 \circ g_1(r(k)).$$

La tarea a realizar por el cancelador de eco se puede expresar como $g_4 \circ \Sigma(r(k))$ de forma tal que al ser sumado a $d(k)$ pueda cancelar a la componente no deseada del eco expresada por $h_2 \circ g_2 \circ h_1 \circ g_1(r(k))$. Matemáticamente:

$$d(k) = h_2 \circ s(t) + \overbrace{h_2 \circ g_2 \circ h_1 \circ g_1(r(k)) - g_4 \circ \Sigma(r(k))}^{0}.$$

Igualando este útimo término a cero (reduciendo la influencia del eco), se puede conseguir la expresión del sistema que deberá implementar el cancelador de eco

$$g_4 \circ \Sigma(r(k)) = h_2 \circ g_2 \circ h_1 \circ g_1(r(k)),$$

con lo cual

$$\Sigma(k) = y(k) = g_4^{-1} \circ h_2 \circ g_2 \circ h_1 \circ g_1(r(k)). \tag{5.2}$$

Dicho operador no lineal posee claramente memoria evanescente, dado que resulta de la composición en cascada de funciones no lineales estáticas sin histéresis con sistemas

[1]Un cancelador de eco no lineal es necesario cuando se combinan ciertas condiciones de atenuación en el circuito híbrido y en la línea de transmición que imposibilitan la utilización de un cancelador de eco lineal [42, pag. 747].

lineales dinámicos. Para el presente ejemplo presentado en [42, ejemplo 3, pag. 748] se harán las siguientes consideraciones:

- g_3, g_4 se consideran como la función identidad.
- $g_1(u) = u^3$, (ver Figura 5.7)
- $g2(u) = 2\tan^{-1}(5u) + .25u$ (ver Figura 5.7)
- $h_1(s) = (s + .75)^{-1}$, filtro de transmisión.
- $h_2(s) = .2(s + .75)^{-1}$, filtro de recepción.

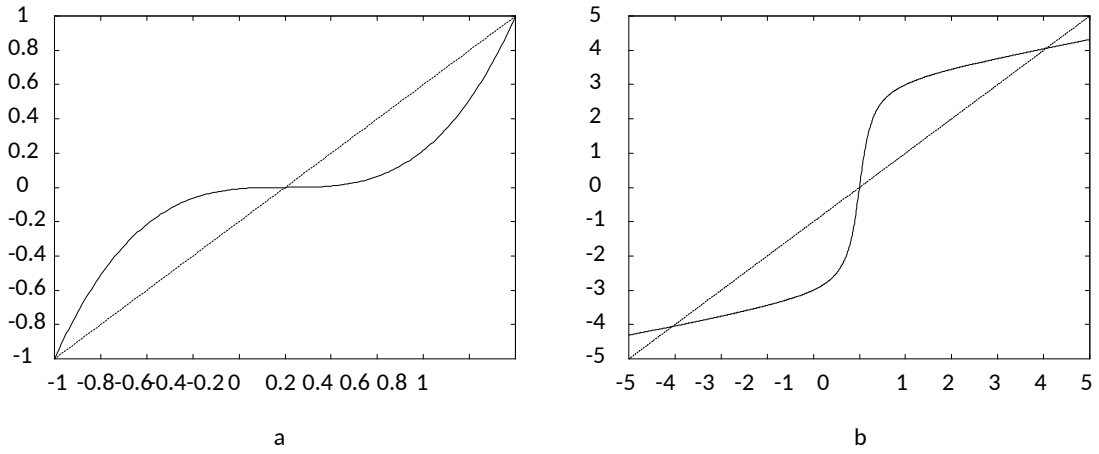


Figura 5.7: a) Función g_1(conversor D/A). b) Función g_2 (retorno del eco).

A continuación se compararán los resultados de aproximación de la estructura LNet con los logrados por un red de valores retrasados.

5.2.2 Resultados de Aproximación.

Se muestra que la estructura LNet necesita de menor cantidad de parámetros que un FIR no lineal o red de valores retrasados descripta por la ecuación 2.10, que por simplicidad denominaremos NFIR. Expresado de forma alternativa, es lo mismo que decir que para Perceptrones de las mismas cantidad de entradas y de neuronas, la aproximación lograda por la estructura LNet es superior a la lograda por un NFIR. Para mostrarlo se procederá a identificar estructuras LNet y NFIR cuyos perceptrones respectivos posean la misma cantidad de entradas y neuronas de la capa oculta. En el

Estructura	**Sistemas/Entradas Atrasadas**	**Neuronas**	**Error en db.**
LNet	4	7	-12.8151
NFIR	4	7	-5.3284

Cuadro 5.1: Estructuras y Errores de Aproximación: configuración 1.

caso de la estructura LNet las entradas al Perceptrón serán las salidas de los filtros de Laguerre. En el caso de la estructura NFIR, simplemente serán las entradas atrasadas. Para el caso de la estructura LNet no se seguirá el procedimiento de modelado dado que el objetivo perseguido es mostrar las ventajas de la estructura respecto a la economía de términos. Las funciones transferencia de los filtros de transmisión y recepción

$$\begin{aligned} h_1(s) &= (s+.75)^{-1} \\ h_2(s) &= .2(s+.75)^{-1} \end{aligned},$$

admiten una aproximación discreta que considerando un tiempo de muestreo $T = 1$ puede ser expresada como

$$\begin{aligned} h_1(q^{-1}) &= .5276q^{-1}(1+.4724q^{-1})^{-1} \\ h_2(q^{-1}) &= .1045q^{-1}(1+.4724q^{-1})^{-1} \end{aligned}, \tag{5.3}$$

donde claramente se aprecia un polo en .4724. Como una forma de mostrar la robustez del método respecto de la elección del polo de los sistemas de Laguerre, dicho parámetro se seleccionó como $a = .49$ cercano al valor .4724 del polo de los filtros de la ecuación 5.3. Para proceder a la identificación del operador 5.2 se generó un secuencia de entrada de 1000 valores $\{r(k)\}_{k=1}^{1000}$ en base a una distribución Equiprob con una probabilidad de cambio $pr = .1$. Al aplicar dicha secuencia al sistema y registrar sus salida se formó un conjunto de valores $\{r(k), y(k)\}_{k=1}^{1000}$ con los cuales se entrenaron diversas estructuras LNet y NFIR. En primer término fueron comparadas una estructura LNet con cuatro sistemas de Laguerre y un Perceptrón de 7 neuronas con una estructura NFIR con cuatro entradas atrasadas y un Perceptrón de 7 neuronas como lo indica la Tabla 5.1. Fueron utilizadas en ambos casos las mismas matrices de pesos inicializadas en valores aleatorios y el mismo algoritmo de entrenamiento. Dicho algoritmo se utilizó en ambos casos durante el mismo número de 100 iteraciones, al final de las cuales se detuvo el entrenamiento y se evaluaron las salidas aproximadas. La aproximación del NFIR puede ser apreciada en la Figura 5.8 y la de la estructura LNet en la Figura 5.9. Para una

Estructura	Sistemas/Entradas Atrasadas	Neuronas	Error en db.
LNet	6	15	-20.1111
NFIR	6	15	-9.6584

Cuadro 5.2: Estructuras y Errores de Aproximación: configuración 2.

mayor facilidad en la comparación de los resultados, el error de aproximación se expresó en db de acuerdo a la siguiente ecuación:

$$\text{Error en db} = 20 \log \left(\frac{\|y - \widetilde{y}\|_2}{\|y\|_2} \right),$$

donde y es la salida del sistema, $\widetilde{y}$ la salida aproximada y $\|\cdot\|_2$ la norma para secuencias en l_2.De la Tabla 5.1 se puede apreciar que la estructura LNet supera en este caso a la NFIR

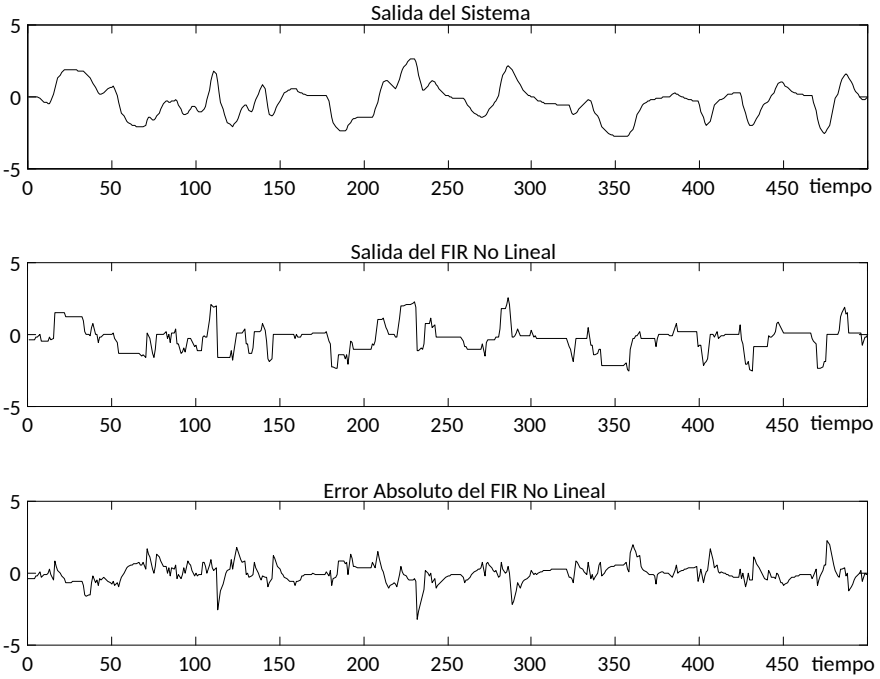


Figura 5.8: NFir con 4 Entradas y 7 Neuronas.

en aproximadamente 7db. Repitiendo el procededimiento anterior para una estructura LNet con 6 sistemas de Laguerre y un Perceptrón de 15 neuronas y para una estructura NFIR con 6 entradas atrasadas y un Perceptrón de 15 neuronas se obtuvieron los datos indicados en la Tabla 5.2. Los resultados de las aproximaciones se pueden apreciar en la Figura 5.10 para la estructura NFIR y en la Figura 5.11 para la estructura LNet.De la Tabla 5.2 es fácil ver que nuevamente la estructura LNet supera en la aproximación

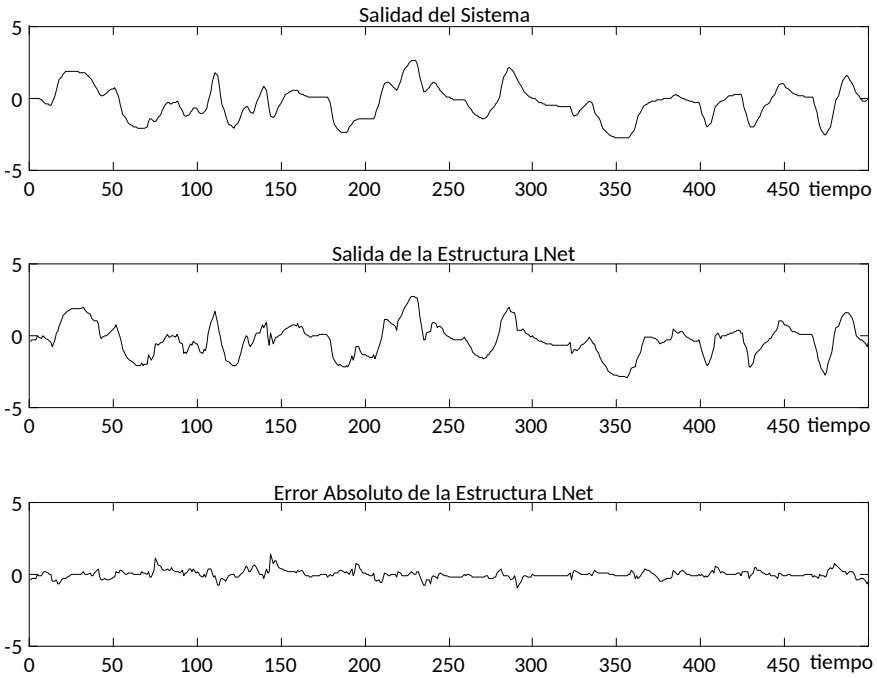


Figura 5.9: LNet con 4 Sistemas de Laguerre y 7 Neuronas.

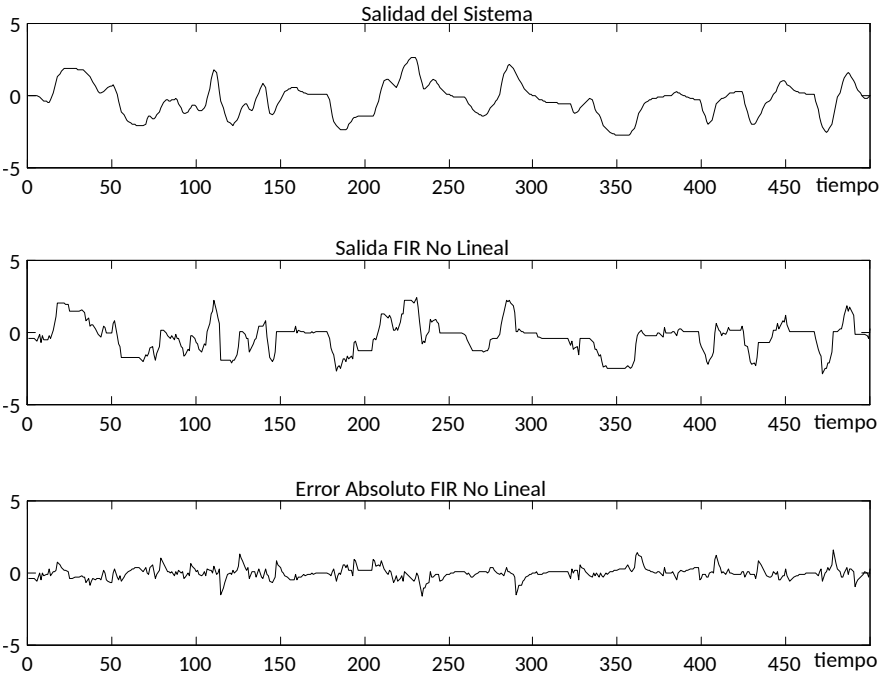


Figura 5.10: NFir con 6 Entradas y 15 Neuronas.

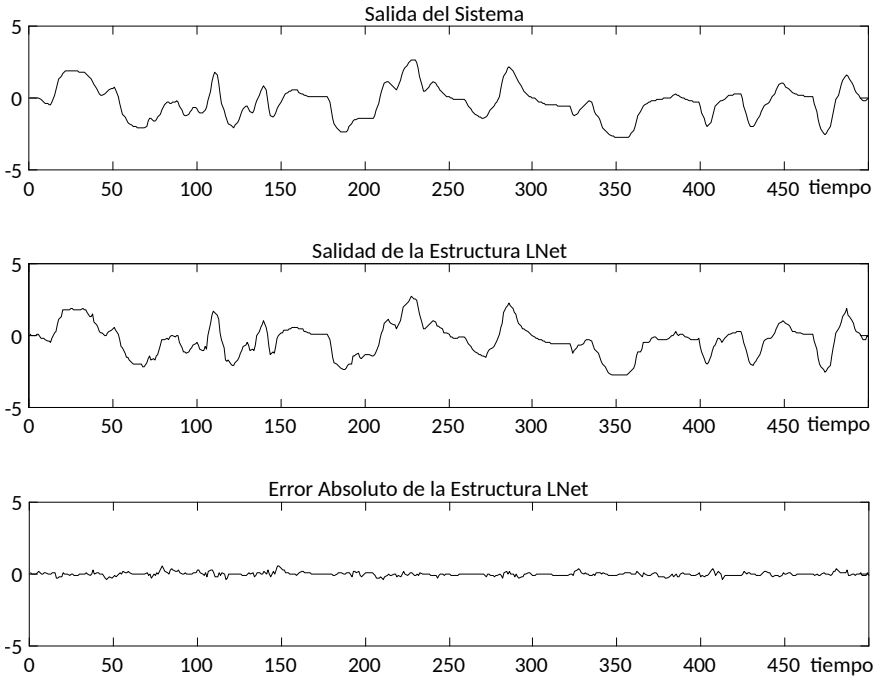


Figura 5.11: LNet con 6 Sistemas de Laguerre y 15 Neuronas.

a la NFIR en aproximadamente 10 db. Para un resultado aproximadamente igual fue necesario utilizar una NFIR con 15 entradas y 20 neuronas en la capa oculta lo cual contrasta notablemente con en Perceptrón de 6 entradas y 15 neuronas que precisa la estructura LNet. Similares resultado son mostrados en el ejemplo 2 de [42], en el cual el rechazo de 21 db es alcanzado por un NFIR (denominado Filtro Perceptrón) con una estructura de 20 entradas y 50 neuronas para un sistema más simple de memoria finita.

5.2.3 Discusión de los Resultados.

El presente ejemplo mostró las ventajas de la estructura LNet sobre un FIR no Lineal respecto de la cantidad de términos que son necesarios utilizar para aproximar un sistema dado. La comparación se basó en una aplicación de cancelación de eco en una línea telefónica, sistema que resulta difilcultoso de aproximar mediante sistemas de Laguerre (Ver [6]). Dicho sistema fue seleccionado para no favorecer en la comparación a una estructura en perjuicio de la otra. Los resultados fueron comparados con los presentados en [42], mostrando una clara ventaja de la estructura LNet respecto de los NFIR. En el mismo trabajo [42] es presentada la estructura de aproximación mostrada por la ecuación 2.11 siendo ilustrado su comportamiento en el caso de cancelación de eco no

lineal para modelos de tercer y quinto órden. Dicha estructura recurrente de tercer órden logra una mejor aproximación (-29 db) con menor cantidad de términos que la estructura LNet, pero a expensas de utilizar un algoritmo de entrenamiento mucho más complicado.

5.3 Columna Binaria de Alcoholes.

En este ejemplo aplicaremos la metodología propuesta en el modelado de una columna de destilación binaria de alcoholes. Adicionalmente se presentarán pautas de diseño que permitan utilizar al modelo LNet de la columna en una estrategia de control predictivo. Se presentarán para dicha columna los resultados de aproximación obtenidos para las estructuras LNet y Cascada-Paralelo de Korenberg (para posibilitar su comparación). Adicionalmente se mostrará cómo es posible extender las ideas de modelación presentadas para contemplar sistemas MISO, lo cual será ejemplificado mediante la inclusión en el modelo LNet de otra entrada, resultante de considerar medible a la perturbación en el nivel de la línea de alimentación (Ver Figura 5.12). Dicho modelo LNet MISO será comparado con un modelo MISO lineal en variables de estado. Concluirá el ejemplo con la presentación de una estrategia de control predictivo en la cual se utiliza el modelo LNet SISO. A continuación presentaremos una descripción del sistema involucrado.

5.3.1 Descripción del Sistema.

Para realizar este estudio se empleó un modelo dinámico (ver Apéndice C) cuya aproximación bilineal fuera implementada como en [13]. El modelo se aplicó para el caso de una separación de alcoholes considerando un flujo molar constante y definiéndose un valor de volatilidad relativa invariante en el tiempo para cada plato. Resultados similares de aproximación y control para dicha columna binaria fueron presentados en [65]. Para el modelo LNet SISO de esta sección se considera como entrada al caudal de reflujo y como salida a la concentración del destilado (ver esquema en la Figura 5.12).Para el sistema así considerado, la Figura 5.13 ilustra como un aumento en el caudal de reflujo introducido en la columna incrementa la pureza del producto destilado. Dicha figura permite apreciar tres regiones: baja pureza ($X < .95$), purezas medias ($.95 \leq X \leq .99$) y alta pureza ($X > .99$). El sistema puede ser aproximado por sendos modelos lineales en las regiones de baja pureza (recta tangente l_1) y de alta pureza (recta tangente l_2)

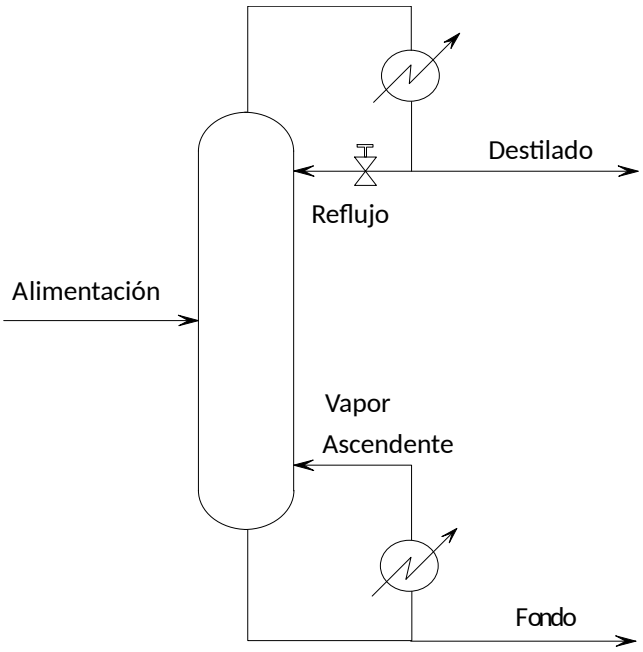


Figura 5.12: Esquema de la Columna de Destilación Binaria de Alcoholes.

como es fácil ver del apartado de la Figura 5.13. De la apreciación de dicha figura resulta simple concluir que a medida que se transita de la región de baja pureza a la de alta pureza el comportamiento no lineal se manifiesta claramente. La gran diferencia en las pendientes de las rectas l_1 y l_2 constituye una muestra concreta de dicho comportamiento. Ninguna línea recta pude aproximar la totalidad del rango comprendido entre $.95 \leq X$ y $X \leq .99$ independientemente de como se intente trazar.Esta constituye la razón por la cual interesa un buen modelo en dicha región, por lo que se decidió aproximar a la concentración del destilado de la columna para los valores comprendidos en $[.94, 1]$. Para proceder a la identificación se generó un secuencia de entrada (reflujo) de 600 valores $\{u(k)\}_{k=1}^{600}$ en base a una distribución Equiprob con una probabilidad de cambio $pr = .5$. Tal señal fue convenientemente escalada para producir una salida (concentración del destilado) en el rango deseado formando un conjunto de valores $\{u(k), y(k)\}_{k=1}^{600}$ de los cuales los primeros 300 constituyeron el conjunto α de entrenamiento y los últimos 300 el conjunto β de validación. Las variaciones de la salida en respuesta a las variaciones en la entrada fueron obtenidas integrando el conjunto de ecuaciones diferenciales C.1 considerando un retenedor de orden cero incluido en la entrada para un período de muestreo $dt = .01$. Las próxima dos secciones presentarán los resultados de aproximación obtenidos con la estructura LNet y por el método de Korenberg.

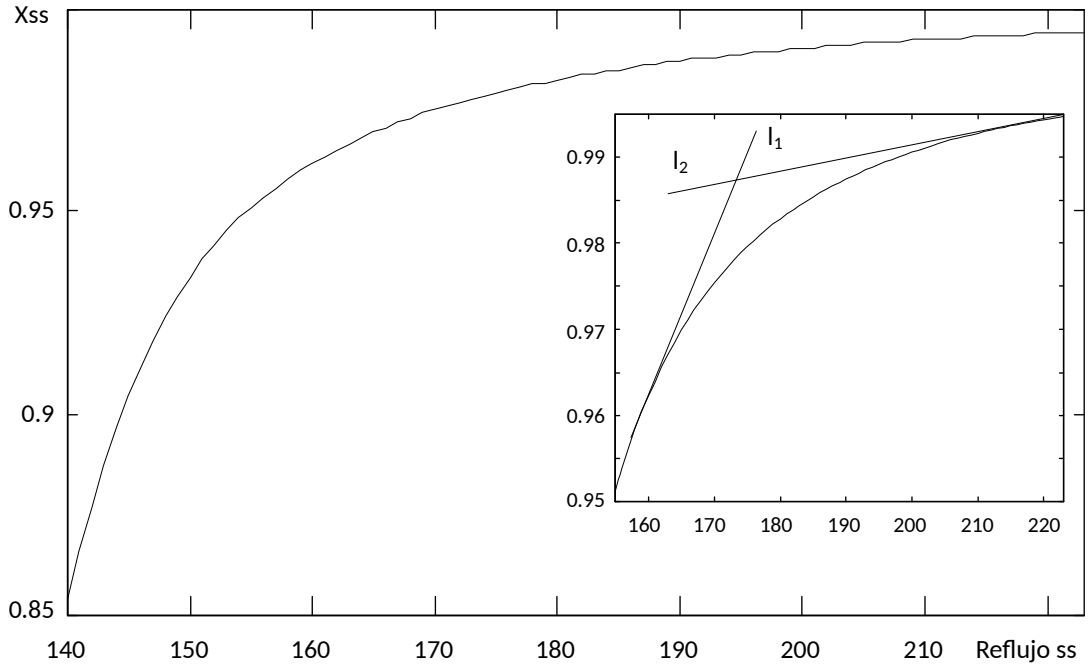


Figura 5.13: Destilado en el Estado Estacionario para Diferentes Valores del Reflujo.

5.3.2 Resultados de Aproximación.

Modelo Cascada Paralelo.

Para obtener el modelo de cascadas en paralelo de Korenberg se siguió el procedimiento definido en la Sección 2.3.1 haciendo las siguientes suposiciones. El número de cascadas en paralelo fue limitado 20, debido a que más allá de dicho número solo se conseguía un decrecimiento ínfimo al aumentar la cantidad de cascadas. La longitud de la respuesta impulsiva de cada uno de los sistemas lineales fue limitada a 30 dado que no se obtuvieron mayores mejoras más allá de dicho número. El orden de los sistemas fue limitado a 15 por la inestabilidad numérica que se producía para un orden superior. Dentro de ese límite se implementó una búsqueda del orden óptimo. Los resultados de aproximación pueden ser apreciados para el modelo obtenido en la Figura 5.15. En el apartado b) de dicha figura se puede apreciar al error de aproximación para los conjuntos α de prueba (cuya norma es $\|Er_\alpha\|_2 = .0161$) y β de validación (cuya norma es $\|Er_\beta\|_2 = .0489$).

Estructura LNet.

El primer paso en el procedimiento de aproximación consiste en estimar el polo a de los sistemas de Laguerre. Dicho polo fue evaluado como $a = .55$ dado que para ese valor la salida del sistema $l_0(k)$ refleja mejor a la constante de tiempo principal del sistema. Para evaluar el número de sistemas de Laguerre se siguió el procedimiento de la Sección 4.2. La matriz $\mathbf{Z}$ (ver ecuación 4.4) se formó utilizando la señal de entrada filtrada por los sistemas $l_0(k), \ldots, l_9(k)$ procediéndose luego a evaluar a los coeficientes de Lipschit. Los resultados de tal evaluación se pueden apreciar en la Figura 5.14. Es fácil ver que para $m > 5$ no hay una mejora significativa al agregar más sistemas, por lo cual el número de sistemas seleccionados fue $m_0 = 5$. Resta solamente definir la cantidad de neuronas en la capa oculta. Siguiendo el procedimiento de la Sección 4.3, se comenzó el entrenamiento con 30 neuronas utilizando solo las primeras 40 muestras del conjunto de entrenamiento α. Luego de un tiempo se detuvo el proceso de entrenamiento propagándose la matriz de datos $\mathbf{Z}$ a través de la capa oculta para obtener la matriz X_0. Se muestran a continuación los primeros cinco valores singulares de dicha matriz, dado que los restantes resultaron prácticamente cero

$$\Sigma_0 = diag\{7.9860, 5.0998, 1.9002, 0.1999, 0.0643\}.$$

El número de neuronas de la capa oculta fue seleccionado en 5 procediéndose luego a terminar el proceso de entrenamiento para la estructura seleccionada. Dicha estructura LNet resultó compuesta por un conjunto de 5 sistemas de Laguerre y un Perceptrón de 5 neuronas en la capa oculta. El apartado a) de la Figura 5.15 ilustra la aproximación obtenida para la estructura LNet. En el apartado b) de dicha figura se puede apreciar el error de aproximación para los conjuntos de prueba α (cuya norma es $\|Er_\alpha\|_2 = .0034$) y β de validación (cuya norma es $\|Er_\beta\|_2 = .012$).Como último paso se procedió a la validación de la estructura LNet cuyos resultados son ilustrados en la Figura 5.16.Es fácil apreciar que la correlación $\phi_{\xi\xi}(\tau)$ es un impulso unitario mientras que las restantes correlaciones se ecuentran dentro de los límites de confidencia del 95%. Dicho comportamiento establece que los residuos no pueden ser predichos por ninguna combinación lineal o no lineal de las entradas y las salidas. Se comprueba fácilmente que el modelo LNet obtenido es válido y mejora ostensiblemente a los resultados obtenidos para

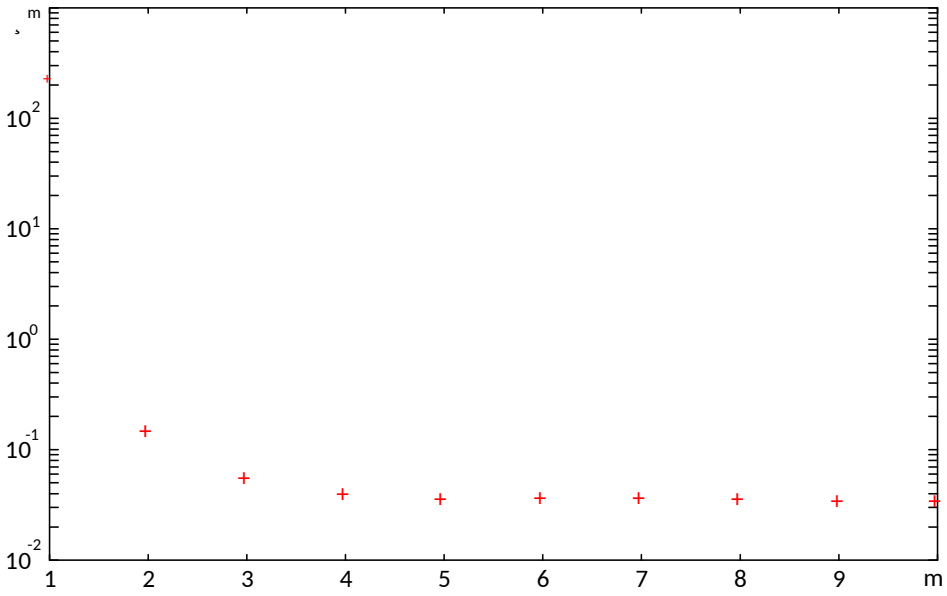


Figura 5.14: Coeficientes de Lipschitz para la Columna.

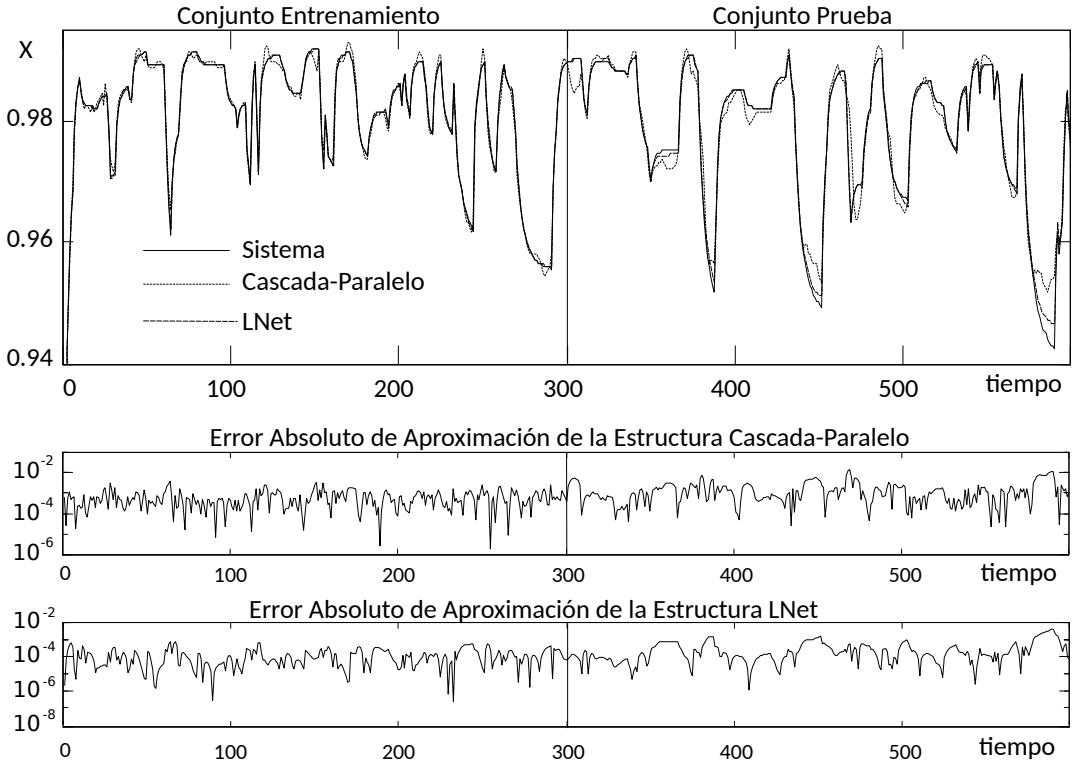


Figura 5.15: Aproximación del Destilado por los Modelos SISO LNet y de Cascadas en Paralelo.

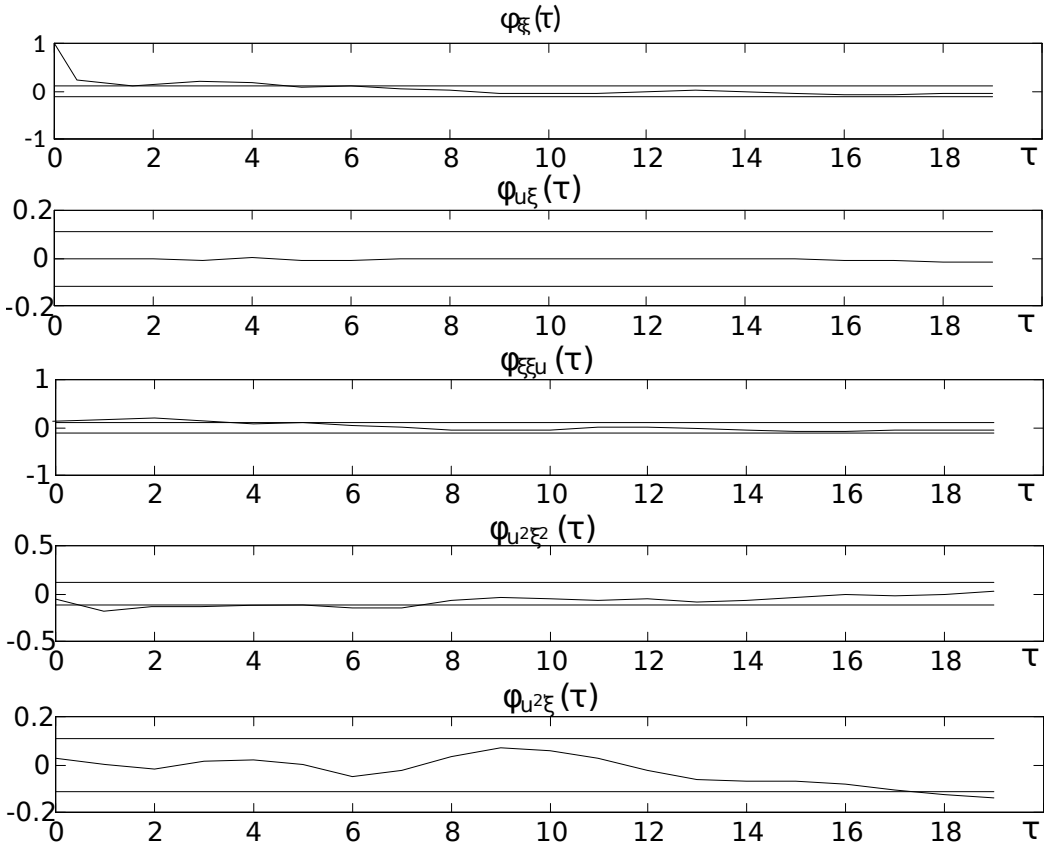


Figura 5.16: Validación del Modelo LNet para la Columna.

la estructura de cascadas en paralelo. A continuación veremos un ejemplo de como la estructura LNet puede ser extendida para considerar sistemas MISO.

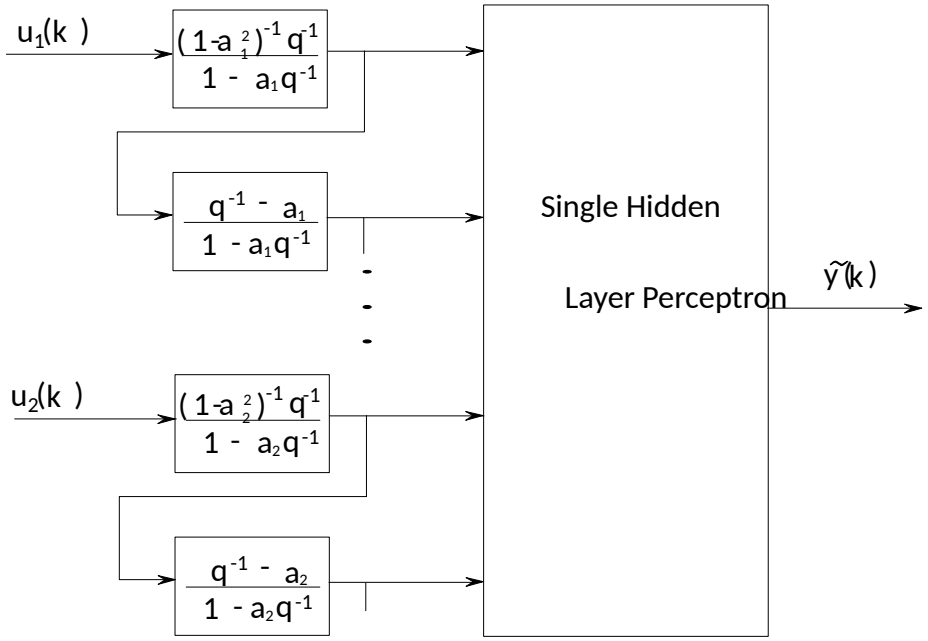


Figura 5.17: Extensión MISO Propuesta para la Estructura LNet.

Modelo MISO de la Columna.

E l modelo LNet fue expandido incluyendo una segunda entrada $u_2(k)$ en la forma esquematizada en la Figura 5.17. Dicha concepción de un modelo LNet MISO resultó ser útil en la práctica aun cuando resta formular una demostración formal de sus capacidades de aproximación. Para realizar al modelo LNet MISO fueron utilizados cinco sistemas de Laguerre (con un $a_1 = .55$) relacionados a la entrada $u_1(k)$ del reflujo y dos sistemas de Laguerre (con $a_2 = 0$) relacionados a la entrada $u_2(k)$ de la perturbación del nivel de entrada (considerado medible). El modelo LNet resultante estuvo constituido por 7 sistemas de Laguerre y un Perceptrón con 9 neuronas en la capa oculta. Para comparar los resultados obtenidos se utilizó un modelo lineal en variables de estado de orden 3, identificado utilizando el paquete de Identificación de Matlab. En la Figura 5.18 pueden ser apreciados los resultados de la aproximación de ambos modelos. Dicha figura presenta las variaciones producidas en el destilado respecto de las variaciones del reflujo (escala inferior izquierda) y de las variaciones porcentuales en el caudal de la alimentación (escala inferior derecha). Es fácil ver que la estructura LNet supera en la calidad de la

aproximación al modelo lineal en todo el dominio de aproximación. A continuación se desarrollarán aspectos relacionados al control predictivo.

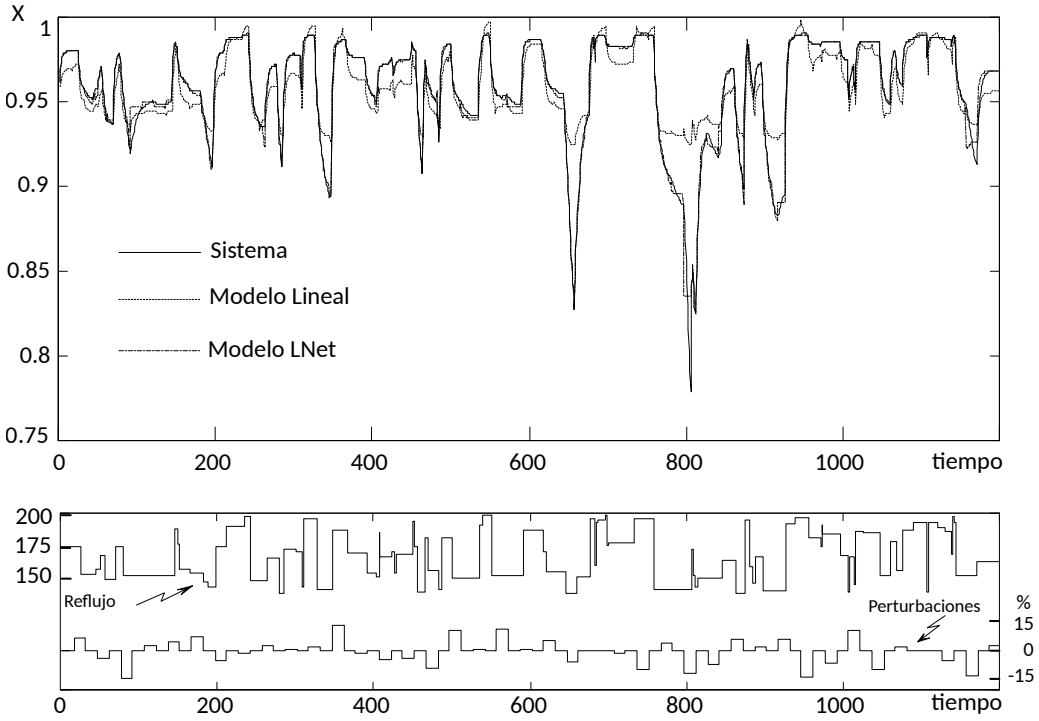


Figura 5.18: Modelos Miso LNet y Lineal para la columna.

5.3.3 Aspectos Generales de Control Predictivo.

La principal característica de los esquemas de control predictivo radica en la utilización explícita de un modelo dinámico del sistema para evaluar los efectos de las futuras acciones de control sobre las salidas del sistema. Entre las aplicaciones particulares que se pueden citar se encuentran los algoritmos de "Dinamic Matrix Control [25]" y "Algorithmic Model Control [21]". En ambos casos la acción de control en el tiempo t proviene de minimizar un cierto índice de performance que puede involucrar tanto estados, salidas y entradas como también restricciones sobre algunos de ellos. Aplicaciones particulares utilizanado modelos basados en redes neuronales pueden ser halladas en [18], y [25], mientras que en [19] se utilizó un modelo basado en wavelets. Dichas implementaciones se basan en esquemas tipo NARMAX como los de la Sección 2.3.2. En [12] fueron utilizados modelos basados en Redes Neuronales Recurrentes. En este último trabajo se utiliza una red recurrente para modelar la función no lineal que relaciona los

estados con sus derivadas asumiendo que todos los estados son medibles. Para el caso que dichos estados no lo fueran, en [45] se plantea la utilización de observadores no lineales. Sin embargo todos los esquemas mecionados resultan de gran complejidad requiriendo tiempos de entrenamiento prolongados para la obtención de los modelos.

En [44] es tratado el problema del denominado "Receding Horizon Control" de sistemas no lineales que estén expresados en variables de estados. El problema está planteado como el de controlar el estado x del sistema en el tiempo t, determinando la entrada de control u^o que resuelve un problema de control óptimo con restricciones sobre el intervalo $[t, t+T]$. El problema de control óptimo con restricciones es usualmente planteado como el de minimizar una funcional cuadrática sobre el intervalo de tiempo $[t, t+T]$ sujeto a que $x(t+T) = 0$. El parámetro T es elegido de forma tal que sea mayor que el máximo tiempo requerido para llevar al sistema desde cualquier estado al origen. La restricción $x(t+T) = 0$ impuesta en el tiempo T asegura la estabilidad [44]. Como es sugerido en [44] el problema de control puede ser además discretizado en el tiempo de forma de reducir el problema de control óptimo a un problema de programación no lineal de dimensiones finitas. A continuación se verá cómo se pueden utilizar los modelos LNet en estrategias de control predictivo.

Control Predictivo LNet.

La formulación del problema de control es planteada como:

$$\begin{array}{l} \min \sum_{j=1}^{T} \left\| y_{t+j} - yd_{t+j} \right\|^2 m_j + \sum_{j=1}^{T_1} \left\| \Delta u_{t+j-1} \right\|^2 n_j \\ \text{st } \Delta u_j = u_j - u_{j-1} = 0, \quad j = T_1, \ldots, T \end{array} , \tag{5.4}$$

donde $\{u_t\}$, $\{y_t\}$, $\{yd_t\}$, son las secuencias de entrada, salida y referencia respectivamente. La acción de control Δu en el tiempo t es elegida como el primer elemento de la secuencia solución del anterior problema de optimización $\left\{u_t^o, ..., u_{t+N_1-1}^o\right\}$. Las secuencias m_j y n_j se utilizan para variar las características de control. Mayne [44] sugirió que T debería ser seleccionado como un valor mayor al tiempo de establecimiento del sistema para brindar un cierto grado de estabilidad al problema de control. En la formulación del modelo LNet, la parte dinámica es lineal y está representada por los sistemas de Laguerre. El mayor comportamiento dinámico es debido al sistema de Laguerre $l_n(k)$ de mayor

orden utilizado en el modelo. Un forma de acotar el horizonte de tiempo T es aproximar al sistema $l_n(k)$ por sus primeros N términos, como si fuera un FIR, suponiendo que la contribución de los términos de orden superior es despreciable y luego tomar $T > N$. Sea $G_n u$ (ecuación 3.12) la respuesta de $l_n(k)$ a la entrada u considerando la respuesta impulsiva infinita de $l_n(k)$. Y sea $G_n^N u$ la aproximación a $G_n u$ mediante los primeros N términos de la respuesta impulsiva de $l_n(k)$. Para acotar a T se procederá a evaluar la relación $\left|G_n^N u\right| / \left|G_n u\right|$, relación que tiende a uno a medida que $N \to \infty$. Luego es necesario seleccionar un N para el cual dicha relación sea aproximadamente igual a 1 y tomar $T > N$. Haciendo $G_n v = 0$ en las ecuaciones 3.13 y 3.12 se puede mostrar que

$$\frac{\left|G_n^N u\right|}{\left|G_n u\right|} \leq 1 - 2r^N + r^{N+1}, \tag{5.5}$$

donde $|a| < |r| < 1$. El valor de r se selecciona para acotar al valor del módulo del polo a. Como dicho valor es menor a 1, es fácil ver que a medida que $N \to \infty$, es decir cuando se toman todos los términos de la respuesta impulsiva, la relación de la ecuacción 5.5 tiende a la unidad como lo esquematiza la Figura 5.19. Esto muestra una cota mínima

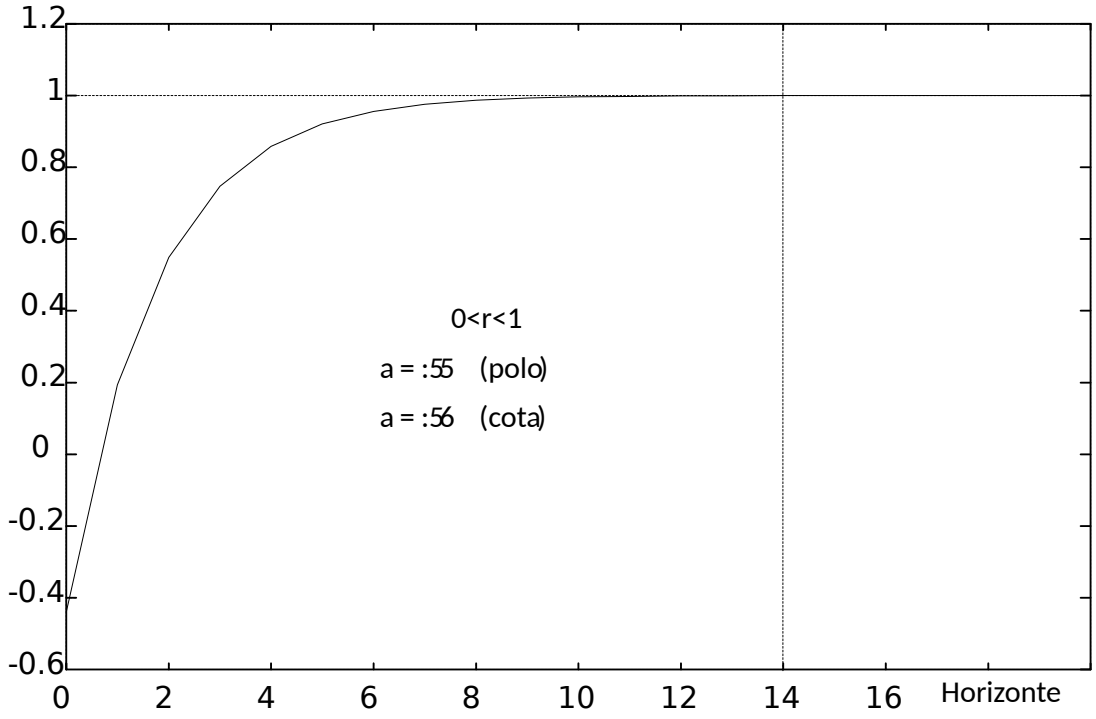


Figura 5.19: Cota al Horizonte de Control para la Columna.

al mayor comportamiento dinámico considerando solamente los primeros N términos de

Modelo	**Horizonte** T	**Secuencia** m_j	**Secuencia** n_j
Lineal	15	10	.05
LNet	15	10	.01

Cuadro 5.3: Parámetros Utilizados en el Algoritmo de Control.

$l_n(k)$. De esta forma se dispone de un medio para evaluar el T necesario, simplemente seleccionando al valor de $T > N$ para el cual la relación 5.5 se acerca a la unidad. A continuación se verá como se aplica el modelo LNet SISO de la sección anterior en el presente esquema de control predictivo. Dicho modelo está constituido por 5 sistemas de Laguerre cuyo polo es $a = .55$. En la Figura 5.19 se puede apreciar la cota mínima en el horizonte de control evaluada para un polo $a = .55$ como el del modelo con un valor de $r = .56$. Del análisis precedente es fácil ver que es necesario seleccionar a $T > 14$ para asegurar cierto grado de estabilidad. Finalmente el valor seleccionado para el horizonte de control fue $T = 15$. Para comparar los resultados de control utilizando el modelo LNet, fue identificado un modelo discreto lineal de tercer orden en variables de estado utilizando el paquete de identificación de MATLAB^{TM}. Para realizar las comparaciones en control se utilizó el mismo algoritmo de control predictivo con ambos modelos. Dicho algoritmo fue probado controlando al sistema en tres diferentes puntos de operación sujeto a diversas perturbaciones en el nivel de la línea de alimentación. El perfil de composiciones deseado yd fue determinado por la siguiente ecuación a diferencias:

$$yd(k) = .4u(k) + .6yd(k-1),$$

donde yd es la concentración del destilado deseada y u es el reflujo (variable manipulada). Los parámetros del algoritmo de control de la ecuación 5.4 pueden ser observados en la Tabla 5.3 para el caso del modelo lineal y del modelo LNet. Los resultados de la utilización de ambos modelos en la estrategia de control predictivo previamente discutida se pueden apreciar en la Figura 5.20. En dicha figura se puede apreciar que se lleva al sistema a operar en tres regiones distintas marcadas por la pureza de su destilado de .992, .962 y .977 lo que obliga al sistema a transitar por su región de máxima no linealidad. En la misma figura se puede apreciar a las perturbaciones introducidas al caudal de la alimentación, cuyo nivel porcentual se aprecia en la escala inferior derecha. Es posible ver de la Tabla 5.3 que la secuencia n_j debió ser incrementada en el caso del modelo

lineal. Se tubo que proceder de esta forma debido a que con un modelo lineal fue imposible conseguir un control más rápido sin oscilaciones. De la gráfica es claro deducir que el control logrado con el modelo LNet supera al logrado utilizando el modelo lineal.

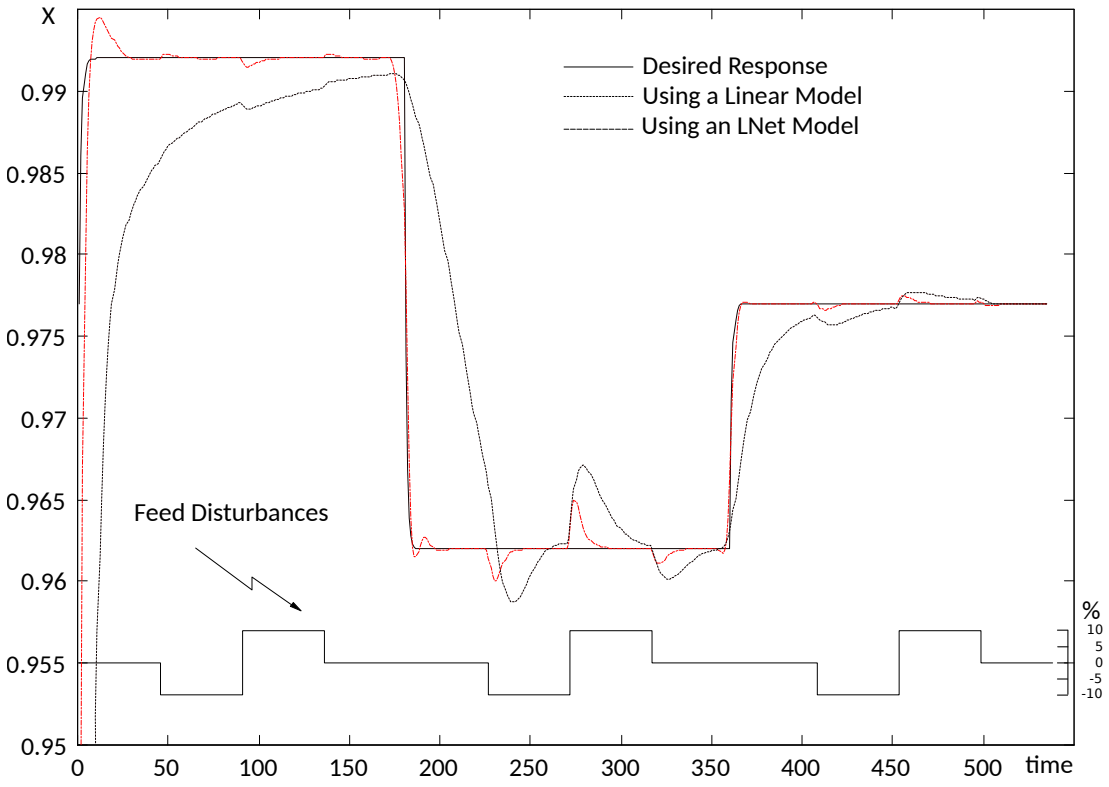


Figura 5.20: Resultados de Control de la Columna.

5.3.4 Discusión de los Resultados.

En el presente ejemplo se aplicó la metodología propuesta en el modelado de una columna de destilación binaria de alcoholes. El modelo LNet obtenido fue comparado con la estructura Cascada-Paralelo de Korenberg. Dicha comparación resultó favorable a la estructura LNet. Se mostró además como es posible extender las ideas de modelación presentadas para contemplar sistemas MISO, hecho que fue ejemplificado a través de la reformulación del modelo LNet de la columa incorporando otra entrada. Dicho modelo LNet MISO fue comparado con un modelo MISO lineal en variables de estado, concluyendo el ejmplo con la presentación de una estrategia de control predictivo en la cual se utilizó el modelo LNet SISO. A continuación presentaremos las conclusiones generales del Capítulo.

5.4 Conclusiones.

En este capítulo se presentaron diversos ejemplos ilustrando facetas específicas de la metodología de modelación desarrollada. El primer ejemplo ilustró la capacidad de la metodología de modelación presentada para hallar la estructura correcta de un sistema no lineal discreto, invariante en el tiempo, causal y que posee memoria evanescente. En segundo término se presentó un caso de cancelación de eco no lineal para ilustrar las ventajas de la estructura LNet sobre un FIR No Lineal, respecto de la cantidad de términos que son necesarios utilizar para aproximar a un sistema dado. El último de los ejemplos presentados consideró la aplicación de la metodología propuesta en el modelado de una columna de destilación binaria de alcoholes. El aspecto de modelado consideró una extensión para sistemas MISO. Adicionalmente fueron presentadas pautas de diseño que permiten utilizar los modelos LNet en una estrategia de control predictivo.

Capítulo 6

Conclusiones y Recomendaciones.

En esta tesis se presentó a la estructura de aproximación para sistemas no lineales discretos LNet. Comenzó la exposición con el planteamiento de la temática de aproximación de sistemas, particularmente orientada a la identificación de modelos entrada-salida no lineales. De la gran variedad de dichos modelos fueron seleccionados aquellos con una buena fundamentación teórica y representativos de su clase. Dentro de los modelos tradicionales fueron citados la serie de Volterra, la serie de Wiener, el modelo de bloques en cascadas y el modelo de cascadas de bloques en paralelo de Korenberg. Dicho modelo fue elegido para ser comparado con la estructura LNet porque supera la mayoría de las dificultades presentadas por los anteriores y por lo simple de su utilización. Con igual criterio se procedió a seleccionar a los modelos citados basados en redes neuronales: el modelo de red de valores retrasados y el modeo NARMAX. En este caso la selección resultó ardua debido a la gran diversidad de modelos neuronales existentes y en muchos casos, a la carencia de resultados que aseguran que un dado modelo es capaz de aproximar a un sistema de determinadas características. En este sentido la presente tesis pretende realizar un aporte caracterizando a los sistemas que pueden ser aproximados por la estructura LNet y desarrollando una metodología para su identificación. La estructura clásica de entradas atrasadas o FIR no lineal fue elegida de los modelos neuronales para ser comparada con la estructura LNet. Fueron definidos los conceptos de neurona, capa y topología conjuntamente con un marco general para especificar sistemas no lineales discretos que contienen redes neuronales. Cabe aclarar que este marco si bien es suficientemente general como para incluir a una gran diversidad de modelos neuronales, no admite a aquellos en los que no pueda ser desarrollado el concepto de

capa. Dicho marco fue utilizado para definir a la estructura LNet.

La estructura LNet está compuesta por un conjunto de sistemas discretos de Laguerre relacionados de forma no lineal mediante un Perceptrón de una capa oculta. Tal esquema si bien es similar al de Wiener, se diferencia principalmente de este por la utilización de un Perceptrón de una capa oculta. Dicho Perceptrón, elemento característico de la estructura LNEt, es el que permite obtener aproximaciones realizables en la práctica. Si se compara a la estructura LNet con el esquema original de Wiener, es fácil apreciar que el Perceptrón reemplaza a los polinomios de Hermite. Se mostró que la cantidad de coeficientes involucrados en el esquema de Wiener crece exponencialmente con las dimensiones del modelo. Suponiendo que se utilizaran 10 sistemas de Laguerre y un polinomio de Hermite de orden 2 serían necesarios del orden de 2^{10} coeficientes. Al respecto fueron presentados resultados que demuestran la conveniencia de utilizar redes neuronales como aproximadores universales de funciones no lineales en lugar de otros tipos de aproximadores como los polinomios. Se demostró que la estructura LNet es capaz de aproximar operadores no lineales, discretos, casuales, invariantes en el tiempo y que poseen memoria evanescente. Para realizar la demostración de las capacidades de aproximación de la estructura LNet fueron definidos los conceptos necesarios, dentro de los cuales el de memoria evanescente juega un papel preponderante. Se mostró que este concepto puede ser visto como una cierta forma de continuidad del operador relacionado al sistema. Cabe destacar que son pocos los resultados disponibles que permiten establecer en qué condiciones un sistema dinámico posee memoria evanescente, siendo dicho problema objeto de investigaciones actuales.

El desarrollo de la tesis continuó con la presentación de la metodología para determinar la estructura LNet. El polo de la expansión fue determinado suponiendo que se dispone la constante de tiempo principal del sistema o que es fácil de evaluar. Alternativamente, dicho polo puede ser evaluado aproximando en algún sentido la respuesta del sistema a una secuencia de excitación, mediante la sección pasabajos de los sistemas de Laguerre. Los parámetros restantes de la estructura son la cantidad de sistemas de Laguerre y el número de neuronas en la capa oculta. La utilización de los denominados coeficientes de Lipschitz, cuyo uso se fundamenta en la continuidad del operador LNet ha mostrado ser un instrumento útil para la evaluación del número de sistemas de Laguerre. Desde un punto de vista práctico, se dispone de un medio que permite acotar la cantidad

de sistemas de Laguerre a utilizar basado en la información disponible. En la estimación de la cantidad de neuronas de la capa oculta, se utilizó una variación de las técnicas de poda. Dicha técnica se basa en una descomposición en valores singulares de la matriz de datos propagada a través de la capa oculta. Finalmente fueron presentados los procedimientos necesarios para validar al modelo obtenido. Son válidas algunas consideraciones respecto a determinados aspectos del modelado.

Una de ellas es sobre la utilización de sistemas de Laguerre cuando el sistema que se pretende modelar es muy oscilatorio. Es conocido que aún en los casos lineales, este problema conlleva a una convergencia lenta de los coeficientes del modelo de Laguerre. Una solución posible consistiría en utilizar series de Kautz [76]. Dichas series son ortogonales, pero a diferencia de las de Laguerre se generan en base a un único polo complejo lo cual permite expresar a un sistema lineal, como una sumatoria de secciones ortogonales de segundo orden. Otra posible base para expresar a un sistema muy oscilatorio, consiste en utilizar ciertas secciones ortogonales de segundo orden como en [14] generadas por polos diferentes. El inconveniente con ambos métodos es que aplicado a modelos no lineales sus algoritmos de entrenamiento se complicarían excesivamente como consecuencia que de que se debería estimar el valor de los polos y los parámetros del Perceptrón en forma conjunta. Resta una consideración sobre el modelo obtenido que debido a la forma de su evaluación, no es óptimo en el sentido de la cantidad de parámetros que lo constituyen. Sin embargo, correctamente validado presenta una alternativa razonable a esquemas con recurrencia, balanceando el esfuerzo de entrenamiento y el de determinación de la estructura.

La metodología presentada fue ilustrada a través de diversos ejemplos que ilustran facetas específicas de la estrategia de modelación presentada. El primer ejemplo ilustró la capacidad de la metodología de modelación presentada para hallar la estructura correcta de un sistema no lineal discreto, invariante en el tiempo, causal y que posee memoria evanescente. La aproximación obtenida por la estructura LNet superó sensiblemente a la obtenida mediante la estructura cascada-paralelo de Korenberg. Dicho experimento contiene dos elementos comunmente hallados en la realidad: la presencia de ruido y de saturación. Se evaluó en este ejemplo la capacidad de determinar la estructura LNet en presencia de ruido de medición de salida. En caso de que los datos contengan ruido, es recomendable utilizar un algoritmo de propagación del error hacia

atrás robusto ("Robust Back Error propagation Algorithm", [11]). Dicha técnica fue utilizada en la estimación de ciertas relaciones entre las variables de un horno de craqueo de etileno, con datos reales que contenían ruido de medición y errores gruesos por Sánchez y col. [59] con notable éxito. Dicho algoritmo es relativamente insensible al sobreajuste de parámetros, lo cual plantea una alternativa interesante: la de comenzar el ajuste de la estructura LNet con un número sobreabundante de sistemas de Laguerre y aplicar alguna técnica de poda para obtener realizaciones con un menor número de parámetros. Dicho enfoque constituirá el objeto de futuras investigaciones. En segundo término, se presentó un caso cancelación de eco no lineal en una línea telefónica para ilustrar las ventajas de la estructura LNet sobre un FIR No Lineal respecto de la cantidad de términos que son necesarios para aproximar a un dado sistema. En este caso se mostró la cantidad sensiblemente menor de parámetros requeridos por la estructura LNet respecto del FIR No Lineal. Además se contrastó la exactitud de los resultados de aproximación obtenidos para el FIR no Lineal con resultados previamente publicados. El último de los ejemplos presentados consideró la aplicación de la metodología propuesta en el modelado de una columna de destilación binaria de alcoholes. Los resultados de aproximación obtenidos fueron comparados con los de la estructura cascada-paralelo de Korenberg, resultando sensiblemente mejores los de la estructura LNet. En dicho ejemplo fue considerada una extensión para sistemas MISO de la metodología presentada. Se mostró que las capacidades de aproximación de la estructura LNet MISO superaron a las obtenidas con un modelo lineal. La obtención de resultados teóricos que permitan establecer las capacidades de aproximación de la estructura LNet para sistemas MISO y MIMO será objeto de futuras investigaciones. Adicionalmente se presentaron pautas de diseño que

permiten utilizar a los modelos LNet en estrategias de control predictivo. Cabe señalar dos posibles objetos de estudio para futuras líneas de investigación en los aspectos relacionados al control. Uno de ellos es la determinación de condiciones de estabilidad para las estrategias de control predictivo utilizando los modelos LNet. Otro aspecto interesante que merece ser estudiado con detenimiento, es la aplicación de técnicas provenientes del álgebra diferencial a modelos no lineales discretos. Resultados parciales previos indican que es posible obtener un modelo aproximado discreto de un sistema no lineal continuo, y luego aplicar técnicas de linealización entrada–salida [37] utilizando el modelo obtenido. Procediendo de tal forma, sería posible utilizar un mode-

lo discreto LNet identificado a través de datos entrada-salida, para linealizar al sistema continuo.

Bibliografía

[1] Arnold C. R. y K. S. Narendra, "The Characterization and Identification of Systems", Technical Report 471, Hardvard University, New York (1965).

[2] Banks S. P., *Mathematical Theories of Nonlinear Systems*, Englewood Cliffs: Prentice Hall, New York (1988).

[3] Barron A. R., "Universal Approximation Bounds for Superposition of a Sigmoidal Function", *IEEE Trans. on Information Theory*, **39**, 3, 930-945 (1993).

[4] Billings S. A.,"Identification of Nonlinear Systems-a Survey", *IEE Proceedings Pt. D.*, **127**, 6, 272-284 (1980).

[5] Billings S. A. y W. S. Voon, "Correlation Based Model Validity Tested for Non-linear Models", *Int. Journal. of Control*, **44**, 1, 235-244 (1986).

[6] Boyd S. y L. Chua, "Fading Memory and the Problem of Approximating Nonlinear Operators with Volterra Series", *IEEE Trans. on Circuits and Systems*, **32**, 11, 1150-1161 (1985).

[7] Brause R. W.,"The Error-Bounded Descriptional Complexity of Approximation Networks", *Neural Networks*, **6**, 177-187 (1993).

[8] Brillinger D. R., "The Identification of Polynomial Systems by Means of Higer Order Spectra", *J. Sound Vib.*, **12**, 301-313 (1970).

[9] Broome P. W., "Discrete Orthonormal Sequences", *Journal of the Association for Computing Machinery*, **12**, 2, 151-168 (1965).

[10] Carpenter G. A. y S. Grossberg, "The ART of Adaptive Pattern Recognition by a Self-recognizing Neural Network", *IEEE Computer*, March, 77-88 (1988).

[11] Chen S. D. y C. J. Jain, "A Robust Back Propagation Learning Algorithm for Function Approximation", *IEEE Trans. on Neural Networks*, **5**, 3, 467-479 (1994).

[12] Chen Q. y W. A. Weigand, "Dynamic Optimization of Nonlinear Processes by Combining Neural Net Model with UDMC", *AIChE Journal*, **40**, 8, 1488-1498 (1994).

[13] Colantonio C. y B. Brignole, "Ajuste de un Modelo Bilineal Dinámico para una Columna Binaria de Alcoholes", R*eporte Interno: PLAPIQUI-UNS* (1994).

[14] Cousseau J.E., Sentoni G., Diniz P.S.R. y O. Agamennoni, "On Orthogonal Parallel Realization for IIR Adaptive Filters", *Proceedings of the ICECS'96 Meeting*, Rodas, Grecia (1996).

[15] Cybenko G., "Approximation by Superposition of Sigmoidal Functions", *Mathematics of Control Signal and Systems*, 303-314 (1989).

[16] Dahleh M. A., Sontang E. D., Tse D. N. C. y L. S. Cao, "Worst-case Identification of Nonlinear Fading Memory Systems", *Automatica*, **31**, 3, 503-508 (1995).

[17] Dieudonne J., *Foundations of Modern Analysis*, Academic, New York (1969).

[18] Donat J. S., Bath N. y T. McAvoy, "Optimizing Neural Net Based Predictive Control", *Internal Document of the Dept. Chem. Eng. University of Maryland* (1990).

[19] Elias-Juares A. y J. C. Kantor, "On the Application of Wavelet to Model Predictive Control", *In the Proceedings of the ACC '90*, San Francisco,1582–1586 (1990).

[20] Eskinat E., Johnson S. H. y W. L. Luyben, "Use of Hammerstein Models in Identification of Nonlinear Systems", *AIChE Journal*, **37**, 255-265 (1991).

[21] García C. E., Prett D. M. y M. Morari, "Model Predictive Control: Theory and Practice – A Survey", *Automatica*, **25**, 3, 335-348 (1989).

[22] Gilbert E. "Functional Expansions for the Response of Nonlinear Diferential Systems", *IEEE Transactions on Automatic Control,* **22**, 909-921 (1977).

[23] C. L. Giles, G. M. Kuhn and J. Williams, "Dynamic Recurrent Neural Nerworks: Theory and Applications", *Special Issue on Dynamic Recurrent Networks: IEEE Trans. on Neural Networks*, **5**, 2, 153–157 (1994).

[24] Hajnal A., Maass W., Pudlak P., Szegedyand M. y G. Turan, "Treshold Circuits of Bounded Depth", *in Proceedings of the 1987 IEEE Symposium on the Fundation of Computer Science*, 99-110 (1987).

[25] Hernández H. y Y. Arkun, "Neural Network Modeling and an Extended DMC Algorithm to Control Nonlinear Systems", *In the Proceedings of the ACC '90*, San Francisco, 2454–2459 (1990).

[26] Hernandez E. y Y. Arkun, "Control of Nonlinear Systems using Polynomial ARMA Models", *AIChE Journal*, **39**, 3, 446-460 (1993).

[27] Hopfield J. J. y D. W. Tank, "Neural Computations of Decisions in Optimization Problems", *Biolog. Cybern.*, **52**, 141-152 (1985).

[28] Huang S. C. y Y. F Huang, "Bounds on Number of Hidden Neurons in Multilayer Perceptron", *IEEE Trans. on Neural Networks*, **2**, 1, 47-55 (1991).

[29] Isidori A., *Nonlinear Control Systems*, Springer-Verlag (1989).

[30] Kohonen T., "The Self-organizing Man", *Proceedings of IEEE*, **78**, 1464-1480 (1990)

[31] Kolmogorov A. N y S. V. Fomin, *Introductory Real Analysis*, Dover Publications, New York (1980).

[32] Korenberg M., "Statistical Identification of Parallel Cascades of Linear and Nonlinear Systems", *in the IFAC Proceedings of Identification and System Parameter Estimation,* 669-674, Washington D.C., USA (1982).

[33] Korenberg M. J. y Larry D. Paarmann, "Orthogonal Approaches to Time-Series Analysis and System Identification", *IEEE Signal Processing Magazine,* 29-43, Julio (1991).

[34] Kosko Bart, *Neural Networks and Fuzzy systems. A Dynamicall Approach to Machine Intelligence,* Prentice-Hall International Editions, New York (1992).

[35] Vladik Kreinovich, "Arbitrary Nonlinearity is sufficient to Represent all Functions by Neural Networks: a Theorem", *Neural Networks*, **4**, 381-382 (1991).

[36] Kunn S. Y. y J. N. Hwang, "An Algebraic Projection Analysis for Optimal Units Size and Learning Rate in Backpropagation Learning", *Caltech Libraries,* I363-I370 (1988).

[37] Lee Hong-Gi y S. I. Marcus, "On Input-output Linearization of Discrete-time nonlinear Systems", *Systems & Control Letters*, **8**, 249-259 (1987).

[38] Leontaritis I. y S. Billings, "Input-output Parametric Models for Nonlinear Systems, Part i: Deterministic Nonlinear Systems. Part II: Stochastic Nonlinear Systems", *International Journal of Control*, **41**, 303-344 (1985).

[39] Ljung L. y T. Söderstrom, *Theory and Practice of Recursive Identification,* M.I.T. Press, Cambridge (1985).

[40] Mäkilä P. M.,"Laguerre Series Approximation of Infinite Dimensional Systems", *Automatica*, **26**, 6, 985-995 (1990).

[41] Marmarelis P. Z. y K. Naka, " Identification of Multinput Biological Systems", *IEEE Trans. on Biomedical Engineering*, **21**, 88-101 (1974).

[42] Matthews M. B. y G. S. Moschytz, "The Identification of Nonlinear Discrete-Time Fading-Memory Systems Using Neural Network Models", *IEEE Trans. on Circuits and Systems II*, **41**, 11, 740-903 (1994).

[43] Matthews V. J., "Adaptive Polynomial Filters", *IEEE Signal Processing Magazine*, **7**, 10-26 (1991).

[44] Mayne D. Q. y H. Michalska, "Moving Horizon Observers and Observer-based Control", *IEEE Trans. on Automatic Control,* **40**, 6, 995-1005 (1995).

[45] Michalska H. y D. Q. Mayne, "Robust Receeding Horizon Control of Constrained Non-Linear Systems", *IEEE Trans. on Automatic Control,* **38**, 11, 1623-1633 (1993).

[46] Middleton R. H. y G. C. Goodwin, *Digital Estimation and Control: a Unified Approach*, Englewood Cliffs: Prentice Hall, New Jersey (1990).

[47] Moody J. y C. J. Darken, "Fast Learning in Networks of Locally Tuned Processing Units", *Neural Computation*,**1**, 281-294 (1988).

[48] Murata N. y S. Yoshizawa, "Network Information Criterion-Determining the Number of Hidden Units for an Artificial Neural Network Model", *IEEE Trans. on Neural Networks*, **5**, 6, 865-872 (1994).

[49] Narendra K. S. y P. G. Gallman, "An Iterative Method for the Identification of Nonlinear Systems Using Harmmerstein Models", *IEEE Trans. on Automatic Control,* **11**, 546-550 (1966).

[50] Narendra K. S. y K. Parthasarrathy, "Identification and Control of Dynamical Systems Using Neural Networks", *IEEE Trans. on Neural Networks*, **1**, 1, 4-97 (1990).

[51] Nebot E. , Sentoni G. y F. Masson , "Identification of a Flexible Manipulator Using Neural Networks", *Proceedings of the IFAC'93 Meeting*, Sydney, Australia, **8**, 199-203 (1993).

[52] Noble B. y J. W. Daniels, *Applied Linear Algebra*, Prentice-Hall, Englewood Cliffs, New Jersey (1977).

[53] Oppenhiem A. V. y R. W. Schafer, *Digital Signal Processing*, Prentice Hall, United Kingdom (1975).

[54] Palm G. y T. Poggio, "The Volterra Representation and the Wiener expansion: Validity and Pitfalls", *SIAM J. Appl. Math.*, **33**, 1, 195-216 (1977).

[55] Partington J. R., "Approximation of Delay Systems by Fourier-Laguerre Series", *Automatica*, **27**, 3, 569-572 (1991).

[56] Partington J. R. y P. M. Mäkilä, "Modeling of Linear Fading Memory Systems", *IEEE Trans. on Automatic Control*, **41**, 6, 899-903 (1996).

[57] Psichogios D. C. y L H. Ungar, "SVD: an Algortihm that Automatically Selects Network Structure", *IEEE Trans. on Neural Networks*, **5**, 3, 513-515 (1994).

[58] Rumelhart D. E. y J. L. McClelland, *Parallel Distributed Processing: Exploration in the Microstructure of Cognition 1*, MIT Press, Cambridge (1986).

[59] Sánches M., Sentoni G., Schbib S., Tonelli S. y J. Romagnoli, "Gross Measurements Error Detection /Identification for an Industrial Ethylene Reactor", *Computer Chemical Engineering*, **20**S, 1559-1564 (1996).

[60] Sandberg Irwin W., "Approximation Theory for Discrete-Time Systems", *IEEE Trans. on Circuits and Systems*, **38**, 5, 564-566 (1991).

[61] Sartori M. A. y P. J. Antsaklis,"A Simple Method to Derive Bounds on the Size and to Train Neural Networks", *IEEE Trans. on Neural Networks*, **2**, 4, 467-471 (1991).

[62] Sentoni G., Agamennoni O., E. Nebot y J. Romagnoli, "Identificación de Sistemas utilizando Implementaciones Mínimas de Redes Neuronales", *Anales del XIV Congreso Interamericano de Ingenieria Química*, Buenos Aires, Argentina, I-14 (1991).

[63] Sentoni G., Agamennoni O., Desages A. y J. Romagnoli, "Neural Network Modelling: Structural Analysis Via Singular Value Decomposition", *Proceedings of the APCChE/CHEMECA'93 Meeting*, Melbourne, Australia, **3**, 205-210 (1993).

[64] Sentoni G., Agamennoni O. y J. Romagnoli, "On the Evaluation of a Certain Kind of Approximation Structure", *Latin American Applied Research*, **25**s, 35-40 (1995).

[65] Sentoni G., Agamennoni O., Desages A. y J. Romagnoli, "Approximate Models for Nonlinear Process Control", *AIChE Journal*, **42**, 8, 2240-2250 (1996).

[66] Shamma J., "The Necessity of Small-Gain Theorem for Time Varing and Nonlinear Systems", *IEEE Trans. on Automatic Control*, **36**, 10, 1138-1147 (1991).

[67] Shamma J. S. y R. Zhao, "Fading-memory feedback systems and roubust stability", *Automatica*, **29**, 191-200 (1993).

[68] Sondhi M. M. y D. Berkley,"Silencing Echoes on the Telephone Network", *Proceedings of the IEEE,* **68**, 8, 948-963 (1980).

[69] Sontag E., "Realization Theory of Discrete-time Nonlinear Systems: Part I–the bounded case", *IEEE Trans. Circuits and Systems*, **26**, 4, 342-356 (1979).

[70] Sontag E., *Polynomial Response Maps*, Academic Press, New York (1979).

[71] Stone J. A., "Desidered Global Rates of Convergence for Nonparametric Regresion", *Ann. Stat.*, **10**, 1040-1053 (1982).

[72] Tang Z. y G. J. Koehler, "Estimating Lipschitz Constants of Feedforward Neural Networks", *Proceedings of the Third International Neural Networks Conference*, San Diego, California, 3, 714-719 (1994).

[73] Taylor J. G., "Living Neural Nets. Tutorial", *New developments in Neural Computing: Neural Computing Meeting*, London, England, 31-51 (1989).

[74] Vidyasagar M., *Nonlinear Systems Analysis*, Englewood Cliffs: Prentice Hall, New Jersey (1993).

[75] Wahlberg Bo, "System Identification Using Laguerre Models", *IEEE Trans. on Automatic Control*, **36**, 5, 551-562 (1991).

[76] Wahlberg Bo, "System Identification Using Kautz Models", *IEEE Trans. on Automatic Control*, **39**, 6, 1276-1282 (1994).

[77] Wiener N., *The Theory of Prediction, Modern Math for Engrs,* Bechenbach: McGraw Hill, New York (1956).

[78] Xiangdong He y Asada Haruhiko, "A New Method for Identifying Orders of Input-Outputs Models for Nonlinear Dynamic Systems", *Proceedings of the ACC'93 M*eeting, San Francisco, USA, 2520–2523 (1993).

[79] Yasui S., "Stochastic Functional Fourier Series, Volterra Series and Nonlinear System Analysis", *IEEE Trans. on Automatic Control*, **24**, 3, 239-242 (1979).

[80] Zervos C., Bélanger P. R. y G. A. Dumont, "On PID Controller Tuning using Orthonormal Series Identification", *Automatica*, **24**, 2, 165-175 (1988).

Apéndice A

Propiedades de los Sistemas de Laguerre.

Serán expuestas algunas propiedades del conjunto de sistemas de Laguerre $L_n(\mathfrak{z})$, definidos por la ecuación 1.15 para $nd = 1$, siendo su versión temporal $l_n(k) = \mathcal{Z}^{-1}[L_n(\mathfrak{z})]$. Para dichos sistemas son válidas las siguientes propiedades.

A) *El conjunto de sistemas es exponencialmente estable.*

Los sistemas se pueden expresar en el campo transformado como $L_n(\mathfrak{z}) = \sum_{k=0}^{\infty} l_n(k)\,\mathfrak{z}^{-k}$ para $|a| < 1$, lo cual implica que la serie es absolutamente convergente para $|\mathfrak{z}| > |a|$. Seleccionando al valor $\mathfrak{z} = \mathfrak{z}_1$, tal que $|a| < |\mathfrak{z}_1| < 1$ implica la convergencia de $\sum_{k=0}^{\infty} \left|l_n(k)\,\mathfrak{z}_1^{-k}\right| < \infty$. Como la serie es absolutamente convergente, existe una constante finita A tal que $\left|l_n(k)\,\mathfrak{z}_1^{-k}\right| < A$. Una elección posible para acotar $|l_n(k)|$ es tomar $A = n + 1$, y $r = |\mathfrak{z}_1|$, con lo cual

$$|l_n(k)| < (n+1)\,r^k. \tag{A.1}$$

Con esta elección de r, $|a| < |r| < 1$, $|l_n(k)|$ se debe aproximar a cero 0 al menos exponencialmente para $n \to \infty$ □

B) El conjunto de los sistemas de Laguerre es ortonormal, es decir que vale

$$\sum_{k=0}^{\infty} l_p(k)\,l_q(k) = \begin{cases} 0 & p \neq q \\ 1 & p = q \end{cases}. \tag{A.2}$$

Esta propiedad puede demostrarse a través de la relación de Parseval para sistemas discretos [53, pag. 66] para lo cual se parte de

$$\sum_{k=0}^{\infty} l_p(k)\, l_q(k) = \frac{1}{2\pi j} \oint_C L_p(\mathfrak{z})\, L_q\left(\mathfrak{z}^{-1}\right) \mathfrak{z}^{-1} d\mathfrak{z}, \tag{A.3}$$

donde $j = \sqrt{-1}$, $L_n(\mathfrak{z})$ establecido por la ecuación 1.15, $l_n(k)$ la antitransformada de $L_n(\mathfrak{z})$. Para seleccionar la curva C hay que tener en cuenta a la región de integración, marcada por los polos de $L_p(z)\, L_q\left(\mathfrak{z}^{-1}\right) \mathfrak{z}^{-1}$. Los polos de $L_p(\mathfrak{z})$ están en $\mathfrak{z} = a$, mientras que los de $L_q\left(\mathfrak{z}^{-1}\right)$ están en $\mathfrak{z} = a^{-1}$, por lo tanto elijiendo a $C : |\mathfrak{z}| = 1$ se está en la región de convergencia $a < |\mathfrak{z}| < a^{-1}$ donde $|\mathfrak{z}|$ indica la operación módulo de $\mathfrak{z}$. Reemplazando los valores de $L_n(\mathfrak{z})$ de 1.15 en A.3 obtenemos

$$\frac{1}{2\pi j} \oint_C L_p(\mathfrak{z})\, L_q\left(\mathfrak{z}^{-1}\right) \mathfrak{z}^{-1} d\mathfrak{z} = \frac{1}{2\pi j} \oint_C 1-a^2 \frac{\mathfrak{z}}{\mathfrak{z}-a} \left(\frac{1-a\mathfrak{z}}{\mathfrak{z}-a}\right)^p \frac{\mathfrak{z}^{-1}}{\mathfrak{z}^{-1}-a} \left(\frac{1-a\mathfrak{z}^{-1}}{\mathfrak{z}^{-1}-a}\right)^q \mathfrak{z}^{-1} d\mathfrak{z}$$

Agrupando términos

$$\sum_{k=0}^{\infty} l_p(k)\, l_q(k) = \frac{1-a^2}{2\pi j} \oint_C \frac{1}{\mathfrak{z}-a} \frac{1}{1-a\mathfrak{z}} \left(\frac{\mathfrak{z}-a}{1-a\mathfrak{z}}\right)^{q-p} d\mathfrak{z}, \tag{A.4}$$

se llega a la expresión deseada, que es necesario evaluar para los casos $p = q$ y $p \neq q$.

$p = q$: En este caso es necesario evaluar a la integral de la ecuación A.4 para $p = q$

$$\oint_C \frac{1}{\mathfrak{z}-a} \frac{1}{1-a\mathfrak{z}} d\mathfrak{z}, \tag{A.5}$$

lo que se hará utilizando el Teorema del los Residuos de Cauchy. El contorno C debe contener a la región de convergencia, que en este caso es $a < |\mathfrak{z}| < 1/a$, de forma tal que existe un solo polo $\mathfrak{z} = a$. El residuo de la ecuación A.5 calculado en $\mathfrak{z} = a$ toma el valor de $2\pi j/1 - a^2$, con lo cual por la ecuación A.4 se demuestra que

$$\sum_{k=0}^{\infty} l_p(k)\, l_p(k) = 1.$$

$p \neq q$: En este caso es necesario evaluar a la integral de la ecuación A.4 para $p \neq q$.

Supongamos que $q > p$ (dado que son intercambiables es indistinto)

$$\oint_C \frac{1}{(1-a\mathfrak{z})\,(1-a\mathfrak{z})^{q-p}} d\mathfrak{z}. \tag{A.6}$$

Resulta fácil ver que la integral A.6 no tiene polos dentro de la región de integración $a < |\mathfrak{z}| < 1/a$. Por lo tanto el residuo es nulo con lo cual por la ecuación A.4 se demuestra que para $p \neq q$:

$$\sum_{k=0}^{\infty} l_p\,(k)\,l_q\,(k) = 0.$$

□

Apéndice B

Lema I.

Lema 4. *Considérese la norma* $\|u\|_w$ *definida por la ecuación 3.5 en el espacio* $l^\infty(\mathbb{Z}_-)$. *Luego, dado* $m_1 > 0$, *el espacio*

$$\mathbf{K}_- \triangleq \left\{ u \in l^\infty(\mathbb{Z}_-) \;\middle|\; \|u\|_\infty \leq m_1 \right\} \tag{B.1}$$

provisto de la norma $\|u\|_w$ *es compacto.*

Prueba. Debemos mostrar que el espacio $\mathbf{K}_-$ con la norma $\|u\|_w$ es compacto en $l^\infty(\mathbb{Z}_-)$, para lo cual elegimos cualquier secuencia $\{u_n\}$ en $\mathbf{K}_-$ con $n = 1, 2, 3, \ldots$Es un resultado conocido que el espacio l^∞ de las secuencias acotadas provisto de la norma $\|\cdot\|_\infty$ no es compacto [31]. Sin embargo la restricción de $\mathbf{K}_-$ en $[-n, 0]$, notada como $\mathbf{K}_-[-n, 0]$ es compacto por ser un conjunto de valores finitos para cada n y estar uniformemente acotado por m_1. Para la demostración de la compacidad de $\mathbf{K}_-$ procederemos a encontrar un $u_0 \in \mathbf{K}_-$ y una subsecuencia de $\{u_n\}$ que converja a u_0 en la norma $\|\cdot\|_w$. Sea $\mathbb{N}$ el conjunto de los números naturales. Como por hipótesis, $|u_n(0)| \leq m_1$ es posible encontrar un $u_0(0) \in \mathbf{K}_-[0]$ y un subconjunto infinito $\mathbb{N}_0 \subset \mathbb{N}$ tal que

$$|u_n(0) - u_0(0)| \to 0 \qquad \text{para } n \to \infty, \qquad n \in \mathbb{N}_0.$$

Si a su vez se considera a $\{u_n | \, n \in \mathbb{N}_0\}$ como a una secuencia en $\mathbf{K}_-[-1, 0]$ es posible concluir que existe $u_0(-1) \in \mathbf{K}_-[-1, 0]$ y un subconjunto infinito $\mathbb{N}_1 \subset \mathbb{N}_0$ tal que

$$\sup_{-1 \leq k \leq 0} |u_n(k) - u_0(k)| \to 0 \qquad \text{para } n \to \infty, \qquad n \in \mathbb{N}_1.$$

Continuando con el razonamiento anterior encontramos a un $u_0 \in \mathbf{K}_-$ y una secuencia decreciente de subconjuntos infinitos $\mathbb{N}_0 \supset \mathbb{N}_1 \supset \mathbb{N}_2 \cdots$ tal que para cada m

$$\sup_{-m \leq k \leq 0} |u_n(k) - u_0(k)| \to 0 \qquad \text{para } n \to \infty, \qquad n \in \mathbb{N}_m. \tag{B.2}$$

Se procede ahora por un argumento diagonal a tomar una secuencia creciente n_m tal que $n_m \in \mathbb{N}_m$, es decir se toman para cada k las subsecuencias que convergen a $u_0(k)$. Luego por la ecuación B.2 para cada m_0 tenemos que

$$\sup_{-m_0 \leq k \leq 0} |u_{n_m}(k) - u_0(k)| \to 0 \qquad \text{para } n \to \infty,$$

lo que significa que la secuencia u_{n_m}converge en forma puntual a u_0 en subconjuntos compactos.

Resta mostrar que $\lim_{m\to\infty} \|u_{n_m} - u_0\|_w = 0$, es decir que u_{n_m}converge a u_0 en la norma $\|u\|_w$. Como la secuencia pesante de la norma $w(k) \to 0$ cuando $k \to \infty$, es posible hallar un $m_0 \in \mathbb{N}$ tal que $w(m_0) \leq \epsilon/2M_1$, con $\epsilon > 0$; y como $u_{n_m}, u_0 \in \mathbf{K}_-$ se tiene que

$$\sup_{k \leq -m_0} |u_{n_m}(k) - u_0(k)|\, w(-k) \leq 2M_1 w(m_0) < \epsilon. \tag{B.3}$$

Ahora se encuentra un m_1 tal que

$$\sup_{-m_0 \leq k \leq 0} |u_{n_m}(k) - u_0(k)| \leq \epsilon, \qquad \text{para } m \geq m_1. \tag{B.4}$$

Luego por las ecuaciones B.3 y B.4, y como $w(k) \leq 1$ se concluye que

$$\|u_{n_m} - u_0\|_w \leq \epsilon, \qquad \text{para } m \geq m_1.$$

La norma pesada $\|\cdot\|_w$ actúa de forma tal que hace aparecer compacto al subespacio $\mathbf{K}_-$. Vimos que provisto de la norma $\|\cdot\|_\infty$ este subespacio no es compacto, pero que si lo es si se considera la restricción en un conjunto de valores $\mathbf{K}_-[-n, 0]$. La norma pesada $\|\cdot\|_w$ hace compacto a $\mathbf{K}_-$ produciendo un evanescimiento de la cola de la secuencia, lo que es equivalente a decir que lo pesa de forma tal que parece como si fuera $\mathbf{K}_-[-n, 0]$. Esto concluye la prueba del Lema □

Apéndice C

Modelo de la Columna de Destilación Binaria de Alcoholes.

A continuación se procederá a explicitar el modelo de la columna de destilación de n platos cuyo proceso esquematiza la Figura 5.12, para lo cual sean las siguientes definiciones:

x_k, z_k : son las concentraciones de líquido y vapor en el k-ésimo plato.

M_k : coeficiente de equilibrio vapor-líquido en el k-ésimo plato.

L_k : caudal de líquido en el k-ésimo plato.

V_k : caudal de vapor en el k-ésimo plato.

L_F : caudal de líquido en la alimentación.

X_F : concentración de líquido en la alimentación.

H : líquido retenido en un plato ("holdup").

H_D : holdup de líquido en el condensador.

H_B : holdup de líquido en el rebullidor.

En cada plato existe una relación no lineal entre el vapor y líquido en equilibrio dada por

$$M_k = \frac{\alpha_k}{1 + (\alpha_k - 1)\, x_k},$$

donde α_k es la volatilidad relativa correspondiente al k-ésimo plato, la cual se considera constante. En la sección del condensador, las ecuaciones de balance de masa resultan, considerando al plato 1 como el de tope

$$V_2 z_2 - L_1 x_1 - (V_2 - L_1)\, x_1 = H_D\, \dot{x}_1 \ .$$

para el cual tomando $V_2 = V$ constante para todos los elementos y expresando la concentración del vapor en términos de la del líquido, $z_2 = M_2 x_2$, resulta

$$\dot{x}_1 = \frac{V}{H_D} \left(M_2 x_2 - x_1\right) .$$

Para un plato de la sección de rectificación, y considerando que la alimentaxión se realiza en el plato k tenemos

$$L_{i-1} x_{i-1} - L_i x_i + V_{i+1} z_{i+1} - V_i z_i = H_i\, \dot{x}_i \ ,$$

y usando $z_i = M_i x_i$, $L_i = L$, $V_i = V$, $H_i = H$, obtenemos

$$\dot{x}_i = \frac{1}{H} \left[L\left(x_{i-1} - x_i\right) + V\left(M_{i+1} x_{i+1} - M_i x_i\right)\right] ,$$

para $i : 1, \ldots, k-1$. Finalmente

$$\dot{x}_k = \frac{1}{H} \left[L\left(x_{k-1} - x_i\right) + V\left(M_{k+1} x_{k+1} - M_k x_k\right) + L_F\left(x_F - x_k\right)\right]$$

$$\dot{x}_j = \frac{1}{H} \left[L\left(x_{j-1} - x_j\right) + V\left(M_{j+1} x_{j+1} - M_j x_j\right) + L_F\left(x_{j-1} - x_j\right)\right]$$

para $j : k+1, \ldots, n-1$. De tal forma que el último plato resulta modelado como

$$\dot{x}_n = \frac{1}{H_b} \left[L\left(x_{n-1} - x_n\right) + V x_n - M_n x_n + L_F\left(x_{n-1} - x_n\right)\right]$$

En resumen, el conjunto de ecuaciones diferenciales que modela al sistema es:

$$\begin{cases} \dot{x}_1 = & \frac{V}{H_D}\left(M_2 x_2 - x_1\right) & \\ \quad\vdots & \quad\vdots & \\ \dot{x}_i = & \frac{1}{H}\left[L\left(x_{i-1} - x_i\right) + V\left(M_{i+1}x_{i+1} - M_i x_i\right)\right] & \text{para } i : 1, \ldots, k-1 \\ \dot{x}_k = & \frac{1}{H}\left[L\left(x_{k-1} - x_i\right) + V\left(M_{k+1}x_{k+1} - M_k x_k\right) + L_F\left(x_F - x_k\right)\right] & \\ \dot{x}_j = & \frac{1}{H}\left[L\left(x_{j-1} - x_j\right) + V\left(M_{j+1}x_{j+1} - M_j x_j\right) + L_F\left(x_{j-1} - x_j\right)\right] & \text{para } j : k+1, \ldots, n-1 \\ \quad\vdots & \quad\vdots & \\ \dot{x}_n = & \frac{1}{H_b}\left[L\left(x_{n-1} - x_n\right) + V x_n - M_n x_n + L_F\left(x_{n-1} - x_n\right)\right] & \end{cases}$$

Definiendo como estado del sistema al vector $x = [x_1, \ldots, x_n]^T$, como entradas y salidas a

$$\begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = \begin{bmatrix} \frac{L}{H} \\ \frac{V}{H} \end{bmatrix}, \quad \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} x_2 \\ x_n \end{bmatrix},$$

respectivamente y de una forma normalizada a L_F y X_F

$$\begin{bmatrix} w_1 \\ w_2 \end{bmatrix} = \begin{bmatrix} \frac{L_F}{H} \\ \frac{L_F X_F}{H} \end{bmatrix},$$

el sistema en su versión final es

$$\begin{cases} \dot{x} = & g\left(x\right)u + p\left(x\right)w \\ y = & h\left(x\right) \end{cases}. \tag{C.1}$$

X_F	L_F	V	L	H	H_D	H_B
.5	250	260	145	.45	3.941	4.628

Cuadro C.1: Parámetros de la Columna

Para el presente ejemplo $n = 10$ y $k = 5$, por lo cual

$$g(x) = \begin{bmatrix} 0 & (M_2x_2 - x_1)\frac{H}{H_D} \\ x_1 - x_2 & M_3x_3 - M_2x_2 \\ x_2 - x_3 & M_4x_4 - M_3x_3 \\ x_3 - x_4 & M_5x_5 - M_4x_4 \\ x_4 - x_5 & M_6x_6 - M_5x_5 \\ x_5 - x_6 & M_7x_7 - M_6x_6 \\ x_6 - x_7 & M_8x_8 - M_7x_7 \\ x_7 - x_8 & M_9x_9 - M_8x_8 \\ x_8 - x_9 & M_{10}x_{10} - M_9x_9 \\ (x_9 - x_{10})\frac{H}{H_B} & (x_{10} - M_{10}x_{10})\frac{H}{H_B} \end{bmatrix}, \; p(x) = \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ 0 & 0 \\ 0 & 0 \\ 0 & 0 \\ -x_6 & 1 \\ x_6 - x_7 & 0 \\ x_7 - x_8 & 0 \\ x_8 - x_9 & 0 \\ (x_9 - x_{10})\frac{H}{H_B} & 0 \end{bmatrix}$$

y

$$h(x) = \begin{bmatrix} x_2 \\ x_{10} \end{bmatrix}$$

para los siguientes valores de volatilidad relativa $\alpha = [0, 4.5, 4.2, 4, 3.8, 3, 2.9, 2.7, 2.6, 2.6]^T$